

บทที่ 3. การรวบรวมและจัดเก็บข้อมูล

- 3.1 การรวบรวมจากไฟล์ข้อมูล
- 3.2 การรวบรวมจากฐานข้อมูล
- 3.3 การรวบรวมจาก API
- 3.4 การรวบรวมจาก Web Site
- 3.5 การรวบรวมข้อมูลโดยใช้ SCP/SFTP
- 3.6 การรวบรวมข้อมูลโดยใช้ Software Tools
- 3.7 แบบฝึกหัด



3.1 การรวบรวมจากไฟล์ข้อมูล



```
1  ### ติดตั้ง Libraries ###  
2  # สำหรับจัดการข้อมูล (Data Manipulation)  
3  %pip install pandas  
4  
5  # สำหรับอ่านไฟล์ Excel  
6  %pip install openpyxl  
7  
8  # สำหรับอ่านไฟล์ภาพและแสดงภาพ  
9  %pip install tensorflow matplotlib
```

✓ 2.7s

 Python

```

1  #อ่านข้อมูลจากไฟล์ csv
2  import pandas as pd
3  x=pd.read_csv('data/customer.csv')
4  x

```

	item	age	sex	education_level	occupation	total_spend
0	1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500
1	2	27	ชาย	ปริญญาโท	พนักงานขาย	6200
2	3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000
3	4	35	หญิง	ปริญญาเอก	พนักงานขาย	8000
4	5	41	ชาย	ปริญญาโท	พนักงานขาย	120000
5	6	32	หญิง	ปริญญาตรี	พนักงานขาย	3500
6	7	26	หญิง	ปริญญาโท	พนักงานขาย	11000
7	8	22	ชาย	ปริญญาตรี	พนักงานขาย	8750
8	9	28	ชาย	NaN	พนักงานขาย	15000
9	10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000

```
1 #อ่านข้อมูลจากไฟล์ excel
2 import pandas as pd
3 x = pd.read_excel('data/customer.xlsx')
4 x
```

```
1 #อ่านข้อมูลจากไฟล์ json
2 import pandas as pd
3 x = pd.read_json('data/tourist.json')
4 pd.json_normalize(x['result']['records'])
```

```
1 #อ่านข้อมูลจากไฟล์ json (อ่านโดยตรง)
2 import json
3
4 with open('data/tourist.json', 'r', encoding='utf-8') as f:
5     | tourist = json.load(f)
6
7 tourist
```

```

1  #การอ่านไฟล์ภาพและแสดงภาพ
2  import tensorflow as tf
3  import matplotlib.pyplot as plt
4  import os
5
6  data_dir = "data/celeb"
7  img_size = (224, 224)
8
9  # ดึงรายชื่อโฟลเดอร์ (ชื่อบุคคล) ทั้งหมด
10 persons = os.listdir(data_dir)
11
12 # แสดงภาพตัวอย่างของแต่ละบุคคล
13 plt.figure(figsize=(15, 8))
14 count = 1
15 for person in persons:
16     # ข้ามถ้าไม่ใช่โฟลเดอร์
17     folder_path = os.path.join(data_dir, person)
18     if not os.path.isdir(folder_path):
19         continue
20
21     # หาไฟล์รูปภาพไฟล์แรก
22     image_files = os.listdir(folder_path)
23     img_path = os.path.join(folder_path, image_files[0])
24
25     # อ่านภาพ
26     img = tf.io.read_file(img_path)
27     img = tf.image.decode_image(img, channels=3, expand_animations=False)
28     img = tf.image.resize(img, img_size)
29
30     # แสดงภาพ
31     plt.subplot(2, (len(persons)+1)//2, count)
32     plt.imshow(tf.cast(img, tf.uint8))
33     plt.title(person)
34     plt.axis("off")
35
36     count += 1
37
38
39 plt.tight_layout()
40 plt.show()

```



```
1  #อ่านข้อมูลจาก Google Drive (เฉพาะรันบน Google Colab)
2  from google.colab import drive
3  import pandas as pd
4
5  # เชื่อมต่อ Google Drive
6  drive.mount('/content/drive', force_remount=True)
7
8  #อ่านข้อมูลจากไฟล์ csv
9  x=pd.read_csv('/content/drive/MyDrive/data/customer.csv')
10 x
```

Python

3.2 การรวบรวมจากฐานข้อมูล



```
1  ### ติดตั้ง Libraries ###  
2  # สำหรับเชื่อมต่อฐานข้อมูล MySQL/MariaDB  
3  %pip install sqlalchemy pymysql  
4  
5  # สำหรับเชื่อมต่อฐานข้อมูล MongoDB  
6  %pip install pymongo
```

✓ 3.6s

 Python

นำไฟล์ schema.sql import เข้าไปยัง MySQL ก่อน

```
1  #การเชื่อมต่อฐานข้อมูล MySQL/MariaDB
2  import pandas as pd
3  from sqlalchemy import create_engine
4
5  DB_HOST = 'localhost'
6  DB_USER = 'root'
7  DB_PASSWORD = '1234'
8  DB_NAME = 'shopdee'
9  DB_PORT = '3306'
10
11 #เชื่อมต่อกับ MySQL/MariaDB
12 engine = create_engine(f"mysql+pymysql://{DB_USER}:{DB_PASSWORD}@{DB_HOST}:{DB_PORT}/{DB_NAME}")
13 print("Connected to MySQL!")
14
15 #query ข้อมูล
16 query = '''SELECT
17 |         |         custID, firstName, lastName, birthDate
18 |         |         FROM customer'''
19 x=pd.read_sql(query, engine)
20 x
```

✓ 0.0s

Python

	custID	firstName	lastName	birthDate
0	1	ณเดช	ชัยเจริญ	2000-08-12
1	2	วิรัตน์	ใจชื่อ	2001-06-02
2	3	วิภาดา	มิมมานท์	1999-07-12
3	4	วิชุดา	วิชเดช	1987-01-24
4	5	สุดสัปดาห์	วิมารดร	1985-07-25
5	6	สุทธิกมล	พรพิมาศ	2001-02-14
6	7	สุดเขต	พิสุทธิสาร	2000-12-05
7	8	พิเชษ	วิรการ	2002-11-07
8	9	สมชาย	ใจงาม	1998-11-09
9	10	สมหญิง	ใจงาม	None

นำไฟล์ customer.csv import เข้าไปยัง mongoDB ก่อน

```
1  #การเชื่อมต่อฐานข้อมูล MongoDB
2  from pymongo import MongoClient
3
4  #เชื่อมต่อกับ MongoDB
5  client = MongoClient("mongodb://localhost:27017")
6  db = client["shopdee"]
7  collection = db["customer"]
8  print("Connected to MongoDB!")
9
10 #query ข้อมูล
11 query = "" #เลือกทั้งหมด
12 #query = {"education_level": "ปริญญาตรี"} #เฉพาะตรี
13 #query = {"education_level": {"$in": ["ปริญญาตรี", "ปริญญาโท"]}} #ตรี หรือ โท
14 #query = {"$or": [{"sex": "หญิง"}, {"education_level": "ปริญญาตรี"}]} #หญิง หรือ ตรี
15 data = collection.find(query)
16
17 #แปลงเป็น DataFrame
18 x = pd.DataFrame(list(data)).drop(columns=["_id"])
19 x
```

✓ 0.0s

Python

	item	age	sex	education_level	occupation	total_spend
0	1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500
1	2	27	ชาย	ปริญญาโท	พนักงานขาย	6200
2	3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000
3	4	35	หญิง	ปริญญาเอก	พนักงานขาย	8000
4	5	41	ชาย	ปริญญาโท	พนักงานขาย	120000
5	6	32	หญิง	ปริญญาตรี	พนักงานขาย	3500
6	7	26	หญิง	ปริญญาโท	พนักงานขาย	11000
7	8	22	ชาย	ปริญญาตรี	พนักงานขาย	8750
8	9	28	ชาย	NaN	พนักงานขาย	15000
9	10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000

3.3 การรวบรวมจาก API



ธนาคารแห่งประเทศไทย
BANK OF THAILAND

```
1  ### ติดตั้ง Libraries ###  
2  # สำหรับ API Calling  
3  %pip install requests
```

✓ 0.6s

 Python

```

1  #รวบรวมข้อมูลจำนวนนักท่องเที่ยวต่างชาติที่เดินทางเข้าประเทศไทย จาก data.go.th
2  #สมัครรับ Token (API-Key) : https://opend.data.go.th/register\_api/
3
4  #Import Libraries
5  import requests
6  import pandas as pd
7
8  #กำหนด API endpoint และ parameter สำหรับเรียกข้อมูล
9  BASE_URL = 'https://opend.data.go.th/get-ckan/datastore_search'
10 resource_id = 'faffc63c-9507-451a-80b7-554cc0787368'
11 limit = 100
12 search = 'china'
13 token = 'Your_API_Key_Here' # Replace with your actual API key
14 API_URL = f'{BASE_URL}?resource_id={resource_id}&limit={limit}&q={search}'
15
16 #ดึงข้อมูลจาก API
17 response = requests.get(API_URL,
18     headers = {
19         'api-key': f'{token}'
20         #'Authorization': f'Bearer {token}'
21     })
22 tourist = response.json()
23 df_tourist = pd.DataFrame(tourist['result']['records'])
24 df_tourist

```

✓ 0.6s

Python

	_id	date	continent	Region	Country	Number	rank
0	136	2015-01-01T00:00:00	Asia and the Pacific	North-East Asia	Hong Kong (China)	43,324	0.057309
1	140	2015-01-01T00:00:00	Asia and the Pacific	North-East Asia	Macao (China)	3,073	0.057309
2	415	2015-01-02T00:00:00	Asia and the Pacific	North-East Asia	China	780,139	0.057309
3	416	2015-01-02T00:00:00	Asia and the Pacific	North-East Asia	Hong Kong (China)	70,792	0.057309
4	420	2015-01-02T00:00:00	Asia and the Pacific	North-East Asia	Macao (China)	4,545	0.057309
...	...	...	...	...	...	...	...
95	9095	2017-01-09T00:00:00	Asia and the Pacific	North-East Asia	China	729,902	0.057309
96	9096	2017-01-09T00:00:00	Asia and the Pacific	North-East Asia	Hong Kong (China)	68,068	0.057309
97	9100	2017-01-09T00:00:00	Asia and the Pacific	North-East Asia	Macao (China)	5,230	0.057309
98	9375	2017-01-10T00:00:00	Asia and the Pacific	North-East Asia	China	810,814	0.057309
99	135	2015-01-01T00:00:00	Asia and the Pacific	North-East Asia	China	563,925	0.057309

100 rows × 7 columns

```
1 #บันทึกข้อมูลเป็นไฟล์ CSV
2 df_tourist.to_csv("data/tourist.csv",
3                 index=True, #ไม่บันทึก Index ลงในไฟล์
4                 encoding='utf-8'
5                 ) #กำหนด encoding สำหรับรองรับภาษาไทย
6 print("Saved to CSV")
```

Python

```
1 #บันทึกข้อมูลเป็นไฟล์ Excel
2 df_tourist.to_excel('data/tourist.xlsx',
3                   sheet_name='Sheet1', #กำหนดชื่อ Sheet
4                   index=False, #ไม่บันทึก Index ลงในไฟล์
5                   )
6 print("Saved to Excel")
```

Python

```
1 #บันทึกข้อมูลเป็นไฟล์ JSON
2 import json
3
4 with open('data/tourist.json', 'w', encoding='utf-8') as f:
5     json.dump(tourist, f, ensure_ascii=False, indent=4)
6 print("Saved to JSON")
```

Python

```

1  #บันทึกข้อมูลไว้ในฐานข้อมูล MySQL/MariaDB
2
3  #Import Libraries
4  import requests
5  from sqlalchemy import create_engine, text
6
7  #เชื่อมต่อกับ MySQL/MariaDB
8  DB_HOST = 'localhost'
9  DB_USER = 'root'
10 DB_PASSWORD = '1234'
11 DB_NAME = 'shopdee'
12 DB_PORT = '3306'
13 engine = create_engine(f"mysql+pymysql://{DB_USER}:{DB_PASSWORD}@{DB_HOST}:{DB_PORT}/{DB_NAME}")
14
15 #ดึงจำนวนนักท่องเที่ยวต่างชาติที่เดินทางเข้าประเทศไทย
16 BASE_URL = 'https://opendata.go.th/get-ckan/datastore_search'
17 resource_id = 'faffc63c-9507-451a-80b7-554cc0787368'
18 limit = 100
19 search = 'china'
20 token = 'Your_API_Key' # Replace with your actual API key
21 API_URL = f'{BASE_URL}?resource_id={resource_id}&limit={limit}&q={search}'
22 response = requests.get(API_URL, headers={'api-key': token})
23 data = response.json()
24 records = data['result']['records']
25

```

```

26 #Create a table
27 create_sql = """
28 CREATE TABLE IF NOT EXISTS tourist_inbound (
29     id INT AUTO_INCREMENT PRIMARY KEY,
30     date DATE,
31     continent VARCHAR(255),
32     region VARCHAR(255),
33     country VARCHAR(255),
34     number INT,
35     ranks FLOAT
36 )
37 """
38 with engine.begin() as conn:
39     conn.execute(text(create_sql))
40
41
42 #Insert data into MySQL's table
43 insert_sql = """
44 INSERT INTO tourist_inbound (date, continent, region, country, number, ranks)
45 VALUES (:date, :continent, :region, :country, :number, :rank)
46 """
47

```

```
48 with engine.begin() as conn:
49     for item in records:
50
51         date_value = item.get("date", "")[:10]
52         continent = item.get("continent", "")
53         region = item.get("Region", "")
54         country = item.get("Country", "")
55
56         number_raw = item.get("Number", "").strip().replace(", ", "")
57         number = int(number_raw) if number_raw.isdigit() else None
58
59         rank_value = float(item.get("rank", 0))
60
61         conn.execute(
62             text(insert_sql),
63             {
64                 "date": date_value,
65                 "continent": continent,
66                 "region": region,
67                 "country": country,
68                 "number": number,
69                 "rank": rank_value
70             }
71         )
72
73 print("Inserted data into MySQL successfully!")
```

```

1  ##รวบรวมข้อมูลอัตราแลกเปลี่ยน-เงินตราต่างประเทศเทียบกับเงินบาท จาก ธนาคารแห่งประเทศไทย
2  #สมัครรับ Token (API-Key) : https://portal.api.bot.or.th/
3
4  #Import Libraries
5  import requests
6  import pandas as pd
7
8  #กำหนด API endpoint และ parameter สำหรับเรียกข้อมูล
9  BASE_URL = 'https://gateway.api.bot.or.th/Stat-ExchangeRate/v2/DAILY_AVG_EXG_RATE/'
10 start_period = '2025-12-16'
11 end_period = '2025-12-16'
12 currency = ''
13 token = 'Your_API_Key_Here'
14 API_URL = f"{BASE_URL}?start_period={start_period}&end_period={end_period}&currency={currency}"
15
16 #ดึงข้อมูลจาก API
17 response = requests.get(API_URL,
18     headers = {
19         'Authorization': f'{token}'
20     }
21 )
22 exchange_rate = response.json()
23 df_exchange_rate = pd.DataFrame(exchange_rate['result']['data']['data_detail'])
24 df_exchange_rate

```

✓ 0.6s

Python

	period	currency_id	currency_name_th	currency_name_eng	buying_sight	buying_transfer	selling	mid_rate
0	2025-12-16	USD	สหรัฐอเมริกา : ดอลลาร์ (USD)	USA : DOLLAR (USD)	31.2705000	31.3538000	31.6794000	31.5166000
1	2025-12-16	GBP	อังกฤษ : ปอนด์สเตอร์ลิง (GBP)	UNITED KINGDOM : POUND STERING (GBP)	41.5988000	41.7193000	42.5330000	42.1262000
2	2025-12-16	EUR	ยูโรโซน : ยูโร (EUR)	EURO ZONE : EURO (EUR)	36.5744000	36.6626000	37.3614000	37.0120000
3	2025-12-16	JPY	ญี่ปุ่น : เยน (100 เยน) (JPY)	JAPAN : YEN (100 YEN) (JPY)	19.9229000	20.0124000	20.6569000	20.3347000
4	2025-12-16	HKD	ฮ่องกง : ดอลลาร์ (HKD)	HONG KONG : DOLLAR (HKD)	3.9991000	4.0146000	4.0887000	4.0517000
5	2025-12-16	MYR	มาเลเซีย : รिंगกิต (MYR)	MALAYSIA : RINGGIT (MYR)	7.5616000	7.6040000	7.8209000	7.7125000
6	2025-12-16	SGD	สิงคโปร์ : ดอลลาร์ (SGD)	SINGAPORE : DOLLAR (SGD)	24.0816000	24.1467000	24.7146000	24.4307000
7	2025-12-16	BND	บรูไนดารุสซาลาม : ดอลลาร์ (BND)	BRUNEI : DOLLAR (BND)	23.9613000	24.0513000	24.8095000	24.4304000
8	2025-12-16	PHP	ฟิลิปปินส์ : เปโซ (PHP)	PHILIPPINES : PESO (PHP)	0.5066000	0.5110000	0.5534000	0.5322000
9	2025-12-16	IDR	อินโดนีเซีย : รูเปีย (1,000 รูเปีย) (IDR)	INDONESIA : RUPIAH (1,000 RUPIAH) (IDR)	1.7233000	1.8010000	1.9946000	1.8978000
10	2025-12-16	INR	อินเดีย : รูปี (INR)	INDIA : RUPEE (INR)	0.3160000	0.3235000	0.3764000	0.3500000
11	2025-12-16	CHF	สวิตเซอร์แลนด์ : ฟรังก์ (CHF)	SWITZERLAND : FRANC (CHF)	39.1685000	39.2454000	39.9518000	39.5986000
12	2025-12-16	AUD	ออสเตรเลีย : ดอลลาร์ (AUD)	AUSTRALIA : DOLLAR (AUD)	20.4575000	20.5082000	21.3022000	20.9052000
13	2025-12-16	NZD	นิวซีแลนด์ : ดอลลาร์ (NZD)	NEW ZEALAND : DOLLAR (NZD)	17.8606000	17.9225000	18.5282000	18.2254000
14	2025-12-16	CAD	แคนาดา : ดอลลาร์ (CAD)	CANADA : DOLLAR (CAD)	22.5682000	22.6167000	23.1340000	22.8754000
15	2025-12-16	SEK	สวีเดน : โครนา (SEK)	SWEDEN : KRONA (SEK)	3.3444000	3.3588000	3.4245000	3.3917000
16	2025-12-16	DKK	เดนมาร์ก : โครน (DKK)	DENMARK : KRONE (DKK)	4.9014000	4.9152000	4.9964000	4.9558000
17	2025-12-16	NOK	นอร์เวย์ : โครน (NOK)	NORWAY : KRONE (NOK)	3.0550000	3.0679000	3.1323000	3.1001000
18	2025-12-16	CNY	จีน : หยวน เรนมินบิ (CNY)	CHINA : YUAN RENMINBI (CNY)	4.3984000	4.4231000	4.5314000	4.4773000


```

1  #บันทึกข้อมูลไว้ใน MongoDB
2
3  #Import Libraries
4  import requests
5  from pymongo import MongoClient
6  from datetime import datetime
7
8  #เชื่อมต่อฐานข้อมูล MongoDB
9  client = MongoClient("mongodb://localhost:27017/")
10 db = client["shopdee"]
11 collection = db["daily_exchange_rate"]
12
13 #ดึงอัตราแลกเปลี่ยน-เงินตราต่างประเทศเทียบกับเงินบาท
14 BASE_URL = 'https://gateway.api.bot.or.th/Stat-ExchangeRate/v2/DAILY_AVG_EXG_RATE/'
15 start_period = '2025-12-01'
16 end_period = '2025-12-01'
17 currency = ''
18 token = 'Your_API_Key_Here'
19 API_URL = f"{BASE_URL}?start_period={start_period}&end_period={end_period}&currency={currency}"
20 response = requests.get(
21     API_URL,
22     headers={'Authorization': token}
23 )
24 data = response.json()
25

```

```
26 #Extract JSON
27 details = data["result"]["data"]["data_detail"]
28
29 #สร้าง list อัตราแลกเปลี่ยน
30 rates_list = []
31 for item in details:
32     rates_list.append({
33         "period": item["period"],
34         "currency_id": item["currency_id"],
35         "currency_name_th": item["currency_name_eng"],
36         "currency_name_eng": item["currency_name_eng"],
37         "rate": float(item["mid_rate"]) # ค่า rate
38     })
39
40 #สร้าง JSON Document
41 json_doc = {
42     "scraped_at": datetime.now().isoformat(),
43     "source": "ธนาคารแห่งประเทศไทย",
44     "rates": rates_list
45 }
46
47 #บันทึกข้อมูลลง MongoDB
48 collection.insert_one(json_doc)
49 print("Inserted data into MongoDB successfully!")
```

3.4 การรวบรวมจาก Web Site



worldometer

```
1  ### ติดตั้ง Libraries ###  
2  # สำหรับ web Crawling  
3  %pip install requests  
4  
5  # สำหรับ Web Scraping  
6  %pip install beautifulsoup4
```

✓ 1.8s

 Python

```

1  #ดึงหัวข้อข่าวจาก BBC News
2  import requests
3  from bs4 import BeautifulSoup
4  from datetime import datetime
5
6  url = "https://www.bbc.com/news"
7  response = requests.get(url)
8
9  soup = BeautifulSoup(response.text, "html.parser")
10
11 #ดึงชื่อ Web Page
12 title = soup.find("title").text
13
14 #ดึงหัวข้อ (ข่าว)
15 headlines = []
16 for h in soup.find_all("h2"):
17     text = h.text.strip()
18     if text:
19         headlines.append(text)
20
21 #สร้าง JSON Document
22 json_doc = {
23     "scraped_at": datetime.now().isoformat(),
24     "source": "BBC News",
25     "url": url,
26     "title": title,
27     "headlines": headlines,
28 }
29
30 json_doc

```

```

{'scraped_at': '2026-07-15T06:34:01.846173',
 'source': 'BBC News',
 'url': 'https://www.bbc.com/news',
 'title': 'BBC News - Breaking news, video and the latest top stories from the U.S. and around the world',
 'headlines': ['Trump scraps threat of 20% fee on Hormuz cargo as US resumes blockade of Iran ports',
 'Trump retreat over Hormuz tolls suggests he is struggling to end Iran war',
 'Police say Ann Widdecombe killed in 'targeted attack' as motive investigated',
 "'If we die, we die together': Wife of man nearly sucked out of Ryanair plane speaks of ordeal",
 'Strait of Hormuz 'faultline' exposes weakness of the US-Iran deal',
 'From Wimbledon towels to Scotch: What India-UK trade deal could mean for shoppers',
 'Superb Spain beat France to reach World Cup final',
 'Singapore court orders Bloomberg to pay $356,000 to ministers in defamation case',
 'Tyrannosaurus rex most expensive dinosaur ever sold',
 'Six people found dead in lift shaft after fire in central Brussels building',
 'Fanfare and flyovers as France celebrates Bastille Day',
 'Trump pays writer E Jean Carroll $5m in damages over sexual abuse and defamation',
 "'Explosive diarrhoea' outbreak remains a mystery as officials struggle to find sources",
 'World Cup 2026',
 'Messi's lucky charm? Elfath to ref England v Argentina',
 'Why do Argentina sing about England and the Falklands?',
 'A winner and true friend - Bartoli on France boss Deschamps',
 'Balogun expected controversy after World Cup ban waived',
 'More to explore',
 'There's no evidence this Mitch McConnell rehab photo is AI',
 'Bangkok fire investigation finds locked doors and flammable decor as deaths climb to 30',
 ...
 'England's one-day woes continue with India defeat',
 'Man Utd sign Tielemans for £35m from Aston Villa',
 'Superb Spain beat France to reach World Cup final',
 'Henderson & Quansah only England absentees for Argentina',
 'World Cup final half-time to last up to 25 minutes']]

```

```


1  #ดึงข้อมูลประชากรโลก
2  import requests
3  from bs4 import BeautifulSoup
4  import pandas as pd
5
6  url = "https://www.worldometers.info/world-population/population-by-country/"
7  response = requests.get(url)
8  soup = BeautifulSoup(response.text, "html.parser")
9
10 #ดึง Table Header
11 thead_raw = soup.find("thead").find("tr").find_all("th")
12 thead = [c.text.strip() for c in thead_raw]
13
14 #ดึง Table rows
15 table = soup.find("table")
16 rows = table.find_all("tr")
17
18 data = []
19 for row in rows:
20     cols = row.find_all("td")
21     cols = [c.text.strip() for c in cols]
22     if cols:
23         data.append(cols)
24
25 df = pd.DataFrame(data, columns=thead)
26 df

```

#	Country (or dependency)	Population 2026	Yearly Change	Net Change	Density (P/Km ²)	Land Area (Km ²)	Migrants (net)	Fert. Rate	Median Age	Urban Pop %	World Share
1	India	1,476,625,576	0.87%	12,760,051	497	2,973,190	â€“440,456	1.93	29.2	37.6%	17.79%
2	China	1,412,914,089	â€“0.22%	â€“3,182,005	150	9,388,211	â€“232,107	1.03	40.6	68.7%	17.02%
3	United States	349,035,494	0.51%	1,759,687	38	9,147,420	1,177,848	1.63	38.7	83.1%	4.20%
4	Indonesia	287,886,782	0.76%	2,165,546	159	1,811,570	â€“39,472	2.08	30.7	60.3%	3.47%
5	Pakistan	259,299,791	1.6%	4,080,237	336	770,880	â€“1,144,738	3.44	20.8	34.7%	3.12%
...	...	...	...	...	...	...	...	...	...	...	...
230	Montserrat	4,328	â€“0.71%	â€“31	43	100	â€“10	1.45	41.8	11.7%	0.000052%
231	Falkland Islands	3,465	â€“0.12%	â€“4	0	12,170	â€“16	1.69	43.4	68.4%	0.000042%
232	Tokelau	2,691	3.18%	83	269	10	43	2.54	27.6	â€“	0.000032%
233	Niue	1,822	0.05%	1	7	260	2	2.44	35.1	45.2%	0.000022%
234	Holy See	506	1%	5	1,265	0	13	1	56.2	â€“	0.0000061%

ows x 12 columns

3.5 การรวบรวมข้อมูลโดยใช้ SCP/SFTP



Command
Prompt

3.6 การรวบรวมข้อมูลโดยใช้ Software Tools



Data Conectors



Data Flow Orchestration



Workflow Orchestration

[Extract & Load](#)
[Database Replication](#)
[Data Activation](#)
[AI & Machine Learning](#)
[Custom Connectors](#)
[Analytics & BI](#)

End to end data movement

All of your sources, in one place, with one movement solution. Enable seamless data flows and access for all teams.


[Learn more](#)


ภาพที่ 3-1 : ตัวอย่าง Data Connectors ของ Airbyte


[Documentation](#)[Development](#)[Community](#)[Projects](#)[Apache](#)[Download](#)

An easy to use, powerful, and reliable system to process and distribute data

NiFi automates cybersecurity, observability, event streams, and generative AI data pipelines and distribution for thousands of companies worldwide across every industry.

[Download](#)[View Documentation](#)

ภาพที่ 3-2 : ตัวอย่าง Data Flow ของ Nifi



ภาพที่ 3-3 : ตัวอย่าง Work Flow ของ Airflow

3.7 แบบฝึกหัด

1. ให้ น.ศ. ทำ Data Ingestion ด้วย Airbyte ตาม Guideline ต่อไปนี้

Data Ingestion Guideline

1. ติดตั้ง Airbyte และ MongoDB ลงบน Ubuntu (WSL)
2. ติดตั้ง MongoDB Compass (Windows)
3. ใช้ Airbyte ดึงข้อมูลจาก google Sheet มาที่ MongoDB
 - 3.1 Source : Google Sheet ผ่าน API
 - 3.2 Destination : MongoDB
 - 3.3 Trigger Type : Cron เช่น ทุกวัน ณ 16:00:00 น.
(ต้องเปลี่ยนเวลาเพื่อให้เห็นผลการดึงข้อมูลได้)
 - 3.4 Sync Type : Replicate
 - 3.5 ตรวจสอบผลการดึงผ่าน MongoDB Compass
4. ใช้ Airbyte ดึงข้อมูล อัตราแลกเปลี่ยนจากธนาคารแห่งประเทศไทย
 - 4.1 Source : อัตราแลกเปลี่ยน ผ่าน BOT API
 - 4.2 Destination : MongoDB
 - 4.3 Trigger Type : Manual
 - 4.4 Sync Type : Append (Incremental)
 - 4.5 ตรวจสอบผลการดึงผ่าน MongoDB Compass
5. สร้าง API แล้วใช้ Airbyte ดึงข้อมูลข่าว
 - 5.1 Source : เว็บไซต์ข่าว ผ่าน Custom API (พัฒนา API เอง)
 - 5.2 Destination : MongoDB
 - 5.3 Trigger Type : Manual
 - 5.4 Sync Type : Append (Full)
 - 5.5 ตรวจสอบผลการดึงผ่าน MongoDB Compass

2. ให้ น.ศ. ทำ Data Automation ตาม Guideline ต่อไปนี้

Data Automation Guideline

1. ติดตั้งและคอนฟิกร MongoDB บน Ubuntu (WSL)

1.1 ติดตั้ง Docker Engine

1.2 ติดตั้ง MongoDB

2. ติดตั้งและคอนฟิกร Python บน Ubuntu (WSL)

3. จัดทำและทดสอบ data automation

3.1 ทำการดึงข้อมูลจาก data sources

3.1.1 สร้างไฟล์ data_ingest.py บน Ubuntu (WSL)

- ดึงข้อมูลผ่าน API จาก data.go.th
- ดึงข้อมูลผ่าน API จาก portal.api.bot.or.th
- ดึงข้อมูล จาก www.worldometers.info
- ดึงข้อมูล จาก www.bbc.com/news
- อื่น ๆ (ถ้ามี)
- บันทึกข้อมูลลงไฟล์เตอร์ เช่น /pichai/data หรือฐานข้อมูล เช่น MongoDB

3.1.2 change mode : chmod +x data_ingest.py

3.1.3 ตั้ง crontab ทุก ๆ 22:00 น. : crontab -e

3.2 ทำการ copy/โอน ข้อมูลจาก **Ubuntu (WSL)**

ไปยัง **Ubuntu (VirtualBox)**

3.2.1 สร้างไฟล์ data_ingest.sh บนเครื่อง Ubuntu (VirtualBox)

3.2.2 change mode : chmod +x data_ingest.sh

3.2.3 ตั้ง crontab ทุก ๆ 23:00 น. : crontab -e



Thank you For Your Attention



สาขาวิชาวิทยาการคอมพิวเตอร์
คณะบริหารธุรกิจและเทคโนโลยีสารสนเทศ 