



บทที่ 4. การทำความสะอาดข้อมูล


- 4.1 การบูรณาการข้อมูล (Data Integration)
- 4.2 การประเมินคุณภาพข้อมูล (Data Assessment)
- 4.3 การปรับปรุงคุณภาพข้อมูล (Data Improvement)
- 4.4 การทำความเข้าใจข้อมูลด้วยสถิติเชิงพรรณนา



4.1 การบูรณาการข้อมูล (Data Integration)

การบูรณาการข้อมูล (Data Integration) คือ กระบวนการรวมข้อมูลจากหลายแหล่ง (Data Sources) เข้ามาเป็นชุดข้อมูลเดียวกัน ก่อนนำไป Cleansing ข้อมูล

Source —► Raw —► Staging —► Cleansing —► Presentation, Predictive —► Web, Mobile



ตัวอย่างการบูรณาการข้อมูล

1. สร้างฟังก์ชัน เชื่อมต่อฐานข้อมูล

```
1 from sqlalchemy import create_engine
2 from pymysql.constants import CLIENT
3
4 def get_mysql_engine(
5     DB_NAME,
6     DB_HOST = 'localhost',
7     DB_USER = 'root',
8     DB_PASSWORD = '1234',
9     DB_PORT = '3306',
10 ):
11
12     engine = create_engine(
13         f"mysql+pymysql://{DB_USER}:{DB_PASSWORD}@{DB_HOST}:{DB_PORT}/{DB_NAME}",
14         connect_args={"client_flag": CLIENT.MULTI_STATEMENTS}
15     )
16     return engine
17
18 engine = get_mysql_engine('')
```

✓ 0.0s

Python

2. สร้างตาราง customer ใน staging และ cleansing zone (ทำครั้งเดียว)

```
1 from sqlalchemy import text
2
3 sql = """
4 -- =====
5 -- STAGING ZONE
6 -- =====
7 CREATE DATABASE IF NOT EXISTS staging;
8 DROP TABLE IF EXISTS staging.customer;
9 CREATE TABLE staging.customer (
10     stg_id          INT AUTO_INCREMENT PRIMARY KEY,
11     custID          VARCHAR(10),
12     firstName       VARCHAR(100),
13     lastName        VARCHAR(100),
14     provinceName    VARCHAR(100),
15     zipcode         VARCHAR(10),
16     mobilePhone     VARCHAR(20),
17     birthdate       VARCHAR(20),
18     gender          VARCHAR(20),
19     email           VARCHAR(100),
20
21     source_system   VARCHAR(20), -- csv / mysql
22     load_date       DATETIME
23 );
24
```

```
25 -- =====
26 -- CLEANSING ZONE
27 -- =====
28 CREATE DATABASE IF NOT EXISTS clean;
29 DROP TABLE IF EXISTS clean.customer;
30 CREATE TABLE clean.customer (
31     custID          INT AUTO_INCREMENT PRIMARY KEY,
32     firstName       VARCHAR(100),
33     lastName        VARCHAR(100),
34     provinceName    VARCHAR(100),
35     zipcode         CHAR(5),
36     mobilePhone     CHAR(10),
37     birthdate       DATE,
38     gender          TINYINT,
39     email           VARCHAR(100),
40     load_date       DATETIME
41 );
42 """"
43
44 with engine.begin() as conn:
45 |     conn.execute(text(sql))
```

3. โหลดข้อมูลจาก MySQL (data source) ไปยัง MySQL (staging zone)

```
1 from sqlalchemy import text
2
3 sql = '''
4 TRUNCATE TABLE staging.customer;
5 INSERT INTO staging.customer (
6     custID, firstName, lastName, provinceName, zipcode,
7     mobilePhone, birthdate, gender, email, source_system, load_date
8 )
9 SELECT
10     a.custID,
11     a.firstName,
12     a.lastName,
13     d.provinceName,
14     a.zipcode,
15     a.mobilePhone,
16     a.birthdate,
17     a.gender,
18     a.email,
19     'mysql',
20     NOW()
21 FROM shopdee.customer a
22 INNER JOIN shopdee.subdistrict b ON a.subdistrictID = b.subdistrictID
23 INNER JOIN shopdee.district c ON b.districtID = c.districtID
24 INNER JOIN shopdee.province d ON c.provinceID = d.provinceID;
25 '''
26 with engine.begin() as conn:
27     conn.execute(text(sql))
```

4. โหลดข้อมูลจากไฟล์ csv (raw zone) ไปรวมใน MySQL (staging zone)

```
1 import pandas as pd
2 from datetime import datetime
3
4 engine = get_mysql_engine('staging')
5 df = pd.read_csv('data/warehouse_cust.csv')
6
7 df['source_system'] = 'csv'
8 df['load_date'] = datetime.now()
9
10 df = df.rename(columns={
11     'รหัส': 'custID',
12     'ชื่อ': 'firstName',
13     'นามสกุล': 'lastName',
14     'จังหวัด': 'provinceName',
15     'รหัสไปรษณีย์': 'zipcode',
16     'เบอร์มือถือ': 'mobilePhone',
17     'วันเกิด': 'birthdate',
18     'เพศ': 'gender',
19     'อีเมล': 'email'
20 })
21
22 df.to_sql(
23     con=engine,
24     schema='staging',
25     name='customer',
26     index=False,
27     if_exists='append'
28 )
```

5. แสดงข้อมูลที่มีการรวมเข้าด้วยกันแล้วใน MySQL (staging zone)

```
1 import pandas as pd
2 engine = get_mysql_engine('staging')
3 query = '''SELECT * FROM staging.customer'''
4 x = pd.read_sql(query, engine)
```

stg_id	custID	firstName	lastName	provinceName	zipcode	mobilePhone	birthdate	gender	email	source_system	load_date
1	1	ณเดช	ชัยเจริญ	กรุงเทพมหานคร	10800	0908786237	2000-08-12	0	nadech@gmail.com	mysql	2026-01-01 10:38:18
2	2	วิรัตน์	ใจเชื้อ	กรุงเทพมหานคร	None	0898763723	2001-06-02	0	wirath@hotmail.com	mysql	2026-01-01 10:38:18
3	3	วิภาดา	มิมมานท์	พระนครศรีอยุธยา	None	0862134496	1999-07-12	1	wipada@gmail.com	mysql	2026-01-01 10:38:18
4	4	วิชุดา	วิชเดช	พระนครศรีอยุธยา	None	0868927364	1987-01-24	1	wichuda@gmail.com	mysql	2026-01-01 10:38:18
5	5	สุดสัปดาห์	วิมารดร	พระนครศรีอยุธยา	None	0893524367	1985-07-25	1	sutsapda@hotmail.com	mysql	2026-01-01 10:38:18
6	6	สุทธิกมล	พรพิมาศ	ปทุมธานี	None	0896789076	2001-02-14	1	suthikamol@hotmail.com	mysql	2026-01-01 10:38:18
7	7	สุดเขต	พิสุธิสาร	ปทุมธานี	None	0897658261	2000-12-05	0	sutket@gmail.com	mysql	2026-01-01 10:38:18
8	8	พิเชษ	วิกราร	กรุงเทพมหานคร	None	0897622817	2002-11-07	0	phichet@gmail.com	mysql	2026-01-01 10:38:18
16	1001	สมชาย	ใจดี	กรุงเทพ	10230	08-1234-5678	12/3/1995	M	somchai.j@gmail.com	csv	2026-01-02 10:38:42
17	1002	สมหญิง	รักเรียน	ปทุม	12000	08-9876-5432	25/7/1998	F	somying.r@gmail.com	csv	2026-01-02 10:38:42
18	1003	พิมพ์ชนก	ศรีสุข	อยุธยา	13000	09-1234-5678	15/1/2000	F	test@test.com	csv	2026-01-02 10:38:42
19	1004	วรพล	แก้วทอง	ปทุม	12120	08-6543-2198	30/5/1996	M	woraphon.k@gmail	csv	2026-01-02 10:38:42
20	1005	สมศักดิ์	บุญช่วย	กรุงเทพฯ	10220	04-2345-6789	8/11/1992	M	somsak	csv	2026-01-02 10:38:42
21	1006	กนกวรรณ	นาคทอง	เชียงใหม่	10900	05-4567-8912	18/9/1994	หญิง	kanokwan.n@gmail.com	csv	2026-01-02 10:38:42
22	1007	ธนกฤต	มีสุข	Bangkok	10400	09-3456-7812	2/12/1991	ชาย	thanakrit.m@gmail.com	csv	2026-01-02 10:38:42
23	1008	ศิริพร	วัฒนชัย	อุดรธานี	41000	None	10/4/1999	หญิง	siriporn.w@gmail.com	csv	2026-01-02 10:38:42
24	1009	ปรีชา	คงมั่น	อยุธยา	13130	08-1987-6543	21/8/1989	ชาย	pricha.k@gmail.com	csv	2026-01-02 10:38:42
25	1010	นภัสสร	สุขใจ	สงขลา	90110	None	5/6/2001	หญิง	napatsorn.s@gmail.com	csv	2026-01-02 10:38:42
26	1011	วิภาดา	มิมมานท์	พระนครศรีอยุธยา	13130	08-6213-4496	12/7/1999	F	wipada@gmail.com	csv	2026-01-02 10:38:42
27	1012	วิชุดา	งามสุข	พระนครศรีอยุธยา	13260	08-6892-7364	24/1/1987	F	wichuda@gmail.com	csv	2026-01-02 10:38:42

4.2 การประเมินคุณภาพข้อมูล

การประเมินคุณภาพข้อมูล (Data Quality Assessment) คือ กระบวนการตรวจสอบและวิเคราะห์ลักษณะของข้อมูล ในมิติต่าง ๆ ของคุณภาพข้อมูล (เช่น ความครบถ้วน ความถูกต้อง) เพื่อระบุปัญหาที่ส่งผลต่อความน่าเชื่อถือของข้อมูล

องค์ประกอบของ คุณภาพข้อมูล :

- ความถูกต้องตามกฎหมาย (Validity)
- ความถูกต้องของข้อมูล (Accuracy)
- ความครบถ้วนของข้อมูล (Completeness)
- ความเป็นเอกลักษณ์ของข้อมูล (Uniqueness)
- ความสอดคล้องของข้อมูล (Consistency)
- ความเป็นปัจจุบันของข้อมูล (Timeliness)

4.2.1 ความถูกต้องตามกฎหมาย (Validity)

- ปัญหา
 - รูปแบบอีเมลไม่ถูกต้อง
 - เบอร์มือถือไม่ได้ขึ้นต้นด้วย 06, 08, และ 09
 - เบอร์มือถือ มีตัวเลขมากกว่า หรือ น้อยกว่า 10 ตัว
 - รหัสไปรษณีย์ มีตัวเลขมากกว่า หรือ น้อยกว่า 5 ตัว
 - ลูก้าลงวันเกิด ซึ่งเป็นวันที่ยังไม่ถึง เช่น 2027-12-30
 - อายุสูงผิดปกติ เช่น 140 ปี
- แนวทาง
 - กำหนดกฎ (Validation Rules) ของแต่ละฟิลด์ เช่น รูปแบบ (Format), ช่วงค่า (Range), ความยาวข้อมูล
 - บังคับใช้ Validation ตั้งแต่ขั้นตอนรับข้อมูล (เช่น Form, Database Constraint)
 - แทนค่าที่ไม่ถูกต้องด้วย NaN หรือ Invalid/Unknown เพื่อจัดการภายหลัง

โค้ดไพทอนสำหรับ ประเมินความถูกต้องตามกฎ

- ตรวจสอบรูปแบบอีเมล

```
1 email_pattern = r'^[A-Za-z0-9._%+-]+@[A-Za-z0-9.-]+\.[A-Za-z]{2,}$'
2
3 valid_email = x[
4     ~x['email'].fillna('').str.match(email_pattern)
5 ][['stg_id', 'email']]
6 valid_email
```

stg_id	email
19	woraphon.k@gmail
20	somsak

- ตรวจสอบเบอร์มือถือไม่ได้ขึ้นต้นด้วย 06, 08, และ 09

```
1 valid_mobile = x[
2     ~x['mobilePhone']
3     .str.replace('-', '', regex=False)
4     .str.match(r'^(06|08|09)\d{8}$', na=True)
5 ][['stg_id', 'mobilePhone']]
6 valid_mobile
```

stg_id	mobilePhone
--------	-------------

20	04-2345-6789
----	--------------

21	05-4567-8912
----	--------------

- รหัสไปรษณีย์ มีตัวเลขมากกว่า หรือ น้อยกว่า 5 ตัว (zipcode)

```
1 valid_zipcode = x[
2 | ~x['zipcode'].str.match(r'^\d{5}$', na=True)
3 ][['stg_id', 'zipcode']]
4 valid_zipcode
```

✓ 0.0s

stg_id zipcode

- ตรวจสอบลูก้าลงวันเกิด ซึ่งเป็นวันที่ยังไม่ถึง (birthdate)

```
1 x['birthdate_parsed'] = pd.to_datetime(x['birthdate'], errors='coerce')
2
3 valid_birthdate = x[
4 | (x['birthdate_parsed'] > pd.Timestamp.today())
5 ][['stg_id', 'birthdate']]
6 valid_birthdate
```

✓ 0.0s

stg_id birthdate

4.2.2 ความถูกต้องของข้อมูล (Accuracy)

- ปัญหา

- พิมพ์ชื่อผิด เช่น "สมศักดิ์" → "สมศักดิ์"
- มีช่องว่างหน้า-ท้าย หรือ ช่องว่างระหว่างตัวอักษร เช่น " สมชาย " → "สมชาย"
- Encoding ผิด (????) เช่น "à,à,£à,´à,□à,□à,²à,•à,£à,µ" → "ปริญญาตรี"
- มีข้อมูลจำลอง (Dummy) โดยที่ลูกค้าหรือพนักงานใส่ข้อมูลหลอกไว้เพื่อให้ผ่านฟอร์ม เช่น ชื่อ "AAA", เบอร์โทร "00000000" หรืออีเมล "test@test.com"

- แนวทาง

- ตรวจสอบความถูกต้องของข้อมูลกับแหล่งอ้างอิงที่เชื่อถือได้
- เปรียบเทียบข้อมูลระหว่างหลายแหล่ง (Cross-check)
- แยกหรือทำเครื่องหมาย Records ที่สงสัยว่าไม่ถูกต้อง เพื่อปรับปรุงหรือแก้ไขในภายหลัง

โค้ดไพทอนสำหรับ ประเมินความถูกต้องของข้อมูล

- การตัดช่องว่าง

```
1 accuracy_name = x[
2     ~ (
3         x['firstName'].fillna('').str.strip().eq(x['firstName']) &
4         x['lastName'].fillna('').str.strip().eq(x['lastName'])
5     )
6 ][['stg_id', 'firstName', 'lastName']]
7
8 accuracy_name
```

stg_id	firstName	lastName
16	สมชาย	ใจดี
25	นภัสสร	สุขใจ

- ค้นหาข้อมูลจำลอง

```
1 accuracy_email_test = x[
2     x['email'].str.contains('test', case=False, na=False)
3 ][['stg_id', 'email']]
4
5 accuracy_email_test
```

stg_id	email
--------	-------

18	test@test.com
----	---------------

4.2.3 ความครบถ้วนของข้อมูล (Completeness)

- ปัญหา
 - มีค่าว่างเปล่า (Missing Value) โดยเฉพาะในฟิลด์ที่ควรมีข้อมูล (Required Field) เช่น มีค่าว่างเปล่าในฟิลด์รหัสไปรษณีย์ เบอร์โทรศัพท์
- แนวทาง
 - กำหนด Mandatory (Required) Field เพื่อเป็นการป้องกัน
 - ตัด Records ที่ Field สำคัญมีค่าว่างเปล่า
 - เติมค่า NaN หรือ Unknown เพื่อนำไปจัดการภายหลัง เช่นการทำ Missing Value Imputation

โค้ดไพทอนสำหรับ ประเมินความครบถ้วนของข้อมูล

```
1 completeness = (  
2     x.isna()  
3     .sum()  
4     .to_frame(name='missing_count')  
5 )  
6  
7 completeness['missing_percent'] = completeness['missing_count'] / len(x) * 100  
8 completeness  
9  
10
```

	missing_count	missing_percent
stg_id	0	0.0
custID	0	0.0
firstName	0	0.0
lastName	0	0.0
provinceName	0	0.0
zipcode	7	35.0
mobilePhone	2	10.0
birthdate	0	0.0
gender	0	0.0
email	0	0.0
source_system	0	0.0
load_date	0	0.0

4.2.4 ความเป็นเอกลักษณ์ของข้อมูล (Uniqueness)

- ปัญหา
 - รหัสลูกค้าซ้ำ
 - อีเมลซ้ำ
 - เบอร์มือถือซ้ำ
 - วันเกิด ซ้ำ
 - ชื่อ + นามสกุล + อีเมลซ้ำ
- แนวทาง
 - กำหนด Primary Key หรือ Unique Key เพื่อป้องกันข้อมูลซ้ำตั้งแต่ระดับฐานข้อมูล
 - ตรวจสอบและระบุข้อมูลซ้ำด้วยกฎหรือเงื่อนไขที่ชัดเจน (Exact / Fuzzy Matching)
 - รวม (Merge) หรือเลือก Records ที่ถูกต้องที่สุดไว้เพียงหนึ่งรายการ
 - จัดเก็บข้อมูลที่ซ้ำซ้อนแยกไว้ในตาราง หรือ ทำเครื่องหมายไว้ เพื่อใช้ตรวจสอบและปรับปรุงคุณภาพข้อมูล

โค้ดไพทอนสำหรับ ประเมินความเป็นเอกลักษณ์ของข้อมูล

- ตรวจสอบรหัสลูกค้าซ้ำ (custID)

```
1 uniqueness_custid = x[
2     x.duplicated('custID', keep=False)
3     ][['stg_id', 'firstName', 'lastName', 'email']]
4 uniqueness_custid
```

0.0s

stg_id	firstName	lastName	email
--------	-----------	----------	-------

- ตรวจสอบบุคคลซ้ำ (firstName + lastName + email)

```
1 uniqueness_person = x[
2     x.duplicated(
3         ['firstName', 'lastName', 'email'],
4         keep=False
5     )
6 ][['stg_id', 'firstName', 'lastName', 'email']]
7 uniqueness_person
```

stg_id	firstName	lastName	email
3	วิภาดา	มีมมานท์	wipada@gmail.com
26	วิภาดา	มีมมานท์	wipada@gmail.com

4.2.5 ความสอดคล้องของข้อมูล (Consistency)

- ปัญหา
 - คำนำหน้าชื่อเป็น "นาย" แต่ระบุเพศเป็น "หญิง"
 - เพศ = ชาย / ช / M / Male
 - จังหวัด = “กรุงเทพ” / “กรุงเทพมหานคร” / “กรุงเทพฯ”
 - รหัสไปรษณีย์ 10900 (จตุจักร) แต่ระบุจังหวัดเป็น "เชียงใหม่"
 - ระบุว่าอายุ 20 ปี แต่คำนวณจากวันเกิดได้ 40 ปี
 - อายุ 5 ขวบ แต่สมัครบัตรเครดิต
- แนวทาง
 - กำหนดรูปแบบมาตรฐาน
 - กำหนด Business Rule หรือ Logic ที่ชัดเจน
 - ทำเครื่องหมาย Records ที่ไม่สอดคล้อง เพื่อปรับปรุงคุณภาพข้อมูล

โค้ดไพทอนสำหรับ ประเมินความสอดคล้องของข้อมูล

- ตรวจสอบรูปแบบการเก็บข้อมูลเพศ (Gender)

```
1 consistency_gender = x[['gender']].value_counts()  
2 consistency_gender
```

✓ 0.0s

gender

0	4
1	4
F	4
M	3
หญิง	3
ชาย	2

- ตรวจสอบรูปแบบการเก็บข้อมูลจังหวัด (provinceName)

```
1 #ดูรายชื่อจังหวัดทั้งหมด แล้วเรียงชื่อจังหวัดเพื่อชื่อที่คล้าย ๆ กัน อยู่ติดกัน
2 x['provinceName'].str.strip().str.lower().value_counts().sort_index()
```

✓ 0.0s

provinceName	
bangkok	1
กรุงเทพ	1
กรุงเทพมหานคร	3
กรุงเทพฯ	1
ปทุม	2
ปทุมธานี	2
พระนครศรีอยุธยา	5
สงขลา	1
อยุธยา	2
อุดรธานี	1
เชียงใหม่	1

```
1  #ดูรายชื่อจังหวัดกรุงเทพมหานคร
2  x[
3      x['provinceName']
4      .str.strip()
5      .str.lower()
6      .str.contains(r'กรุงเทพ|angkok', na=False)
7  ]['provinceName'].unique()
```

✓ 0.0s

```
array(['กรุงเทพมหานคร', 'กรุงเทพ', 'กรุงเทพฯ', 'Bangkok'], dtype=object)
```

```
1 #ดูรายชื่อจังหวัดพระนครศรีอยุธยา
2 x[x['provinceName'].str.contains('อยุธยา', na=False)]['provinceName'].unique()
3
```

✓ 0.0s

```
array(['พระนครศรีอยุธยา', 'อยุธยา'], dtype=object)
```

```
1 #ดูรายชื่อจังหวัดปทุมธานี
2 x[x['provinceName'].str.contains('ปทุม', na=False)]['provinceName'].unique()
3
```

✓ 0.0s

```
array(['ปทุมธานี', 'ปทุม'], dtype=object)
```

```

1 #Mapping รายชื่อจังหวัด
2 x['province_normalized'] = (
3     x['provinceName']
4     .str.strip()
5     .str.lower()
6     .replace({
7         'กรุงเทพฯ': 'กรุงเทพมหานคร',
8         'กรุงเทพ': 'กรุงเทพมหานคร',
9         'bangkok': 'กรุงเทพมหานคร',
10        'อยุธยา': 'พระนครศรีอยุธยา',
11        'ปทุม': 'ปทุมธานี'
12    })
13 )
14
15 x_diff = x[x['provinceName'] != x['province_normalized']]
16
17 consistency_province_diff = (
18     x_diff
19     .groupby(['provinceName', 'province_normalized'])
20     .size()
21     .reset_index(name='count')
22 )
23 consistency_province_diff

```

provinceName	province_normalized	count
Bangkok	กรุงเทพมหานคร	1
กรุงเทพ	กรุงเทพมหานคร	1
กรุงเทพฯ	กรุงเทพมหานคร	1
ปทุม	ปทุมธานี	2
อยุธยา	พระนครศรีอยุธยา	2

4.2.6 ความเป็นปัจจุบันของข้อมูล (Timeliness)

- ปัญหา
 - เปลี่ยนชื่อ-นามสกุล
 - เปลี่ยนเบอร์โทร
 - เปลี่ยนที่อยู่
 - ยกเลิกการใช้อีเมล หรือ อีเมลเต็มทำให้ส่งอีเมลไม่ได้
- แนวทาง
 - ใช้ข้อมูลจากแหล่งที่มีการอัปเดตล่าสุด
 - มีกระบวนการตรวจสอบและอัปเดตข้อมูลอยู่เรื่อย ๆ
 - ทำเครื่องหมาย Records ที่ไม่เป็นปัจจุบัน เพื่อปรับปรุงคุณภาพข้อมูล

โค้ดไพทอนสำหรับ ประเมินความเป็นปัจจุบันของข้อมูล

- ตรวจสอบความเป็นปัจจุบันของข้อมูลทางอ้อม ผ่าน load_date

```
1 x['data_age_days'] = (pd.Timestamp.now() - x['load_date']).dt.days
2
3 timeliness_summary = {
4     'min_age_days': x['data_age_days'].min(),
5     'max_age_days': x['data_age_days'].max(),
6     'avg_age_days': x['data_age_days'].mean()
7 }
8 timeliness_summary
9
```

✓ 0.0s

```
{'min_age_days': np.int64(5),
 'max_age_days': np.int64(6),
 'avg_age_days': np.float64(5.4)}
```

ตัวอย่าง การคำนวณความครบถ้วนของข้อมูล (%)

แถวที่	Field 1	Field 2	Field 3	Field 4	Field 5	Field 6	Field 7	Field 8	Field 9	Field 10
1	x	x	x	x	x	x	x	x	x	x
2	x	x	x	x	x	x	x	x	x	x
3	x	x	x	x	x	x	x	x	x	x
4	x	x	x	x	x	x	x	x	x	x
5	x	x	x	x	x	x	x	x	x	x
6	x	x	x	x	x	x	x	x	x	x
7	x	x	x	x	x	x	x	x	x	x
8	x	x	x							
9	x	x	x	x	x	x	x	x	x	x
10	x	x	x	x	x	x	x	x	x	x
11	x	x	x		x	x	x	x	x	x
12	x	x	x		x	x	x	x	x	x
13	x	x	x		x	x	x	x	x	x
14		x	x		x	x	x	x	x	x
15		x	x		x	x	x	x	x	x
16		x	x		x	x	x	x	x	x
17		x	x	x	x	x	x	x	x	x
18		x	x	x	x	x	x	x	x	x
19		x	x	x	x	x	x	x	x	x
20		x	x	x	x	x	x	x	x	x

ความครบถ้วน (แบบเซลล์) = (จำนวนเซลล์ข้อมูลทั้งหมด – จำนวนเซลล์ข้อมูลที่ขาด) /
จำนวนเซลล์ข้อมูลทั้งหมด) * 100
= (200 – 20) / 200) * 100 = 90%

ความครบถ้วน (แบบคอลัมน์) = (จำนวนคอลัมน์ทั้งหมด – จำนวนคอลัมน์ที่ขาด) /
จำนวนคอลัมน์ทั้งหมด) * 100
= (10 – 8) / 10) * 100 = 20%

ความครบถ้วน (แบบแถว) = (จำนวนแถวทั้งหมด – จำนวนแถวที่ขาด) /
จำนวนแถวทั้งหมด) * 100
= (20 – 11) / 20) * 100 = 45%

4.3 การปรับปรุงคุณภาพข้อมูล (Data Improvement)

การปรับปรุงคุณภาพข้อมูล (Data Quality Improvement) คือ กระบวนการแก้ไขข้อมูล เพื่อให้ข้อมูลมีความถูกต้อง ครบถ้วน สอดคล้อง และเหมาะสมต่อการนำไปประมวลผล วิเคราะห์ หรือใช้งานในขั้นตอนถัดไป

องค์ประกอบของ การปรับปรุงคุณภาพข้อมูล :

- ความถูกต้องตามกฎ (Validity)
- ความถูกต้องของข้อมูล (Accuracy)
- ความครบถ้วนของข้อมูล (Completeness)
- ความเป็นเอกลักษณ์ของข้อมูล (Uniqueness)
- ความสอดคล้องของข้อมูล (Consistency)
- ความเป็นปัจจุบันของข้อมูล (Timeliness)

โค้ดไพทอนสำหรับ การปรับปรุงคุณภาพข้อมูล [ความถูกต้องตามกฎหมาย]

```
1 x.loc[11, 'email'] = 'woraphon.k@gmail.com'
2 x.loc[12, 'email'] = 'somsak@gmail.com'
3 x[['stg_id', 'email']][11:13]
4
```

✓ 0.0s

stg_id		email
11	19	woraphon.k@gmail.com
12	20	somsak@gmail.com

4.4 การทำความเข้าใจข้อมูลด้วยสถิติเชิงพรรณนา

การทำความเข้าใจข้อมูลด้วยสถิติเชิงพรรณนา คือ กระบวนการใช้สถิติเชิงพรรณนา (Descriptive Statistics) เพื่อสรุป อธิบาย และนำเสนอข้อมูลที่มีอยู่ โดยมุ่งเน้นการอธิบายลักษณะของข้อมูลเชิงตัวเลข

องค์ประกอบของ สถิติเชิงพรรณนา :

- การวัดแนวโน้มเข้าสู่ส่วนกลาง (Measures of Central Tendency)
- การวัดการกระจายของข้อมูล (Measures of Dispersion)
- การวัดตำแหน่งของข้อมูล (Measures of Position)
- การวัดรูปร่างของการแจกแจงข้อมูล (Measures of Shape)

4.4.1 การวัดแนวโน้มเข้าสู่ส่วนกลาง

การวัดแนวโน้มเข้าสู่ส่วนกลาง (Measures of Central Tendency) ใช้บอกว่า “ค่ากลาง” ของข้อมูลอยู่ตรงไหน

- ค่าเฉลี่ย (Mean)
 - ผลรวมของข้อมูล ÷ จำนวนข้อมูล
 - เหมาะกับข้อมูลที่ไม่มีค่าผิดปกติ (outlier)
- มัธยฐาน (Median)
 - ค่าที่อยู่ตรงกลางเมื่อเรียงข้อมูล
 - เหมาะกับข้อมูลที่มี outlier
- ฐานนิยม (Mode)
 - ค่าที่พบมากที่สุด
 - ใช้ได้กับข้อมูลเชิงคุณภาพ (categorical)

4.4.1.1 ค่าเฉลี่ย

สูตรการหาค่าเฉลี่ย

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

เมื่อ

$\bar{x}$ = ค่าเฉลี่ยของกลุ่มตัวอย่าง (Samples)

x_i = ค่าของข้อมูลตัวที่ i

n = จำนวนข้อมูลทั้งหมด

หรือ

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

เมื่อ

μ = ค่าเฉลี่ยของประชากร (Population)

x_i = ค่าของข้อมูลตัวที่ i

n = จำนวนข้อมูลทั้งหมด

ตัวอย่างการคำนวณ ค่าเฉลี่ย

จากข้อมูลต่อไปนี้ จงหา ค่าเฉลี่ยของกลุ่มตัวอย่าง

$$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$$

วิธีทำ

จาก $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ จะได้

$$\bar{x} = \frac{1}{9} (25 + 27 + 23 + 41 + 32 + 26 + 22 + 28 + 34)$$

$$\bar{x} = \frac{1}{9} (258) = 28.67$$

ตอบ ค่าเฉลี่ยของกลุ่มตัวอย่าง คือ **28.67** ปี

โค้ดไพทอนสำหรับ ค่าเฉลี่ย

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print(f'ค่าเฉลี่ยของอายุ คือ {x['age'].mean():.2f} ปี')
7
8 #numpy
9 print(f'ค่าเฉลี่ยของอายุ คือ {np.mean(x['age']):.2f} ปี')
```

✓ 0.0s

ค่าเฉลี่ยของอายุ คือ 28.67 ปี

ค่าเฉลี่ยของอายุ คือ 28.67 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.1.2 มัธยฐาน

สูตรการหามัธยฐาน

$$\text{Median} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{if } n \text{ is odd} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{if } n \text{ is even} \end{cases}$$

เมื่อ

n = จำนวนข้อมูลทั้งหมด

ตัวอย่างการคำนวณ มัธยฐาน

จากข้อมูลต่อไปนี้ จงหา มัธยฐาน

$$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$$

วิธีทำ

- ทำการเรียงข้อมูล ได้ดังนี้

$$x = \{22, 23, 25, 26, 27, 28, 32, 34, 41\}$$

- หาตำแหน่งของ **มัธยฐาน** จากสูตร $(n+1) / 2$ ได้ดังนี้

$$\frac{9 + 1}{2} = 5$$

- หา **มัธยฐาน** ได้จาก ค่าในตำแหน่งที่ 5 นั่นคือ **27**

ตอบ มัธยฐาน คือ **27** ปี

โค้ดไพทอนสำหรับ มัธยฐาน

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print(f'มัธยฐานของอายุ คือ {x['age'].median():.2f} ปี')
7
8 #numpy
9 print(f'มัธยฐานของอายุ คือ {np.nanmedian(x['age']):.2f} ปี')
```

✓ 0.0s

มัธยฐานของอายุ คือ 27.00 ปี

มัธยฐานของอายุ คือ 27.00 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.1.3 ฐานนิยม

สูตรหาฐานนิยม

$Mode =$ ค่าที่มีความถี่สูงสุด หรือ ค่าที่เกิดขึ้นซ้ำกันมากที่สุด

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงหา ค่าฐานนิยม

$x =$ ['ปริญาตรี', 'ปริญาโท', 'ปริญาตรี', 'ปริญาเอก', 'ปริญาโท', 'ปริญาตรี', 'ปริญาโท', 'ปริญาตรี', 'ปริญาตรี']

วิธีทำ

หาความถี่ (ค่าที่ซ้ำกัน) ของแต่ละกลุ่มข้อมูล ได้ดังนี้

ปริญาตรี = 5

ปริญาโท = 3

ปริญาเอก = 1

พบว่า **ปริญาตรี** มีความถี่สูงที่สุด

ตอบ ฐานนิยม คือ **ปริญาตรี**

โค้ดไพทอนสำหรับ ฐานนิยม

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print(f'ฐานนิยมของระดับการศึกษา คือ {x.education_level.mode()[0]}')
7
8 #numpy
9 edu = x["education_level"].dropna().to_numpy()
10 values, counts = np.unique(edu, return_counts=True)
11 mode_edu = values[np.argmax(counts)]
12 print(f'ฐานนิยมของระดับการศึกษา คือ {mode_edu}')
```

✓ 0.0s

ฐานนิยมของระดับการศึกษา คือ ปริญญาตรี

ฐานนิยมของระดับการศึกษา คือ ปริญญาตรี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.2 การวัดการกระจายของข้อมูล

การวัดการกระจายของข้อมูล (Measures of Dispersion) ใช้บอกว่าข้อมูล กระจายตัวมากน้อยเพียงใด

- พิสัย (Range)
 - ค่าสูงสุด – ค่าต่ำสุด
- ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)
 - วัดความแตกต่างของข้อมูลจากค่าเฉลี่ย
 - ยิ่งค่าสูง → ข้อมูลยิ่งกระจายมาก
- ความแปรปรวน (Variance)
 - กำลังสองของส่วนเบี่ยงเบนมาตรฐาน
- Interquartile Range (IQR)
 - $Q_3 - Q_1$
 - ใช้ร่วมกับ Boxplot เพื่อดู Outlier

4.4.2.1 พิสัย

สูตรการหาพิสัย

$$Range = Max - Min$$

เมื่อ

$$Range = \text{พิสัย}$$

$$Max = \text{ค่าสูงสุด}$$

$$Min = \text{ค่าต่ำสุด}$$

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงหา พิสัย

$$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$$

วิธีทำ จาก $Range = Max - Min$

$$\text{จะได้ } Max = 41, Min = 22$$

$$Range = 41 - 22 = 19$$

ตอบ พิสัย คือ **19** ปี

โค้ดไพทอนสำหรับ พิสัย

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 age_range_pd = x['age'].max() - x['age'].min()
7 print(f'พิสัยของอายุ คือ {age_range_pd:.2f} ปี')
8
9 #numpy
10 age_range_np = np.nanmax(x['age']) - np.nanmin(x['age'])
11 print(f'พิสัยของอายุ คือ {age_range_np:.2f} ปี')
```

✓ 0.0s

พิสัยของอายุ คือ 19.00 ปี

พิสัยของอายุ คือ 19.00 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.2.2 ส่วนเบี่ยงเบนมาตรฐาน

สูตรการหาส่วนเบี่ยงเบนมาตรฐาน

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{หรือ}$$

เมื่อ

s = ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

$\bar{x}$ = ค่าเฉลี่ยของกลุ่มตัวอย่าง (Samples)

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

เมื่อ

σ = ส่วนเบี่ยงเบนมาตรฐานของประชากร

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

μ = ค่าเฉลี่ยของประชากร (Population)

ตัวอย่างการคำนวณ ส่วนเบี่ยงเบนมาตรฐาน

จากข้อมูลต่อไปนี้ จงหา ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง

$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$ กำหนดให้ $\bar{x} = 28.67$

วิธีทำ

จาก $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$ จะได้ $\frac{1}{n-1} = \frac{1}{9-1} = \frac{1}{8}$

$$\sum_{i=1}^9 (x_i - \bar{x})^2 = (25 - 28.67)^2 + (27 - 28.67)^2 + (23 - 28.67)^2 + (41 - 28.67)^2 + (32 - 28.67)^2 + (26 - 28.67)^2 + (22 - 28.67)^2 + (28 - 28.67)^2 + (34 - 28.67)^2$$

$$s = \sqrt{\frac{1}{8} (292)} = 6.04$$

ตอบ ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง คือ **6.04** ปี

โค้ดไพทอนสำหรับ ส่วนเบี่ยงเบนมาตรฐาน

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 std_s = x['age'].std() #ddof=1
8 std_p = x['age'].std(ddof=0)
9 print(f'ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง (อายุ) คือ {std_s:.2f} ปี')
10 print(f'ส่วนเบี่ยงเบนมาตรฐานของประชากร (อายุ) คือ {std_p:.2f} ปี\n')
11
12 #numpy
13 print('-----Numpy-----')
14 std_s = np.std(x['age'], ddof=1)
15 std_p = np.std(x['age']) #ddof=0
16 print(f'ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง (อายุ) คือ {std_s:.2f} ปี')
17 print(f'ส่วนเบี่ยงเบนมาตรฐานของประชากร (อายุ) คือ {std_p:.2f} ปี')
```

✓ 0.0s

-----Pandas-----

ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง (อายุ) คือ 6.04 ปี

ส่วนเบี่ยงเบนมาตรฐานของประชากร (อายุ) คือ 5.70 ปี

-----Numpy-----

ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง (อายุ) คือ 6.04 ปี

ส่วนเบี่ยงเบนมาตรฐานของประชากร (อายุ) คือ 5.70 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.2.3 ความแปรปรวน

สูตรการหาความแปรปรวน

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{หรือ}$$

เมื่อ

s^2 = ความแปรปรวนของกลุ่มตัวอย่าง (Samples)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

$\bar{x}$ = ค่าเฉลี่ยของกลุ่มตัวอย่าง

$$\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

เมื่อ

σ^2 = ความแปรปรวนของประชากร (Population)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

μ = ค่าเฉลี่ยของประชากร

ตัวอย่างการคำนวณ ความแปรปรวน

จากข้อมูลต่อไปนี้ จงหา ความแปรปรวนของกลุ่มตัวอย่าง

$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$ กำหนดให้ $\bar{x} = 28.67$

วิธีทำ

จาก $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ จะได้ $\frac{1}{n-1} = \frac{1}{9-1} = \frac{1}{8}$

$$\sum_{i=1}^9 (x_i - \bar{x})^2 = (25 - 28.67)^2 + (27 - 28.67)^2 + (23 - 28.67)^2 + (41 - 28.67)^2 + (32 - 28.67)^2 + (26 - 28.67)^2 + (22 - 28.67)^2 + (28 - 28.67)^2 + (34 - 28.67)^2$$

$$s^2 = \frac{1}{8} (292) = 36.5$$

ตอบ ความแปรปรวนของกลุ่มตัวอย่าง คือ **36.5**

โค้ดไพทอนสำหรับ ความแปรปรวน

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 var_s = x['age'].var() #ddof=1
8 var_p = x['age'].var(ddof=0)
9 print(f'ความแปรปรวนของกลุ่มตัวอย่าง (อายุ) คือ {var_s:.2f}')
10 print(f'ความแปรปรวนของประชากร (อายุ) คือ {var_p:.2f}\n')
11
12 #numpy
13 print('-----Numpy-----')
14 var_s = np.var(x['age'], ddof=1)
15 var_p = np.var(x['age']) #ddof=0
16 print(f'ความแปรปรวนของของกลุ่มตัวอย่าง (อายุ) คือ {var_s:.2f}')
17 print(f'ความแปรปรวนของประชากร (อายุ) คือ {var_p:.2f}')
```

✓ 0.0s

-----Pandas-----

ความแปรปรวนของกลุ่มตัวอย่าง (อายุ) คือ 36.50

ความแปรปรวนของประชากร (อายุ) คือ 32.44

-----Numpy-----

ความแปรปรวนของของกลุ่มตัวอย่าง (อายุ) คือ 36.50

ความแปรปรวนของประชากร (อายุ) คือ 32.44

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.2.4 IQR

สูตรการหาความแปรปรวน

$$IQR = Q_3 - Q_1$$

$$Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)}), \quad p = \{0.25, 0.5, 0.75\}$$

$$k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots \quad \text{บางทฤษฎีคำนวณค่า } k \text{ จากสมการ} \quad k = \lfloor p(n+1) \rfloor, k = 1, 2, 3, \dots$$

$$h = \{p(n-1)\}$$

เมื่อ

IQR = Interquartile Range (IQR)

Q_p = ค่าควอร์ไทล์ ในสัดส่วน percentile นั่นคือ $Q_1 = Q_{0.25}$, $Q_2 = Q_{0.5}$, $Q_3 = Q_{0.75}$

$x_{(k)}$ = ค่าของข้อมูลลำดับที่ k

$x_{(k+1)}$ = ค่าของข้อมูลลำดับที่ $k+1$

h = ตัวเลขหลังจุดทศนิยม (Fractional Part) จากการคำนวณ $p(n-1)$

ตัวอย่างการคำนวณ IQR

จากข้อมูลต่อไปนี้ จงหา IQR

$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$

วิธีทำ

1. เรียงข้อมูลจากน้อยไปหามาก ได้ดังนี้

$x_{\text{sort}} = [22, 23, 25, 26, 27, 28, 32, 34, 41]$

2. คำนวณ Q_1 และ Q_3 ดังนี้

คำนวณ Q_1 (25 percentile)

จาก $Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)})$ และ $k = \lfloor p(n - 1) \rfloor, k = 0, 1, 2, \dots$

จะได้ $p = 0.25$

$$p(n - 1) = 0.25(9 - 1) = 2.0$$

$k = 2$ เมื่อ k เริ่มต้นที่ 0

$$h = 0$$

$$x_{(k)} = 25$$

$$x_{(k+1)} = 26$$

$$Q_1 = 25 + (0)(26 - 25)$$

$$Q_1 = 25 + 0 = 25$$

คำนวณ Q_3 (75 percentile)

จาก $Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)})$ และ $k = \lfloor p(n - 1) \rfloor, k = 0, 1, 2, \dots$

จะได้ $p = 0.75$

$$p(n - 1) = 0.75(9 - 1) = 6.0$$

$k = 6$ เมื่อ k เริ่มต้นที่ 0

$$h = 0.75$$

$$x_{(k)} = 32$$

$$x_{(k+1)} = 34$$

$$Q_3 = 32 + (0)(34 - 32)$$

$$Q_3 = 32 + 0 = 32$$

3. คำนวณ IQR ดังนี้

$$\text{IQR} = 32 - 25 = 7$$

ตอบ IQR คือ 7 ปี

โค้ดไพทอนสำหรับ IQR

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 q1 = x['age'].quantile(0.25)
7 q3 = x['age'].quantile(0.75)
8 iqr = q3 - q1
9 print(f'IQR ของอายุ คือ {iqr:.2f} ปี')
10
11 #numpy
12 q1 = np.nanquantile(x['age'], 0.25)
13 q3 = np.nanquantile(x['age'], 0.75)
14 iqr = q3 - q1
15 print(f'IQR ของอายุ คือ {iqr:.2f} ปี')
16
```

✓ 0.0s

IQR ของอายุ คือ 7.00 ปี

IQR ของอายุ คือ 7.00 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.3 การวัดตำแหน่งของข้อมูล

การวัดตำแหน่งของข้อมูล (Measures of Position) ใช้ระบุตำแหน่งของข้อมูลในชุดข้อมูล

- ควอร์ไทล์ (Quartile)
 - คือการแบ่งข้อมูลออกเป็น 4 ส่วนเท่าๆ กัน โดยมี 3 จุดตัดที่เรียกว่า Q1, Q2 และ Q3
- เดไซล์ (Decile)
 - คือ การแบ่งข้อมูลออกเป็น 10 ส่วนเท่าๆ กัน โดยมี 9 จุดตัดที่เรียกว่า D1, D2, ..., D9
- เพอร์เซ็นไทล์ (Percentile)
 - คือ การแบ่งข้อมูลออกเป็น 100 ส่วนเท่า ๆ กัน โดยมี 99 จุดตัด ตั้งแต่ P1, P2, ..., P99

4.4.3.1 ควอร์ไทล์

สูตรการหา ควอร์ไทล์

$$Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)}), \quad p = \{0.25, 0.5, 0.75\}$$

$$k = \lfloor p(n - 1) \rfloor, k = 0, 1, 2, \dots \quad \text{บางทฤษฎีคำนวณค่า } k \text{ จากสมการ} \quad k = \lfloor p(n + 1) \rfloor, k = 1, 2, 3, \dots$$

$$h = \{p(n - 1)\}$$

เมื่อ

Q_p = ค่าควอร์ไทล์ ในสัดส่วน percentile นั่นคือ $Q_1 = Q_{0.25}$, $Q_2 = Q_{0.5}$, $Q_3 = Q_{0.75}$

$x_{(k)}$ = ค่าของข้อมูลลำดับที่ k

$x_{(k+1)}$ = ค่าของข้อมูลลำดับที่ $k+1$

h = ตัวเลขหลังจุดทศนิยม (Fractional Part) จากการคำนวณ $p(n-1)$

โค้ดไพทอนสำหรับ คิวอร์ไทล์

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 q1 = x['age'].quantile(0.25)
8 q3 = x['age'].quantile(0.75)
9 print(f'Q1 ของอายุ คือ {q1:.2f} ปี')
10 print(f'Q3 ของอายุ คือ {q3:.2f} ปี\n')
11
12 #numpy
13 print('-----Numpy-----')
14 q1 = np.nanquantile(x['age'], 0.25)
15 q3 = np.nanquantile(x['age'], 0.75)
16 print(f'Q1 ของอายุ คือ {q1:.2f} ปี')
17 print(f'Q3 ของอายุ คือ {q3:.2f} ปี')
18
```

✓ 0.0s

-----Pandas-----

Q1 ของอายุ คือ 25.00 ปี

Q3 ของอายุ คือ 32.00 ปี

-----Numpy-----

Q1 ของอายุ คือ 25.00 ปี

Q3 ของอายุ คือ 32.00 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.3.2 เดไซล์

สูตรการหา เดไซล์

$$D_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)}), \quad p = \{0.1, 0.2, 0.3, \dots, 0.9\}$$

$$k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots \quad \text{บางทฤษฎีคำนวณค่า } k \text{ จากสมการ} \quad k = \lfloor p(n+1) \rfloor, k = 1, 2, 3, \dots$$

$$h = \{p(n-1)\}$$

เมื่อ

D_p = ค่าเดไซล์ ในสัดส่วน percentile นั่นคือ $D_1 = Q_{0.1}, D_2 = Q_{0.2}, \dots, D_9 = Q_{0.9}$

$x_{(k)}$ = ค่าของข้อมูลลำดับที่ k

$x_{(k+1)}$ = ค่าของข้อมูลลำดับที่ $k+1$

h = ตัวเลขหลังจุดทศนิยม (Fractional Part) จากการคำนวณ $p(n-1)$

โค้ดไพทอนสำหรับ เดไซน์

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 d3 = x['age'].quantile(0.3)
8 d7 = x['age'].quantile(0.7)
9 print(f'D3 ของอายุ คือ {d3:.2f} ปี')
10 print(f'D7 ของอายุ คือ {d7:.2f} ปี\n')
11
12 #numpy
13 print('-----Numpy-----')
14 d3 = np.nanquantile(x['age'], 0.3)
15 d7 = np.nanquantile(x['age'], 0.7)
16 print(f'D3 ของอายุ คือ {d3:.2f} ปี')
17 print(f'D7 ของอายุ คือ {d7:.2f} ปี')
18
```

✓ 0.0s

-----Pandas-----

D3 ของอายุ คือ 25.40 ปี

D7 ของอายุ คือ 30.40 ปี

-----Numpy-----

D3 ของอายุ คือ 25.40 ปี

D7 ของอายุ คือ 30.40 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.3.3 เปอร์เซ็นไทล์

สูตรการหา เปอร์เซ็นไทล์

$$P_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)}), \quad p = \{0.01, 0.02, 0.03, \dots, 0.99\}$$

$$k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots \quad \text{บางทฤษฎีคำนวณค่า } k \text{ จากสมการ} \quad k = \lfloor p(n+1) \rfloor, k = 1, 2, 3, \dots$$

$$h = \{p(n-1)\}$$

เมื่อ

P_p = ค่าเปอร์เซ็นไทล์ ในสัดส่วน percentile นั่นคือ $P_1 = P_{0.01}$, $P_2 = P_{0.02}$, ..., $P_{99} = P_{0.99}$

$x_{(k)}$ = ค่าของข้อมูลลำดับที่ k

$x_{(k+1)}$ = ค่าของข้อมูลลำดับที่ $k+1$

h = ตัวเลขหลังจุดทศนิยม (Fractional Part) จากการคำนวณ $p(n-1)$

โค้ดไพทอนสำหรับ เปอร์เซ็นไทล์

```
1 import pandas as pd
2 import numpy as np
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 p25 = x['age'].quantile(0.25)
8 p75 = x['age'].quantile(0.75)
9 print(f'P25 ของอายุ คือ {p25:.2f} ปี')
10 print(f'P75 ของอายุ คือ {p75:.2f} ปี\n')
11
12 #numpy
13 print('-----Numpy-----')
14 p25 = np.nanquantile(x['age'], 0.25)
15 p75 = np.nanquantile(x['age'], 0.75)
16 print(f'P25 ของอายุ คือ {p25:.2f} ปี')
17 print(f'P75 ของอายุ คือ {p75:.2f} ปี')
18
```

✓ 0.0s

-----Pandas-----

P25 ของอายุ คือ 25.00 ปี

P75 ของอายุ คือ 32.00 ปี

-----Numpy-----

P25 ของอายุ คือ 25.00 ปี

P75 ของอายุ คือ 32.00 ปี

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.4 การวัดรูปร่างของการแจกแจงข้อมูล

การวัดรูปร่างของการแจกแจงข้อมูล (Measures of Shape) คือ สถิติที่ใช้เพื่ออธิบาย ลักษณะรูปทรงของการกระจายตัวของข้อมูล ว่ามีความสมมาตร หรือ เบ้ไปทางใด และมีความ โด่งหรือแบน มากน้อยเพียงใด เมื่อเปรียบเทียบกับ การแจกแจงแบบปกติ (Normal Distribution)

- ความเบ้ (Skewness)
 - เบ้ขวา (Positive Skew)
 - เบ้ซ้าย (Negative Skew)
- ความโด่ง (Kurtosis)
 - โด่ง (Leptokurtic)
 - แบน (Platykurtic)

4.4.4.1 ความเบ้

สูตรการหา ความเบ้

$$G_1 = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3 \quad \text{หรือ} \quad \gamma_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^3$$

เมื่อ

G_1 = ความเบ้ของกลุ่มตัวอย่าง (Samples)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

$\bar{x}$ = ค่าเฉลี่ยของกลุ่มตัวอย่าง

s = ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง

เมื่อ

γ_1 = ความเบ้ของประชากร (Population)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

μ = ค่าเฉลี่ยของประชากร

σ = ส่วนเบี่ยงเบนมาตรฐานของประชากร

ตัวอย่างการคำนวณ ความเบ้

จากข้อมูลต่อไปนี้ จงหา ความเบ้ของกลุ่มตัวอย่าง

$$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$$

$$\text{กำหนดให้ } n = 9, \quad \bar{x} = 28.667, \quad s = 6.042$$

วิธีทำ

$$\text{จาก } G_1 = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3 \quad \text{จะได้} \quad \frac{n}{(n-1)(n-2)} = \frac{9}{(8)(7)} = 0.161$$

$$G_1 = 0.161 \sum_{i=1}^n \left(\frac{x_i - 28.667}{6.042} \right)^3$$

$$G_1 = 0.161 \left[\left(\frac{25 - 28.667}{6.042} \right)^3 + \left(\frac{27 - 28.667}{6.042} \right)^3 + \left(\frac{23 - 28.667}{6.042} \right)^3 + \left(\frac{41 - 28.667}{6.042} \right)^3 + \left(\frac{32 - 28.667}{6.042} \right)^3 + \right. \\ \left. \left(\frac{26 - 28.667}{6.042} \right)^3 + \left(\frac{22 - 28.667}{6.042} \right)^3 + \left(\frac{28 - 28.667}{6.042} \right)^3 + \left(\frac{34 - 28.667}{6.042} \right)^3 \right] \\ = 0.161 \times 6.860 = 1.10$$

ตอบ ความเบ้ของกลุ่มตัวอย่าง คือ 1.10

โค้ดไพทอนสำหรับ ความเบ้

```
1 import pandas as pd
2 from scipy import stats as sp
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 skew_s = x['age'].skew()
8 print(f'ความเบ้ของกลุ่มตัวอย่าง (อายุ) คือ {skew_s:.2f}\n')
9
10 #numpy
11 print('-----Numpy-----')
12 skew_s = sp.skew(x['age'], bias=False, nan_policy='omit')
13 skew_p = sp.skew(x['age'], nan_policy='omit') #bias=True
14 print(f'ความเบ้ของของของกลุ่มตัวอย่าง (อายุ) คือ {skew_s:.2f}')
15 print(f'ความเบ้ของประชากร (อายุ) คือ {skew_p:.2f}')
```

✓ 0.0s

-----Pandas-----
ความเบ้ของกลุ่มตัวอย่าง (อายุ) คือ 1.10

-----Numpy-----
ความเบ้ของของของกลุ่มตัวอย่าง (อายุ) คือ 1.10
ความเบ้ของประชากร (อายุ) คือ 0.91

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000

4.4.4.2 ความโด่ง

สูตรการหา ความโด่ง

$$G_2 = \left[\frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 \right] - \frac{3(n-1)^2}{(n-2)(n-3)} \quad \text{หรือ} \quad \gamma_2 = \left[\frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^4 \right] - 3$$

เมื่อ

G_2 = ความโด่งของกลุ่มตัวอย่าง (Samples)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

$\bar{x}$ = ค่าเฉลี่ยของกลุ่มตัวอย่าง

s = ส่วนเบี่ยงเบนมาตรฐานของกลุ่มตัวอย่าง

เมื่อ

γ_2 = ความโด่งของประชากร (Population)

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าของข้อมูลตัวที่ i

μ = ค่าเฉลี่ยของประชากร

σ = ส่วนเบี่ยงเบนมาตรฐานของประชากร

ตัวอย่างการคำนวณ ความโค้ง

จากข้อมูลต่อไปนี้ จงหา ความโค้งของกลุ่มตัวอย่าง

$$x = [25, 27, 23, 41, 32, 26, 22, 28, 34]$$

$$\text{กำหนดให้ } n = 9, \quad \bar{x} = 28.667, \quad s = 6.042$$

วิธีทำ

$$\text{จาก } G_2 = \left[\frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 \right] - \frac{3(n-1)^2}{(n-2)(n-3)} \quad \text{จะได้} \quad \frac{n(n+1)}{(n-1)(n-2)(n-3)} = \frac{9(10)}{(8)(7)(6)} = 0.268$$

$$\frac{3(n-1)^2}{(n-2)(n-3)} = \frac{3(8)^2}{(7)(6)} = 4.571$$

$$G_2 = \left[0.268 \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 \right] - 4.571$$

$$G_2 = \left[0.268 \left(\left(\frac{25 - 28.667}{6.042} \right)^4 + \left(\frac{27 - 28.667}{6.042} \right)^4 + \left(\frac{23 - 28.667}{6.042} \right)^4 + \left(\frac{41 - 28.667}{6.042} \right)^4 + \left(\frac{32 - 28.667}{6.042} \right)^4 + \right. \right. \\ \left. \left(\frac{26 - 28.667}{6.042} \right)^4 + \left(\frac{22 - 28.667}{6.042} \right)^4 + \left(\frac{28 - 28.667}{6.042} \right)^4 + \left(\frac{34 - 28.667}{6.042} \right)^4 \right) \right] - 4.571$$

$$= 0.268 \times 20.496 - 4.571 = 0.92$$

ตอบ ความโค้งของกลุ่มตัวอย่าง คือ 0.92

โค้ดไพทอนสำหรับ ความโด่ง

```
1 import pandas as pd
2 from scipy import stats as sp
3 x = pd.read_csv('data/customer2.csv')
4
5 #pandas
6 print('-----Pandas-----')
7 kurt_s = x['age'].kurt()
8 print(f'ความโด่งของกลุ่มตัวอย่าง (อายุ) คือ {kurt_s:.2f}\n')
9
10 #numpy
11 print('-----Numpy-----')
12 kurt_s = sp.kurtosis(x['age'], bias=False, nan_policy='omit')
13 kurt_p = sp.kurtosis(x['age'], nan_policy='omit') #bias=True
14 print(f'ความโด่งของของของกลุ่มตัวอย่าง (อายุ) คือ {kurt_s:.2f}')
15 print(f'ความโด่งของประชากร (อายุ) คือ {kurt_p:.2f}')
```

✓ 0.0s

-----Pandas-----

ความโด่งของกลุ่มตัวอย่าง (อายุ) คือ 0.92

-----Numpy-----

ความโด่งของของของกลุ่มตัวอย่าง (อายุ) คือ 0.92

ความโด่งของประชากร (อายุ) คือ -0.12

item	age	sex	education_level	occupation	total_spend
1	25.0	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27.0	ชาย	ปริญญาโท	พนักงานขาย	6200
3	23.0	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	NaN	หญิง	ปริญญาเอก	พนักงานขาย	8000
5	41.0	ชาย	ปริญญาโท	พนักงานขาย	120000
6	32.0	หญิง	ปริญญาตรี	พนักงานขาย	3500
7	26.0	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22.0	ชาย	ปริญญาตรี	พนักงานขาย	8750
9	28.0	ชาย	NaN	พนักงานขาย	15000
10	34.0	ชาย	ปริญญาตรี	พนักงานขาย	12000



Thank you
For Your Attention



สาขาวิชาวิทยาการคอมพิวเตอร์
คณะบริหารธุรกิจและเทคโนโลยีสารสนเทศ 