



วิทยาการข้อมูล


DATA SCIENCE

อ.พีชัย จอดพิมาย
ห้อง 970

สาขาวิชาวิทยาการคอมพิวเตอร์




จุดมุ่งหมายของรายวิชา




1. เพื่อให้นักศึกษาเข้าใจทฤษฎีวิทการข้อมูล
2. เพื่อให้นักศึกษาสามารถนำทฤษฎีวิทการข้อมูลไปประยุกต์ใช้ในการตัดสินใจทางธุรกิจ
3. เพื่อให้ผู้เรียนมีคุณธรรม จริยธรรม ระเบียบวินัย ความซื่อสัตย์สุจริต มีความรับผิดชอบต่อสังคม และตระหนักในจรรยาบรรณวิชาชีพ

จำนวนชั่วโมงเรียน




การบรรยาย/การฝึกปฏิบัติ	การศึกษาด้วยตนเอง
4 ชั่วโมงต่อสัปดาห์ (60 ชั่วโมงต่อภาคการศึกษา)	5 ชั่วโมงต่อสัปดาห์ (75 ชั่วโมงต่อภาคการศึกษา)

เกณฑ์ระดับคะแนน




ช่วงคะแนน	ระดับคะแนน (เกรด)
80-100	A
75-79	B+
70-74	B
65-69	C+
60-64	C
55-59	D+
50-54	D
0-49	F

วิธีการประเมิน



วิธีการประเมิน	สัดส่วนของการประเมินผล
แบบฝึกหัด/แบบทดสอบ	ร้อยละ 20
โครงงาน	ร้อยละ 30
การสอบกลางภาค	ร้อยละ 25
การสอบปลายภาค	ร้อยละ 25

แผนการเรียนรู้ COURSE SYLLABUS




สัปดาห์ที่	บทเรียน
1	บทที่ 1 แนะนำวิทยาการข้อมูล (Introduction to Data Science)
2	บทที่ 2 ภาษาโปรแกรมไพทอน (Python)
3-4	บทที่ 3 การรวบรวมและวิเคราะห์ข้อมูลเชิงสำรวจ (Data Collection and EDA)
5	บทที่ 4 การแทนค่าสูญหาย (Data Imputation)
6	บทที่ 5 การแปลงข้อมูล (Data Transformation)
7	บทที่ 6 การตรวจหาค่าผิดปกติ (Outlier Detection)
8	บทที่ 7 วิศวกรรมคุณลักษณะ (Feature Engineering)

แผนการเรียนรู้ COURSE SYLLABUS



สัปดาห์ที่	บทเรียน
9	สอบกลางภาค
10-11	บทที่ 8 การจำแนกกลุ่ม (Classification)
12-13	บทที่ 9 รีเกรสชัน (Regression)
14-15	บทที่ 10 การจัดกลุ่ม (Clustering)
16	บทที่ 11 กฎความสัมพันธ์ (Association Rule)
17	สอบปลายภาค



บทที่ 1

แนะนำวิทยาการข้อมูล


- ✓ 1.1 นิยามของวิทยาการข้อมูล
- ✓ 1.2 กระบวนการวิทยาการข้อมูล
- ✓ 1.3 ทักษะสำหรับวิทยาการข้อมูล
- ✓ 1.4 เครื่องมือสำหรับวิทยาการข้อมูล
- ✓ 1.5 แบบฝึกหัด

1.1 นิยามของวิทยาการข้อมูล

วิทยาการข้อมูล (Data Science : DS) คือ กระบวนการในการค้นหารูปแบบ (Pattern), ความสัมพันธ์ (Relationship), หรือข้อมูลเชิงลึก (Insight) ที่ซ่อนอยู่ในข้อมูลขนาดใหญ่ (Big Data) เพื่อนำไปใช้ในการตัดสินใจ หรือ แก้ปัญหาทางธุรกิจ (Businuss Problem)



Big Data คือ ชุดข้อมูลที่มี “ขนาดใหญ่ ความหลากหลายสูง และไหลเข้าอย่างรวดเร็ว” จนเครื่องมือแบบดั้งเดิม (เช่น RDBMS ทั่วไป) ไม่สามารถจัดเก็บ ประมวลผล หรือวิเคราะห์ได้อย่างมีประสิทธิภาพ



ภาพที่ 1-1 : 3V's Big Data

1. Volume (ปริมาณ)

- ข้อมูลมีขนาดใหญ่มาก ระดับ Terabytes ขึ้นไป
- เกินความสามารถในการจัดการด้วยระบบฐานข้อมูลทั่วไป

2. Velocity (ความเร็ว)


- ข้อมูลเกิดขึ้นและเปลี่ยนแปลงอย่างรวดเร็ว
- ต้องการการประมวลผลแบบ Real-time

3. Variety (ความหลากหลาย)

- ข้อมูลมีหลากหลายรูปแบบ
- มีทั้ง Structured เช่น RDBMS, CSV, Excel
Semi-Structured เช่น XML, JSON
Unstructured เช่น Text, Image, Audio, Video


1.2 กระบวนการวิทยาการข้อมูล

กระบวนการวิทยาการข้อมูล (Data Science Process) คือ ชุดของขั้นตอนสำหรับการจัดการข้อมูลขนาดใหญ่ ตั้งแต่การรวบรวมข้อมูล การจัดเก็บ การปรับปรุงคุณภาพ ไปจนถึงการวิเคราะห์และการนำเสนอผลลัพธ์ เพื่อเปลี่ยนข้อมูลที่มีปริมาณมหาศาลและซับซ้อน ให้กลายเป็นข้อมูลเชิงลึก (Insights) ที่สามารถนำไปใช้ในการตัดสินใจ หรือสร้างมูลค่าทางธุรกิจได้




- Data Pipeline
- CRISP-DM

1.2.1 Data Pipeline



ภาพที่ 1-2 : Data Pipeline

1.2.2 CRISP-DM



- 1) ความเข้าใจในธุรกิจ (Business Understanding)
- 2) ความเข้าใจในข้อมูล (Data Understanding)
- 3) การเตรียมข้อมูล (Data Preparation)
- 4) การสร้างโมเดล (Modeling)
- 5) การประเมินโมเดล (Evaluation)
- 6) การนำโมเดลไปใช้ (Deployment)

ภาพที่ 1-3 : Cross-Industry Standard Process for Data Mining (CRISP-DM)

ขั้นที่ 1 : ความเข้าใจในธุรกิจ (BUSINESS UNDERSTANDING)

- เข้าใจเป้าหมายขององค์กร เช่น วิสัยทัศน์ (Vision) พันธกิจ (Mission) กระบวนการทำงาน (Business Process)
- เข้าใจปัญหา (Problem) และความต้องการขององค์กร (Business Requirement) เช่น จำนวนลูกค้าลดลง ยอดขายลดลง การปล่อยเงินกู้เกิดหนี้เสีย
- แปลงปัญหาและความต้องการขององค์กรไปเป็นปัญหาการวิเคราะห์ข้อมูล
- วางแผนโครงการ (Project Plan) เช่น กิจกรรม เวลา คน เครื่องมือ ในการวิเคราะห์ข้อมูล



Business Problems and Requirements

Transform



Data Analytics Problems

ตารางที่ 1-1 : การแปลงปัญหาและความต้องการขององค์กรไปเป็นปัญหาการวิเคราะห์ข้อมูล

ปัญหา/ความต้องการขององค์กร	คำถามเชิงธุรกิจ	ประเภทปัญหาทางการวิเคราะห์ข้อมูล
ต้องการการจัดกลุ่มลูกค้า	ลูกค้าสามารถแบ่งออกได้ที่กลุ่ม	Clustering
ต้องการการจัดกลุ่มพนักงาน	พนักงานสามารถแบ่งออกได้ที่กลุ่ม	Clustering
ต้องการเพิ่มยอดขายต่อใบเสร็จ	สินค้าใดที่ลูกค้ามักซื้อพร้อมกัน	Association Rule
ต้องการประเมินราคาบ้าน	บ้านหลังนี้ควรมีราคาเท่าไร	Regression
ต้องการทำนายราคาหุ้น	หุ้นบริษัทนี้ควรมีราคาเท่าไร	Regression (Time Series)
ปัญหาการอนุมัติสินเชื่อซื้อบ้าน	ควรอนุมัติสินเชื่อให้ลูกค้ารายนี้หรือไม่	Classification (Binary)
ต้องการรักษาฐานลูกค้า	ลูกค้ารายนี้จะยังคงใช้บริการต่อหรือไม่	Classification (Binary)
ต้องการการวินิจฉัยโรคเบาหวาน	ผู้เข้ารับการตรวจโรครายนี้เป็นโรคเบาหวานหรือไม่	Classification (Binary)

ขั้นที่ 2 : ความเข้าใจในข้อมูล (DATA UNDERSTANDING)

- การรวบรวมข้อมูล (Data Collection)
 - Structured Data เช่น RDBMS, CSV, Excel
 - Semi-Structured Data เช่น XML, JSON
 - Unstructured Data เช่น Text, Image, Audio, Video

item	age	sex	education_level	occupation	total_spend
1	25	หญิง	ปริญญาตรี	พนักงานขาย	4,500
2	27	ชาย	ปริญญาโท	พนักงานขาย	6,200
3	23	ชาย	ปริญญาตรี	พนักงานขาย	5,000
4	35	หญิง	ปริญญาเอก	พนักงานขาย	8,000
5	41	ชาย	ปริญญาโท	พนักงานขาย	120,000
6	32	หญิง	ปริญญาตรี	พนักงานขาย	3,500
7	26	หญิง	ปริญญาโท	พนักงานขาย	11,000
8	22	ชาย	ปริญญาตรี	พนักงานขาย	8,750
9	28	ชาย		พนักงานขาย	15,000
10	34	ชาย	ปริญญาตรี	พนักงานขาย	12,000

ภาพที่ 1-4 : ตัวอย่างข้อมูลที่เก็บอยู่ใน RDBMS (MySQL)

ตัวอย่าง CSV

item,age,sex,education_level,occupation,total_spend

1,25,หญิง,ปริญญาตรี,พนักงานขาย,"4,500"
2,27,ชาย,ปริญญาโท,พนักงานขาย,"6,200"
3,23,ชาย,ปริญญาตรี,พนักงานขาย,"5,000"
4,35,หญิง,ปริญญาเอก,พนักงานขาย,"8,000"
5,41,ชาย,ปริญญาโท,พนักงานขาย,"120,000"
6,32,หญิง,ปริญญาตรี,พนักงานขาย,"3,500"
7,26,หญิง,ปริญญาโท,พนักงานขาย,"11,000"
8,22,ชาย,ปริญญาตรี,พนักงานขาย,"8,750"
9,28,ชาย,,พนักงานขาย,"15,000"
10,34,ชาย,ปริญญาตรี,พนักงานขาย,"12,000"

ตัวอย่าง Exeel

	A	B	C	D	E	F
1	item	age	sex	education_level	occupation	total_spend
2	1	25	หญิง	ปริญญาตรี	พนักงานขาย	4,500
3	2	27	ชาย	ปริญญาโท	พนักงานขาย	6,200
4	3	23	ชาย	ปริญญาตรี	พนักงานขาย	5,000
5	4	35	หญิง	ปริญญาเอก	พนักงานขาย	8,000
6	5	41	ชาย	ปริญญาโท	พนักงานขาย	120,000
7	6	32	หญิง	ปริญญาตรี	พนักงานขาย	3,500
8	7	26	หญิง	ปริญญาโท	พนักงานขาย	11,000
9	8	22	ชาย	ปริญญาตรี	พนักงานขาย	8,750
10	9	28	ชาย		พนักงานขาย	15,000
11	10	34	ชาย	ปริญญาตรี	พนักงานขาย	12,000

ภาพที่ 1-5 : ตัวอย่างข้อมูลที่เก็บอยู่ในรูปแบบไฟล์ CSV และ Excel

ตัวอย่าง XML

```
<?xml version="1.0" encoding="UTF-8" ?>
<root>
  <orderID>1</orderID>
  <orderDate>2020-08-11</orderDate>
  <TotalPrice>1500</TotalPrice>
  <customer>
    <customerID>1</customerID>
    <firstName>วิรัตน์</firstName>
    <lastName>สุขใจ</lastName>
    <mobilePhone>0894599232</mobilePhone>
    <email>wirath@hotmail.com</email>
  </customer>
  <product>
    <productID>12</productID>
    <productName>เสื้อแขนยาว</productName>
    <Quantity>1</Quantity>
    <Price>1000</Price>
  </product>
  <product>
    <productID>15</productID>
    <productName>กางเกงขายาว</productName>
    <Quantity>1</Quantity>
    <Price>500</Price>
  </product>
</root>
```

ตัวอย่าง JSON

```
{
  "orderID": "1",
  "orderDate": "2020-08-11",
  "TotalPrice": "1500",
  "customer": {
    "customerID": "1",
    "firstName": "วิรัตน์",
    "lastName": "สุขใจ",
    "mobilePhone": "0894599232",
    "email": "wirath@hotmail.com",
  },
  "product": [
    {
      "productID": "12",
      "productName": "เสื้อแขนยาว",
      "Quantity": "1",
      "Price": "1000",
    },
    {
      "productID": "15",
      "productName": "กางเกงขายาว",
      "Quantity": "1",
      "Price": "500",
    }
  ]
}
```

ภาพที่ 1-6 : ตัวอย่างข้อมูลที่เก็บอยู่ในรูปแบบไฟล์ XML และ JSON

ตัวอย่าง Text


Clothing ID	Review Text
767	Absolutely wonderful - silky and sexy and comfortable
1080	Love this dress! it's sooo pretty. i happened to find it in a store, and i'm glad i did bc i never would have ordered it online bc it's petite. i bought a petite and am 5'8". i love the length on me- hits just a little below the knee. would definitely be a true midi on someone who is truly petite.
1077	I had such high hopes for this dress and really wanted it to work for me. i initially ordered the petite small (my usual size) but i found this to be outrageously small. so small in fact that i could not zip it up! i reordered it in petite medium, which was just ok. overall, the top half was comfortable and fit nicely, but the bottom half had a very tight under layer and several somewhat cheap (net) over layers. imo, a major design flaw was the net over layer sewn directly into the zipper - it c
1049	I love, love, love this jumpsuit. it's fun, flirty, and fabulous! every time i wear it, i get nothing but great compliments!
847	This shirt is very flattering to all due to the adjustable front tie. it is the perfect length to wear with leggings and it is sleeveless so it pairs well with any cardigan. love this shirt!!!

ภาพที่ 1-7 : ตัวอย่างข้อมูลที่เก็บอยู่ในรูปแบบ Text

ตัวอย่าง Image



ตัวอย่าง Audio




ตัวอย่าง Video



ภาพที่ 1-8 : ตัวอย่างข้อมูลที่เก็บอยู่ในรูปแบบไฟล์ Image, Audio, และ Video

- การอธิบายคุณลักษณะข้อมูล (Data Description/Exploration)
 - Descriptive Statistics เช่น Count, Mode, Mean, Median, SD
 - Data Visualization เช่น Bar Chart, Pie Chart, Boxplot, Scatter Plot









ภาพที่ 1-9 : Level of Measurement

ตารางที่ 1-2 : คุณสมบัติและสถิติสำหรับระดับการวัดข้อมูล

ระดับการวัด	คุณสมบัติ	สถิติ			
		Count/Percent/Mode	Rank/Median	บวก/ลบ/Mean/SD	คูณ/หาร/C.V./R
Nominal	- แยกกลุ่มได้ - เช่น เพศ ศาสนา				
Ordinal	- จัดลำดับได้ - เช่น ระดับการศึกษา ความพึงพอใจ				
Interval	- มีช่วงห่างเท่ากัน - เช่น เวลา อุณหภูมิ (°C)				
Ratio	- มีศูนย์แท้ - เช่น อายุ รายได้				

ตารางที่ 1-3 : การอธิบายคุณลักษณะข้อมูลด้วย Descriptive Statistics

	count	mean	std	min	25%	50%	75%	max
age	10.0	29.3	6.037844	22.0	25.25	27.5	33.5	41.0
total_spend	10.0	19395.0	35535.338045	3500.0	5300.00	8375.0	11750.0	120000.0



ภาพที่ 1-10 : การอธิบายคุณลักษณะข้อมูลด้วย Data Visualization

ขั้นที่ 3 : การเตรียมข้อมูล (DATA PREPARATION)

- ปรับปรุงคุณภาพข้อมูล จากปัญหาที่พบในขั้นตอนที่ผ่านมา
- เปลี่ยนแปลงข้อมูลให้เหมาะสมกับเทคนิคการวิเคราะห์ข้อมูล
(เช่น เทคนิคที่ต้องบวก ลบ คูณ หาร จำเป็นต้องแปลงข้อมูลให้เป็นตัวเลขก่อน)

ตารางที่ 1-4 : เทคนิคการเตรียมข้อมูล

เทคนิค	คำอธิบาย
Missing Value Imputation	การแทนค่าข้อมูลสูญหาย หรือ ไม่ทราบค่า
Data Transformation	การแปลงข้อมูลจากค่าหนึ่งไปเป็นอีกค่าหนึ่ง
Outlier Detection	การตรวจหาและจัดการค่าผิดปกติ
Feature Engineering	การแยก การรวม การเลือก และการแปลงปัจจัย (คอลัมน์)
Handling Class Imbalance	การจัดการความไม่สมดุลของคลาส

ตัวอย่างการเตรียมข้อมูล


- แทนค่าสูญหายด้วยค่า mode นั่นคือ “ปริญญาตรี”
- ตัดคอลัมน์ “อาชีพ” ออก (อาชีพเดียวไม่สามารถแบ่งแยกกลุ่มได้)
- ตัดแถว “ที่ 5” ออก (120,000 ถูกพิจารณาเป็นค่าสูงผิดปกติ)
- แปลงข้อมูล ให้ ชาย=0, หญิง=1, ปริญญาตรี=0, ปริญญาโท=1, ปริญญาเอก=2

ตารางที่ 1-5 : ตัวอย่างการเตรียมข้อมูล

คนที่	อายุ	เพศ	ระดับการศึกษา	อาชีพ	ยอดการใช้จ่าย
1	25	หญิง 1	ปริญญาตรี 0	พนักงานขาย	4,500
2	27	ชาย 0	ปริญญาโท 1	พนักงานขาย	6,200
3	23	ชาย 0	ปริญญาตรี 0	พนักงานขาย	5,000
4	35	หญิง 1	ปริญญาเอก 2	พนักงานขาย	8,000
5	41	ชาย 0	ปริญญาโท 1	พนักงานขาย	120,000
6	32	หญิง 1	ปริญญาตรี 0	พนักงานขาย	3,500
7	26	หญิง 1	ปริญญาโท 1	พนักงานขาย	11,000
8	22	ชาย 0	ปริญญาตรี 0	พนักงานขาย	8,750
9	28	ชาย 0	ปริญญาตรี 0	พนักงานขาย	15,000
10	34	ชาย 0	ปริญญาตรี 0	พนักงานขาย	12,000

ขั้นที่ 4 : การสร้างโมเดล (MODELING)

- เลือก Modeling Techniques (K-Mean, KNN, ANN)
- สร้าง ประเมิน และปรับปรุงโมเดล



ภาพที่ 1-11 : การสร้างโมเดล



ภาพที่ 1-12 : วิธีการประเมินโมเดล (Assessment)

ขั้นที่ 5 : การประเมินค่าของโมเดล (EVALUATION)

ประเมินผลลัพธ์ (Evaluate Results)


- นำโมเดลไปทดลองในสถานการณ์จริง
- ประเมินโมเดลว่าจะสามารถแก้ไขปัญหาหรือพบกับความต้องการขององค์กร ตามที่กำหนดไว้ในขั้น Business Understanding

ตัดสินใจว่าจะดำเนินโครงการต่อหรือไม่ (Determine Next Steps)

- ขึ้นอยู่กับผลการประเมิน
- ถ้าโมเดลมีแนวโน้มว่าจะช่วยให้ความต้องการขององค์กรประสบความสำเร็จได้ก็ดำเนินการต่อ
- ถ้าไม่ อาจจะย้อนกลับไปแก้ไขโมเดล หรือไม่ก็หยุดโครงการเลย

ภาพที่ 1-13 : การประเมินค่าของโมเดล (Evaluation)

ขั้นที่ 6 : การนำโมเดลไปใช้ (DEPLOYMENT)



ภาพที่ 1-14 : การนำโมเดลไปใช้ (Deployment)

1.3 ทักษะสำหรับวิทยาการข้อมูล

ทักษะสำหรับวิทยาการข้อมูล(Data Science Skills) คือ ชุดทักษะที่เกี่ยวข้องกับการจัดการ วิเคราะห์ และสร้างคุณค่าจากข้อมูลขนาดใหญ่


Business and
Domain Skills

Big Data & Cloud
Platform Skills

Data Engineering
Skills

Statistical &
Machine Learning
Skills

Programming &
Software
Engineering Skills



ภาพที่ 1-15 : Machine Learning Techniques

1.3.1 การจำแนกกลุ่มข้อมูล (Classification)


การจำแนกกลุ่มข้อมูล (Classification) คือ เทคนิคการทำนายกลุ่มข้อมูล (Class) โดยเรียนรู้จากข้อมูลที่มีการระบุกลุ่มไว้แล้ว (Labeled Data)

ตัวอย่างการประยุกต์ใช้

- การอนุมัติสินเชื่อซื้อบ้าน (อนุมัติ/ไม่อนุมัติ)
- การทำนายการรักษาฐานลูกค้า (เป็นลูกค้าต่อไป/ไม่เป็นลูกค้าต่อ)
- การวินิจฉัยโรคเบาหวาน (เป็น/ไม่เป็น)
- การตรวจจับ Spam Mail (เป็น/ไม่เป็น)
- การแยกแยะวัตถุของรถยนต์ขับเคลื่อนอัตโนมัติ (รถยนต์/คน/สัตว์)

เทคนิคการจำแนกกลุ่มข้อมูล

- Logistic Regression (LR)
- Naïve Bays (NB)
- Decision Tree (DT)
- SVM / KNN / ANN



ภาพที่ 1-16 : ตัวอย่างการวินิจฉัยผู้ป่วยโรคเบาหวาน

1.3.2 รีเกรสชัน (Regression)


รีเกรสชัน (Regression) คือ เทคนิคการทำนายค่าตัวเลข (Numerical Value) โดยเรียนรู้ความสัมพันธ์ระหว่างตัวแปรต้น (Independent/Input) กับตัวแปรตาม (Dependent/Output/Target) จากข้อมูลที่มีอยู่

ตัวอย่างการประยุกต์ใช้

- การประเมินราคาบ้าน (บาท/ตร.ม.)
- การประมาณการรายได้ (บาท/เดือน)
- การทำนายราคาหุ้น (บาท)
- การทำนายอุณหภูมิ (องศาเซลเซียส)
- การทำนายปริมาณน้ำฝน (มม./24 ชม.)
- การทำนายปริมาณ PM 2.5 (มคก./ลบ.ม.)

เทคนิครีเกรสชัน

- Linear Regression (LR)
- Classification and Regression Trees (CART)
- SVR / KNN / ANN



ภาพที่ 1-17 : ตัวอย่างการประมาณการรายได้

1.3.3 การจัดกลุ่มข้อมูล (Clustering)


การจัดกลุ่มข้อมูล (Clustering) คือ เทคนิคการแบ่งข้อมูลออกเป็นกลุ่มย่อย ๆ โดยข้อมูลที่อยู่ในกลุ่มเดียวกันจะมีคุณลักษณะที่คล้ายคลึงกัน และแตกต่างจากข้อมูลในกลุ่มอื่น

ตัวอย่างการประยุกต์ใช้

- การจัดกลุ่มลูกค้าเพื่อเสนอโปรโมชั่นที่เหมาะสม (กลุ่มที่ 1, 2,..., k)
- การจัดกลุ่มร้านค้าปลีกเพื่อสร้างกลยุทธ์ที่เหมาะสม (กลุ่มที่ 1, 2,..., k)
- การจัดกลุ่มพนักงานเพื่อใช้สำหรับการฝึกอบรม (กลุ่มที่ 1, 2,..., k)

เทคนิคการจัดกลุ่มข้อมูล

- K-Mean
- Hierarchical Clustering
- DBSCAN
- Self-Organizing Map (SOM)



ภาพที่ 1-18 : ตัวอย่างการจัดกลุ่มลูกค้า

1.3.4 กฎความสัมพันธ์ (Association Rule)

กฎความสัมพันธ์ (Association Rule) คือ เทคนิคในการค้นหารูปแบบและความสัมพันธ์ของข้อมูล โดยพิจารณาว่าถ้ามีเหตุการณ์ A เกิดขึ้น จะมีโอกาสที่จะเกิดเหตุการณ์ B ตามมาด้วยมากน้อยเพียงใด

ตัวอย่างการประยุกต์ใช้

- ด้านสินค้า เช่น ถ้าซื้อกาแฟ แล้วจะซื้อคุกกี้
- ด้านการท่องเที่ยว เช่น ถ้าไปวัดพระแก้ว แล้วจะไปวัดโพธิ์และวัดอรุณราชวราราม
- ด้านการแพทย์ เช่น ถ้าเป็นเบาหวานและโรคอ้วน แล้วจะเป็นความดันโลหิตสูง

เทคนิคกฎความสัมพันธ์

- Apriori
- FP-Growth

กฎที่ 1 : {กาแฟ} → {ซื้อคุกกี้}	(Support 40%, Confidence 72%)
กฎที่ 2 : {รองเท้าวาง} → {ถุงเท้ากีฬา}	(Support 67%, Confidence 91%)
กฎที่ 3 : {ข้าวกล้องขุดพิเศษ} → {น้ำผลไม้}	(Support 59%, Confidence 90%)
กฎที่ 4 : {ขนมปัง, แยม} → {เนย}	(Support 35%, Confidence 85%)
กฎที่ 5 : {แชมพู} → {ครีมนวดผม, ทรีตเมนต์ผม}	(Support 28%, Confidence 76%)

ภาพที่ 1-19 : ตัวอย่างกฎความสัมพันธ์

1.4 เครื่องมือสำหรับวิทยาการข้อมูล

Data Science Tools คือ ชุดเครื่องมือหรือแพลตฟอร์มที่ใช้ในการจัดเก็บ ประมวลผล วิเคราะห์ และจัดการข้อมูลขนาดใหญ่

Data Management
Systems

Data Ingestion and
Data Integration
Tools

Data Visualization
Tools

ML Modeling
Tools

Programming
Languages

Workflow
Orchestration
Tools

Big Data
Platforms

- **Data Management Systems**

- Relational Database Management System (RDBMS)



- Not only SQL (NoSQL)




- **Data Ingestion and Data Integration Tools**



- **Data Visualization Tools**



- ML Modeling Tools



- **Programming Languages**



SQL



Batch Script



Shell Script



PowerShell Script

- **Workflow Orchestration Tools**



- **Big Data Platforms**



CLOUDERA



ตารางที่ 1-6 : เปรียบเทียบ Data/ML Platforms จาก 3 Hyperscalers (AWS, GCP, Azure)

หมวดหมู่	AWS (Amazon)	Azure (Microsoft)	GCP (Google Cloud)
Storage (Data Lake)	Amazon S3	ADLS Gen2	Cloud Storage (GCS)
Data Integration	AWS Glue	Data Factory (ADF)	Dataflow / Data Fusion
Data Warehouse	Amazon Redshift	Synapse Analytics	BigQuery
AI / ML Platform	Amazon SageMaker	Azure Machine Learning	Vertex AI
Business Intelligence	Amazon QuickSight	Power BI	Looker
Stream Processing	Amazon Kinesis	Stream Analytics	Pub/Sub + Dataflow

1.5 แบบฝึกหัด

1. วิทยาการข้อมูล (Data Science) คืออะไร และมีจุดประสงค์เพื่ออะไร?
2. จงอธิบายความแตกต่างระหว่าง Large Dataset กับ Big Data
3. จงอธิบายความแตกต่างระหว่าง Data Pipeline กับ CRISP-DM
4. ใน CRISP-DM ขั้นตอนไหนสำคัญที่สุด เพราะอะไร
5. ข้อมูลประเภท Structured Data, Semi-Structured Data, และ Unstructured Data มีความแตกต่างกันอย่างไร จงยกตัวอย่างประกอบ
6. จงยกตัวอย่างข้อมูลของแต่ละระดับการวัดข้อมูล (Level of Measurement) ระดับละ 5 ตัวอย่าง
7. หากห้าง Lotus ต้องจัดวาง Zone การขายสินค้าใหม่ ควรใช้เทคนิคการวิเคราะห์ข้อมูลแบบใด เหมาะสมที่สุด เพราะอะไร
8. การประเมินโมเดลในด้าน "ประสิทธิผล (Effectiveness)" และ "ประสิทธิภาพ (Efficiency)" แตกต่างกันอย่างใด
9. จงอธิบายความแตกต่างระหว่างระบบฐานข้อมูลแบบ SQL กับ NoSQL พร้อมทั้งยกตัวอย่างประกอบ
10. หากองค์กรต้องการใช้บริการแพลตฟอร์ม Cloud จาก 3 ค่ายหลัก (AWS, Azure, GCP) เพื่อพัฒนา ML Model ควรเลือกใช้บริการใดของแต่ละค่าย
11. จงยกตัวอย่างองค์กรในประเทศไทยอย่างน้อย 5 องค์กร ที่น่าจะมีข้อมูลในระดับ Big Data และระบุแหล่งที่มาของข้อมูล (Data Source) พร้อมทั้งแสดงผลที่เชื่อได้ว่าข้อมูลเหล่านั้นอยู่ในระดับ Big Data จริง ๆ

12. สมมติว่าบริษัท E-commerce แห่งหนึ่งต้องการนำข้อมูลลูกค้ามาวิเคราะห์เพื่อลดอัตราการยกเลิกบริการ (Churn Rate) แต่ข้อมูลที่มียังกระจัดกระจายและไม่สมบูรณ์ ในฐานะนักวิเคราะห์ข้อมูล คุณจะประยุกต์ใช้ขั้นตอนของ CRISP-DM อย่างไรให้ครอบคลุมกระบวนการนี้
13. หากแพลตฟอร์มโซเชียลมีเดียต้องการวิเคราะห์ความรู้สึกของผู้ใช้งาน (Sentiment Analysis) แบบเรียลไทม์ผ่านวิดีโอคลิปและข้อความคอมเมนต์ ข้อมูลนี้สะท้อนลักษณะ 3V's ของ Big Data อย่างไร และจะส่งผลต่อการจัดการข้อมูลอย่างไรเมื่อเทียบกับฐานข้อมูลแบบดั้งเดิม
14. ผู้บริหารต้องการสร้างระบบ AI สองระบบ ระบบแรกคือ "ทำนายความเสี่ยงในการเป็นโรคหัวใจ (เป็น/ไม่เป็น)" และระบบที่สองคือ "ทำนายระยะเวลาที่ผู้ป่วยจะต้องพักรักษาในโรงพยาบาล (จำนวนวัน)" คุณจะเลือกเทคนิคการวิเคราะห์ข้อมูลแบบใดสำหรับแต่ละระบบ พร้อมวิเคราะห์เหตุผล



THANK YOU
FOR YOUR ATTENTION