



# บทที่ 4

## การแทนค่าสูญหาย

- ✓ 4.1 แนะนำการแทนค่าสูญหาย
- ✓ 4.2 Mean Imputation
- ✓ 4.3 Median Imputation
- ✓ 4.4 Mode Imputation
- ✓ 4.5 KNN Imputation
- ✓ 4.6 แบบฝึกหัด

## 4.1 แนะนำการแทนค่าสูญหาย

- การแทนที่ข้อมูลสูญหาย (Missing Value Imputation) คือ การแทนข้อมูลเข้าไปในส่วนที่สูญหาย
- การสูญหาย อาจมาจากการสูญหายหลังจากเก็บข้อมูลแล้ว หรืออาจเกิดจากผู้ที่ยังไม่เก็บข้อมูลไม่สามารถจัดเก็บข้อมูลได้ตั้งแต่ต้น
- ตัวอย่างเทคนิคของการแทนที่ข้อมูลสูญหาย มีดังนี้
  - Mean Imputation
  - Median Imputation
  - Mode Imputation
  - KNN Imputation



## Classification

Identifying which category an object belongs to.

**Applications:** Spam detection, image recognition.

**Algorithms:** [Gradient boosting](#), [nearest neighbors](#), [random forest](#), [logistic regression](#), and [more...](#)

## Regression

Predicting a continuous-valued attribute associated with an object.

**Applications:** Drug response, stock prices.

**Algorithms:** [Gradient boosting](#), [nearest neighbors](#), [random forest](#), [ridge](#), and [more...](#)

## Clustering

Automatic grouping of similar objects into sets.

**Applications:** Customer segmentation, grouping experiment outcomes.

**Algorithms:** [k-Means](#), [HDBSCAN](#), [hierarchical clustering](#), and [more...](#)

## Dimensionality reduction

Reducing the number of random variables to consider.

**Applications:** Visualization, increased efficiency.

**Algorithms:** [PCA](#), [feature selection](#), [non-negative matrix factorization](#), and [more...](#)

## Model selection

Comparing, validating and choosing parameters and models.

**Applications:** Improved accuracy via parameter tuning.

**Algorithms:** [Grid search](#), [cross validation](#), [metrics](#), and [more...](#)

## Preprocessing

Feature extraction and normalization.

**Applications:** Transforming input data such as text for use with machine learning algorithms.

**Algorithms:** [Preprocessing](#), [feature extraction](#), and [more...](#)

```
1 # ติดตั้ง Scikit-learn
2 %pip install scikit-learn
```

Python

## 4.1.1 การตรวจสอบค่าสูญหาย

|   | item | age  | sex  | education_level | occupation | total_spend |
|---|------|------|------|-----------------|------------|-------------|
| 0 | 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 1 | 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 2 | 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 3 | 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 4 | 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 5 | 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 6 | 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 7 | 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 8 | 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 9 | 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

- วิธีแสดงจำนวนค่า NaN ในทุกคอลัมน์

```
1 x.isna().sum()
```

✓ 0.0s

```
age          1
sex          0
education_level  1
occupation    0
total_spend   0
dtype: int64
```

- วิธีแสดงจำนวนค่า NaN ในคอลัมน์ที่มีค่า NaN

```
1 x.isna().sum()[x.isna().sum() > 0]
```

✓ 0.0s

```
age          1
education_level  1
dtype: int64
```

- วิธีแสดงชื่อคอลัมน์ที่มีค่า NaN

```
1 x.columns[x.isna().any()].tolist()
```

✓ 0.0s

['age', 'education\_level']

- วิธีแสดงแถวที่มีค่า NaN

```
1 x[x.isna().any(axis=1)]
```

0.0s

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |

- วิธีแสดงแถวที่มีค่า NaN ในคอลัมน์ที่ระบุ

```
1 x[x['age'].isna()]
```

0.0s

| item | age | sex  | education_level | occupation | total_spend |
|------|-----|------|-----------------|------------|-------------|
| 4    | NaN | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |

## 4.1.2 การจัดการค่าสูญหายเบื้องต้น

- วิธีลบคอลัมน์ที่มีค่า NaN

```
1 x.dropna(axis=1)
```

0.0s

| item | sex  | occupation | total_spend |
|------|------|------------|-------------|
| 1    | หญิง | พนักงานขาย | 4500        |
| 2    | ชาย  | พนักงานขาย | 6200        |
| 3    | ชาย  | พนักงานขาย | 5000        |
| 4    | หญิง | พนักงานขาย | 8000        |
| 5    | ชาย  | พนักงานขาย | 120000      |
| 6    | หญิง | พนักงานขาย | 3500        |
| 7    | หญิง | พนักงานขาย | 11000       |
| 8    | ชาย  | พนักงานขาย | 8750        |
| 9    | ชาย  | พนักงานขาย | 15000       |
| 10   | ชาย  | พนักงานขาย | 12000       |

- วิธีลบแถวที่มีค่า NaN

```
1 x.dropna()
```

0.0s

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## • วิธีลบคอลัมน์ที่ระบุ

```
1 x.drop(columns=['age', 'education_level'])
```

0.0s

| item | sex  | occupation | total_spend |
|------|------|------------|-------------|
| 1    | หญิง | พนักงานขาย | 4500        |
| 2    | ชาย  | พนักงานขาย | 6200        |
| 3    | ชาย  | พนักงานขาย | 5000        |
| 4    | หญิง | พนักงานขาย | 8000        |
| 5    | ชาย  | พนักงานขาย | 120000      |
| 6    | หญิง | พนักงานขาย | 3500        |
| 7    | หญิง | พนักงานขาย | 11000       |
| 8    | ชาย  | พนักงานขาย | 8750        |
| 9    | ชาย  | พนักงานขาย | 15000       |
| 10   | ชาย  | พนักงานขาย | 12000       |

## • วิธีลบแถวที่ระบุ

```
1 #วิธีลบแถวที่ระบุ
2 x.drop(index=[3, 8])
```

✓ 0.0s

|   | item | age  | sex  | education_level | occupation | total_spend |
|---|------|------|------|-----------------|------------|-------------|
| 0 | 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 1 | 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 2 | 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4 | 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 5 | 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 6 | 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 7 | 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9 | 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

กรณีกำหนดคอลัมน์ item เป็น index

เช่น x.set\_index('item', inplace=True) ให้ใช้ index=[4, 9]  
แทน index=[3, 8]

- วิธีลบแถวที่มีค่า NaN ในคอลัมน์ที่ระบุ

```
1 x.dropna(subset=['age'])
```

0.0s

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.2 Mean Imputation

- เป็นวิธีการแทนข้อมูลที่สูญหายด้วยค่าเฉลี่ย (Mean)
- ข้อดี คือ เป็นวิธีที่สะดวก
- ข้อเสีย คือ กรณีที่มี Outliers (ข้อมูลผิดปกติ--ค่าสูงหรือต่ำเกินไป) จะทำให้ค่าเฉลี่ยที่ได้ไม่สามารถนำไปใช้แทนข้อมูลที่สูญหายได้
- ต้องเป็นตัวแปร Interval หรือ Ratio

## 4.2.1 การคำนวณสำหรับ Mean Imputation

สูตรการหาค่าเฉลี่ย

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

เมื่อ

$\bar{x}$  = ค่าเฉลี่ยจากข้อมูลทั้งหมด

$x_i$  = ค่าของข้อมูลตัวที่  $i$

$n$  = จำนวนข้อมูลทั้งหมด

วิธีทำ

$$\bar{x} = \frac{1}{9} (25 + 27 + 23 + 41 + 32 + 26 + 22 + 28 + 34)$$

$$\bar{x} = \frac{1}{9} (258) = 28.67$$

นำค่า **28.67** ไปแทนที่ค่าสูญหาย ในแถวที่ 4 คอลัมน์ “age”

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.2.2 โค้ดไพทอนสำหรับ Mean Imputation

```
1 # Import Libraries
2 import numpy as np
3 from sklearn.impute import SimpleImputer
4
5 # Choose the imputation strategy
6 imp=SimpleImputer(missing_values=np.nan, strategy='mean')
7
8 # Compute the mean value for the age column
9 imp.fit(x[['age']])
10
11 # Show the computed mean value
12 print(f'Mean value: {imp.statistics_[0]:.2f}')
13
14 # Replace missing values with the computed mean value
15 x[['age']]=imp.transform((x[['age']]))
16 x
```

✓ 0.0s

Mean value: 28.50

| item | age   | sex  | education_level | occupation | total_spend |
|------|-------|------|-----------------|------------|-------------|
| 1    | 25.00 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.00 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | 28.67 | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.00 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.00 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.00 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.00 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.3 Median Imputation

- เป็นวิธีการแทนข้อมูลที่สูญหายด้วยค่ามัธยฐาน (Median)
- ข้อดี คือ เป็นวิธีที่สะดวก และไม่ Sensitive ต่อ outliers
- ต้องเป็นตัวแปร Ordinal, Interval, หรือ Ratio

## 4.3.1 การคำนวณสำหรับ Median Imputation

### สูตรการหาค่ามัธยฐาน

$$\text{Median} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & \text{if } n \text{ is odd} \\ \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & \text{if } n \text{ is even} \end{cases}$$

เมื่อ

$n$  = จำนวนข้อมูลทั้งหมด

### วิธีทำ

- ทำการเรียงข้อมูล ได้ดังนี้

$$x = \{22, 23, 25, 26, 27, 28, 32, 34, 41\}$$

- หาดำแหน่งของค่า **มัธยฐาน** จากสูตร  $(n+1) / 2$  ได้ดังนี้

$$\frac{9+1}{2} = 5$$

- หาค่า **มัธยฐาน** ได้จาก ค่าในตำแหน่งที่ 5 นั่นคือ **27**

นำค่า **27** ไปแทนที่ค่าสูญหาย ในแถวที่ 4 คอลัมน์ “age”

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.3.2 โค้ดไพทอนสำหรับ Median Imputation

```
1 # Import Libraries
2 import numpy as np
3 from sklearn.impute import SimpleImputer
4
5 # Choose the imputation strategy
6 imp=SimpleImputer(missing_values=np.nan, strategy='median')
7
8 # Compute the median value for the age column
9 imp.fit(x[['age']])
10
11 # Show the computed median value
12 print(f'Median value: {imp.statistics_[0]:.2f}')
13
14 # Replace missing values with the computed median value
15 x[['age']] = imp.transform(x[['age']]).round(2)
16 x
```

✓ 0.0s

Median value: 27.00

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | 27.0 | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.4 Mode Imputation

- เป็นวิธีการแทนข้อมูลที่สูญหายด้วยค่าฐานนิยม (Mode)
- ข้อดี คือ เป็นวิธีที่สะดวก และไม่ Sensitive ต่อ outliers
- ต้องเป็นตัวแปรระดับ Nominal ขึ้นไป

## 4.4.1 การคำนวณสำหรับ Mode Imputation

### สูตรการหาค่าฐานนิยม

$Mode =$  ค่าที่เกิดขึ้นซ้ำกันมากที่สุด

### วิธีทำ

หาความถี่ของค่าที่ซ้ำกัน ได้ดังนี้

ปริญญาตรี = 5

ปริญญาโท = 3

ปริญญาเอก = 1

ดังนั้น ค่า **ฐานนิยม** คือ **ปริญญาตรี**

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

นำค่า **ปริญญาตรี** ไปแทนที่ค่าสูญหาย ในแถวที่ 9 คอลัมน์ “education\_level”

## 4.4.2 โค้ดไพทอนสำหรับ Mode Imputation

```
1 # Import Libraries
2 import numpy as np
3 from sklearn.impute import SimpleImputer
4
5 # Choose the imputation strategy
6 imp=SimpleImputer(missing_values=np.nan, strategy='most_frequent')
7
8 # Compute the mode value for the education level column
9 imp.fit(x[['education_level']])
10
11 # Show the computed mode value
12 print(f'Mode value: {imp.statistics_[0]}')
13
14 # Replace missing values with the computed mode value
15 x[['education_level']]=imp.transform(x[['education_level']])
16 x
17
```

✓ 0.0s

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

Mode value: ปริญญาตรี

## 4.5 KNN Imputation

- เป็นวิธีการแทนค่าข้อมูลที่สูญหายด้วย KNN ซึ่งจะพิจารณาค่าของตัวแปรจากข้อมูลที่ “ใกล้เคียงที่สุด” จำนวน  $k$  รายการ แล้วนำมาคำนวณเพื่อแทนค่าที่หายไป
- ข้อดี
  - ให้ค่าที่แทนเข้าไปมีความ "สมจริง" มากกว่า เพราะพิจารณาความคล้ายคลึงของข้อมูลรอบข้าง
  - รองรับตัวแปรทั้งแบบ Categorical (Nominal/Ordinal) และแบบ Numerical (Interval/Ratio)
- ข้อจำกัด
  - ใช้เวลาในการประมวลผลมาก เมื่อข้อมูลมีขนาดใหญ่
  - ต้องทำ Scaling ข้อมูลก่อน เพื่อป้องกันตัวแปรบางตัวมีอิทธิพลเกินไป
  - ไม่เหมาะกับข้อมูลที่มี Missing จำนวนมาก

## 4.5.1 การคำนวณสำหรับ KNN Imputation

|      | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| item |      |      |                 |            |             |
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

จากข้อมูลพบว่า มีค่าสูญหาย 2 ค่า คือ

- item 4 ในคอลัมน์ age
- item 9 ในคอลัมน์ education\_level


เป้าหมาย คือ การประมาณค่าที่สูญหาย โดยการหาค่าเฉลี่ย หรือ การโหวต (กรณีเป็นตัวแปร Nominal) จาก  $k$  แถวแรกที่มีระยะห่างน้อยที่สุด ระหว่าง **แถวที่มีค่าสูญหาย** กับ **แถวอื่น ๆ**

- แทนค่าข้อมูลสูญหายของคอลัมน์อายุ (age)

ตัดข้อมูลที่ไม่จำเป็น และ ทำการเข้ารหัสข้อมูล (Encoding) ดังนี้

- occupation มีค่าเป็นพนักงานขายทั้งหมด ซึ่งไม่สามารถแยกความแตกต่างของข้อมูล จึงตัดคอลัมน์นี้
- item ที่ 9 ของคอลัมน์ education\_level เป็นค่า NaN ไม่สามารถนำมาคำนวณได้ จึงตัดแถวนี้
- sex เป็นตัวแปรแบบ Nominal แปลงเป็นตัวเลข ได้ดังนี้ ชาย=0 หญิง=1)
- education\_level เป็นตัวแปรแบบ Ordinal แปลงเป็นตัวเลข ได้ดังนี้ ตรี=0, โท=1, เอก=2)


|      | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| item |      |      |                 |            |             |
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |



|      | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| item |      |     |                 |             |
| 1    | 25.0 | 1   | 0.0             | 4500        |
| 2    | 27.0 | 0   | 1.0             | 6200        |
| 3    | 23.0 | 0   | 0.0             | 5000        |
| 4    | NaN  | 1   | 2.0             | 8000        |
| 5    | 41.0 | 0   | 1.0             | 120000      |
| 6    | 32.0 | 1   | 0.0             | 3500        |
| 7    | 26.0 | 1   | 1.0             | 11000       |
| 8    | 22.0 | 0   | 0.0             | 8750        |
| 10   | 34.0 | 0   | 0.0             | 12000       |

## ทำการแปลงข้อมูล (Nomalization) ให้อยู่ในช่วง 0-1 ดังนี้

|      | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| item |      |     |                 |             |
| 1    | 25.0 | 1   | 0.0             | 4500        |
| 2    | 27.0 | 0   | 1.0             | 6200        |
| 3    | 23.0 | 0   | 0.0             | 5000        |
| 4    | NaN  | 1   | 2.0             | 8000        |
| 5    | 41.0 | 0   | 1.0             | 120000      |
| 6    | 32.0 | 1   | 0.0             | 3500        |
| 7    | 26.0 | 1   | 1.0             | 11000       |
| 8    | 22.0 | 0   | 0.0             | 8750        |
| 10   | 34.0 | 0   | 0.0             | 12000       |



|      | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| item |      |     |                 |             |
| 1    | 25.0 | 1.0 | 0.0             | 0.0086      |
| 2    | 27.0 | 0.0 | 0.5             | 0.0232      |
| 3    | 23.0 | 0.0 | 0.0             | 0.0129      |
| 4    | NaN  | 1.0 | 1.0             | 0.0386      |
| 5    | 41.0 | 0.0 | 0.5             | 1.0000      |
| 6    | 32.0 | 1.0 | 0.0             | 0.0000      |
| 7    | 26.0 | 1.0 | 0.5             | 0.0644      |
| 8    | 22.0 | 0.0 | 0.0             | 0.0451      |
| 10   | 34.0 | 0.0 | 0.0             | 0.0730      |

## คำนวณระยะทางระหว่าง item ที่ 4 กับ item อื่น ๆ ดังนี้

| ชุดข้อมูลทดสอบ (Test Set)  |     |                 |             |     |                                                    |         |                                           |
|----------------------------|-----|-----------------|-------------|-----|----------------------------------------------------|---------|-------------------------------------------|
| item                       | sex | education_level | total_spend | age |                                                    |         |                                           |
| 4                          | 1   | 1               | 0.0386      | ?   |                                                    |         |                                           |
| ชุดข้อมูลฝึก (Traning Set) |     |                 |             |     |                                                    |         |                                           |
| item                       | sex | education_level | total_spend | age | การคำนวณระยะทาง<br>ด้วยวิธีแบบยุคลิด               | ระยะทาง | รายการข้อมูลฝึก<br>ที่ใกล้ที่สุด 3 อันดับ |
| 1                          | 1   | 0               | 0.0086      | 25  | $\text{SQRT}((1-1)^2+(1-0)^2+(0.0386-0.0086)^2)$   | 1.0004  | x                                         |
| 2                          | 0   | 0.5             | 0.0232      | 27  | $\text{SQRT}((1-0)^2+(1-0.5)^2+(0.0386-0.0232)^2)$ | 1.1181  |                                           |
| 3                          | 0   | 0               | 0.0129      | 23  | $\text{SQRT}((1-0)^2+(1-0)^2+(0.0386-0.0129)^2)$   | 1.4144  |                                           |
| 5                          | 0   | 0.5             | 1           | 41  | $\text{SQRT}((1-0)^2+(1-0.5)^2+(0.0386-1)^2)$      | 1.4745  |                                           |
| 6                          | 1   | 0               | 0           | 32  | $\text{SQRT}((1-1)^2+(1-0)^2+(0.0386-0)^2)$        | 1.0007  | x                                         |
| 7                          | 1   | 0.5             | 0.0644      | 26  | $\text{SQRT}((1-1)^2+(1-0.5)^2+(0.0386-0.0644)^2)$ | 0.5007  | x                                         |
| 8                          | 0   | 0               | 0.0451      | 22  | $\text{SQRT}((1-0)^2+(1-0)^2+(0.0386-0.0451)^2)$   | 1.4142  |                                           |
| 10                         | 0   | 0               | 0.073       | 34  | $\text{SQRT}((1-0)^2+(1-0)^2+(0.0386-0.073)^2)$    | 1.4146  |                                           |

จากการคำนวณ พบว่า item ที่ 7, 1, และ 6 มีระยะทางใกล้เคียงกับ item ที่ 4 มากที่สุด 3 ลำดับแรก  
ดังนั้น Missing Value ใน item ที่ 4 จึงมีค่าเท่ากับ **27.67** ซึ่งคำนวณมาจากเฉลี่ย (Mean) ของ  
item 7, 1, และ 6 ในคอลัมน์ age


**หมายเหตุ :** 27.67 มาจาก  $(26 + 25 + 32) / 3$

- แทนค่าข้อมูลสูญหายของคอลัมน์ระดับการศึกษา (education\_level)

ตัดข้อมูลที่ไม่จำเป็น และ ทำการเข้ารหัสข้อมูล (Encoding) ดังนี้

- occupation มีค่าเป็นพนักงานขายทั้งหมด ซึ่งไม่สามารถแยกความแตกต่างของข้อมูล จึงตัดคอลัมน์นี้
- item ที่ 4 ของคอลัมน์ age เป็นค่า NaN ไม่สามารถนำมาคำนวณได้ จึงตัดแถวนี้
- sex เป็นตัวแปรแบบ Nominal แปลงเป็นตัวเลข ได้ดังนี้ ชาย=0 หญิง=1)


|      | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| item |      |      |                 |            |             |
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |



|      | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| item |      |     |                 |             |
| 1    | 25.0 | 1   | ปริญญาตรี       | 4500        |
| 2    | 27.0 | 0   | ปริญญาโท        | 6200        |
| 3    | 23.0 | 0   | ปริญญาตรี       | 5000        |
| 5    | 41.0 | 0   | ปริญญาโท        | 120000      |
| 6    | 32.0 | 1   | ปริญญาตรี       | 3500        |
| 7    | 26.0 | 1   | ปริญญาโท        | 11000       |
| 8    | 22.0 | 0   | ปริญญาตรี       | 8750        |
| 9    | 28.0 | 0   | NaN             | 15000       |
| 10   | 34.0 | 0   | ปริญญาตรี       | 12000       |

## ทำการแปลงข้อมูล (Nomalization) ให้อยู่ในช่วง 0-1 ดังนี้

|      | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| item |      |     |                 |             |
| 1    | 25.0 | 1   | ปริญญาตรี       | 4500        |
| 2    | 27.0 | 0   | ปริญญาโท        | 6200        |
| 3    | 23.0 | 0   | ปริญญาตรี       | 5000        |
| 5    | 41.0 | 0   | ปริญญาโท        | 120000      |
| 6    | 32.0 | 1   | ปริญญาตรี       | 3500        |
| 7    | 26.0 | 1   | ปริญญาโท        | 11000       |
| 8    | 22.0 | 0   | ปริญญาตรี       | 8750        |
| 9    | 28.0 | 0   | NaN             | 15000       |
| 10   | 34.0 | 0   | ปริญญาตรี       | 12000       |



|      | age    | sex | education_level | total_spend |
|------|--------|-----|-----------------|-------------|
| item |        |     |                 |             |
| 1    | 0.1579 | 1.0 | ปริญญาตรี       | 0.0086      |
| 2    | 0.2632 | 0.0 | ปริญญาโท        | 0.0232      |
| 3    | 0.0526 | 0.0 | ปริญญาตรี       | 0.0129      |
| 5    | 1.0000 | 0.0 | ปริญญาโท        | 1.0000      |
| 6    | 0.5263 | 1.0 | ปริญญาตรี       | 0.0000      |
| 7    | 0.2105 | 1.0 | ปริญญาโท        | 0.0644      |
| 8    | 0.0000 | 0.0 | ปริญญาตรี       | 0.0451      |
| 9    | 0.3158 | 0.0 | NaN             | 0.0987      |
| 10   | 0.6316 | 0.0 | ปริญญาตรี       | 0.0730      |

# คำนวณระยะทางระหว่าง item ที่ 9 กับ item อื่น ๆ ดังนี้

| ชุดข้อมูลทดสอบ (Test Set)  |       |     |             |                 |                                                     |         |                                           |
|----------------------------|-------|-----|-------------|-----------------|-----------------------------------------------------|---------|-------------------------------------------|
| item                       | age   | sex | total_spend | education_level |                                                     |         |                                           |
| 9                          | 0.316 | 0   | 0.0987      | ?               |                                                     |         |                                           |
| ชุดข้อมูลฝึก (Traning Set) |       |     |             |                 |                                                     |         |                                           |
| item                       | age   | sex | total_spend | education_level | การคำนวณระยะทาง<br>ด้วยวิธีแบบยุคลิด                | ระยะทาง | รายการข้อมูลฝึก<br>ที่ใกล้ที่สุด 3 อันดับ |
| 1                          | 0.158 | 1   | 0.0086      | ปริญญาตรี       | $SQRT((0.3158-0.1579)^2+(0-1)^2+(0.0987-0.0086)^2)$ | 1.0164  |                                           |
| 2                          | 0.263 | 0   | 0.0232      | ปริญญาโท        | $SQRT((0.3158-0.2632)^2+(0-0)^2+(0.0987-0.0232)^2)$ | 0.092   | x                                         |
| 3                          | 0.053 | 0   | 0.0129      | ปริญญาตรี       | $SQRT((0.3158-0.0526)^2+(0-0)^2+(0.0987-0.0129)^2)$ | 0.2768  | x                                         |
| 5                          | 1     | 0   | 1           | ปริญญาโท        | $SQRT((0.3158-1)^2+(0-0)^2+(0.0987-1)^2)$           | 1.1316  |                                           |
| 6                          | 0.526 | 1   | 0           | ปริญญาตรี       | $SQRT((0.3158-0.5263)^2+(0-1)^2+(0.0987-0)^2)$      | 1.0267  |                                           |
| 7                          | 0.211 | 1   | 0.0644      | ปริญญาโท        | $SQRT((0.3158-0.2105)^2+(0-1)^2+(0.0987-0.0644)^2)$ | 1.0061  |                                           |
| 8                          | 0     | 0   | 0.0451      | ปริญญาตรี       | $SQRT((0.3158-0)^2+(0-0)^2+(0.0987-0.0451)^2)$      | 0.3203  |                                           |
| 10                         | 0.632 | 0   | 0.073       | ปริญญาตรี       | $SQRT((0.3158-0.6316)^2+(0-0)^2+(0.0987-0.073)^2)$  | 0.3168  | x                                         |

จากการคำนวณ พบว่า item ที่ 2, 3, และ 10 มีระยะทางใกล้เคียงกับ item ที่ 9 มากที่สุด 3 ลำดับแรก  
 ดังนั้น Missing Value ใน item ที่ 9 จึงมีค่าเท่ากับ **ปริญญาตรี** ซึ่งได้จากการโหวด (Mode) ของ  
 item 2, 3, และ 10 ในคอลัมน์ education\_level

**หมายเหตุ :** ปริญญาตรี มาจาก ค่า Mode ของ {ปริญญาโท, ปริญญาตรี, ปริญญาตรี}

## 4.5.2 โค้ดไพทอนสำหรับ KNN Imputation

- การแทนค่าข้อมูลสูญหายของคอลัมน์อายุ (age)
  - เตรียมข้อมูล (ตัดข้อมูลที่ไม่จำเป็น, ทำ Encoding, และ ทำ Nomalization)

```
1 ##### เตรียมข้อมูล #####
2 import pandas as pd
3 from sklearn.preprocessing import LabelBinarizer
4 from sklearn.preprocessing import OrdinalEncoder
5 from sklearn.preprocessing import MinMaxScaler
6
7 #อ่านข้อมูลจากไฟล์ csv
8 df=pd.read_csv('data/customer2.csv')
9
10 # ตั้งค่า item เป็นดัชนีของ DataFrame
11 df.set_index('item', inplace=True)
12
13 # คัดลอกข้อมูลต้นฉบับ
14 x = df.copy()
15
16 # ลบคอลัมน์ occupation ที่เป็นค่าคงที่
17 x = x.drop(columns=['occupation'])
18
19 # ลบแถวที่มีค่าว่างในคอลัมน์ education_level
20 x = x.dropna(subset=['education_level'])
21
22 # สร้าง LabelBinarizer สำหรับแปลงข้อมูลเพศ
23 train = LabelBinarizer()
24 x['sex'] = train.fit_transform(x[['sex']])
25
26 # สร้าง OrdinalEncoder โดยกำหนดลำดับของระดับการศึกษา
27 trans = OrdinalEncoder(
28     categories=[['ปริญญาตรี','ปริญญาโท','ปริญญาเอก']])
29 x['education_level']=trans.fit_transform(x[['education_level']])
30
31 # สร้าง MinMaxScaler เพื่อปรับขนาดข้อมูลให้อยู่ในช่วง 0-1
32 x = x.astype(float) #เพื่อรองรับค่าทศนิยมที่ได้จากการ Scale
33 scaler = MinMaxScaler((0, 1))
34 trans_col = ['sex', 'education_level', 'total_spend']
35 x.loc[:, trans_col] = scaler.fit_transform(x[trans_col]).round(4)
36 x
```

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |



| item | age  | sex | education_level | total_spend |
|------|------|-----|-----------------|-------------|
| 1.0  | 25.0 | 1.0 | 0.0             | 0.0086      |
| 2.0  | 27.0 | 0.0 | 0.5             | 0.0232      |
| 3.0  | 23.0 | 0.0 | 0.0             | 0.0129      |
| 4.0  | NaN  | 1.0 | 1.0             | 0.0386      |
| 5.0  | 41.0 | 0.0 | 0.5             | 1.0000      |
| 6.0  | 32.0 | 1.0 | 0.0             | 0.0000      |
| 7.0  | 26.0 | 1.0 | 0.5             | 0.0644      |
| 8.0  | 22.0 | 0.0 | 0.0             | 0.0451      |
| 10.0 | 34.0 | 0.0 | 0.0             | 0.0730      |

- คำนวณค่าที่จะนำไปแทนค่าอายุที่สูญหาย

```
1 ##### KNN Imputation #####
2 from sklearn.neighbors import NearestNeighbors
3
4 # เลือกตัวแปรตามและตัวแปรต้น
5 y = x[['age']]
6 X = x.drop(columns=['age'])
7
8 # เลือก training set และ test set
9 item = 4
10 x_train = X[X.index != item]
11 y_train = y[y.index != item]
12
13 x_test = X[X.index == item]
14 y_test = y[y.index == item]
15
16 # คำนวณหาระยะทางระหว่าง training set และ test set
17 net = NearestNeighbors(n_neighbors = 3, metric = 'minkowski', p = 2)
18 net.fit(x_train,y_train)
19 dist, index = net.kneighbors(x_test)
20
21 # ประมาณค่าสูญหาย จากค่าเฉลี่ยของ 3 รายการแรกที่มีระยะทางใกล้ที่สุด
22 new_age_value = x['age'][x_train.index[index[0]].tolist()].mean().round(2)
23
24 # แสดงผลลัพธ์
25 print(f'Distance : {dist.round(4)}')
26 print(f'Index :{x_train.index[index[0]].tolist()}')
27 print(f'New Age Value : {new_age_value}')
```

Distance : `[[0.5007 1.0004 1.0007]]`

Index :`[7, 1, 6]`

New Age Value : `27.67`

ค่าที่จะนำไปแทนค่าสูญหายคือ **27.67** อย่างไรก็ตาม  
ค่านี้จะถูกเก็บไว้ก่อน เพื่อแทนค่าสูญหายในขั้น  
ตอนสุดท้าย

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

- การแทนค่าข้อมูลสูญหายของคอลัมน์ระดับการศึกษา (education\_level)

- เตรียมข้อมูล (ตัดข้อมูลที่ไม่จำเป็น, ทำ Encoding, และ ทำ Nomalization)

```

1 ##### เตรียมข้อมูล #####
2 # คัดลอกข้อมูลต้นฉบับ
3 x = df.copy()
4
5 # ลบคอลัมน์ occupation ที่เป็นค่าคงที่
6 x = x.drop(columns=['occupation'])
7
8 # ลบแถวที่มีค่าว่างในคอลัมน์ age
9 x = x.dropna(subset=['age'])
10
11 # สร้าง LabelBinarizer สำหรับแปลงข้อมูลเพศ
12 train = LabelBinarizer()
13 x['sex'] = train.fit_transform(x[['sex']])
14
15 # เพื่อรองรับค่าทศนิยมที่ได้จากการ Scale
16 trans_col = ['age', 'sex', 'total_spend']
17 x[trans_col] = x[trans_col].astype(float)
18
19 # สร้าง MinMaxScaler เพื่อปรับขนาดข้อมูลให้อยู่ในช่วง 0-1
20 scaler = MinMaxScaler((0, 1))
21 x.loc[:, trans_col] = scaler.fit_transform(x[trans_col]).round(4)
22 x

```

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |



|      | age    | sex | education_level | total_spend |
|------|--------|-----|-----------------|-------------|
| item |        |     |                 |             |
| 1    | 0.1579 | 1.0 | ปริญญาตรี       | 0.0086      |
| 2    | 0.2632 | 0.0 | ปริญญาโท        | 0.0232      |
| 3    | 0.0526 | 0.0 | ปริญญาตรี       | 0.0129      |
| 5    | 1.0000 | 0.0 | ปริญญาโท        | 1.0000      |
| 6    | 0.5263 | 1.0 | ปริญญาตรี       | 0.0000      |
| 7    | 0.2105 | 1.0 | ปริญญาโท        | 0.0644      |
| 8    | 0.0000 | 0.0 | ปริญญาตรี       | 0.0451      |
| 9    | 0.3158 | 0.0 | NaN             | 0.0987      |
| 10   | 0.6316 | 0.0 | ปริญญาตรี       | 0.0730      |

- คำนวณค่าที่จะนำไปแทนค่าระดับการศึกษาที่สูญหาย

```
1 ##### KNN Imputation #####
2 from sklearn.neighbors import NearestNeighbors
3
4 # เลือกตัวแปรตามและตัวแปรต้น
5 y = x[['education_level']]
6 X = x.drop(columns=['education_level'])
7
8 # เลือก training set และ test set
9 item = 9
10 x_train = X[X.index != item]
11 y_train = y[y.index != item]
12
13 x_test = X[X.index == item]
14 y_test = y[y.index == item]
15
16 # คำนวณหาระยะทางระหว่าง training set และ test set
17 net = NearestNeighbors(n_neighbors = 3, metric = 'minkowski', p = 2)
18 net.fit(x_train,y_train)
19 dist, index = net.kneighbors(x_test)
20
21 # ประมาณค่าสูญหาย จากค่า Mode ของ 3 รายการแรกที่มีระยะทางใกล้ที่สุด
22 new_education_level = x['education_level'][x_train.index[index[0]].tolist()].mode()[0]
23
24 # แสดงผลลัพธ์
25 print(f'Distance : {dist.round(4)}')
26 print(f'Index :{x_train.index[index[0]].tolist()}')
27 print(f'New Value : {new_education_level}')
```

Distance : `[[0.092 0.2768 0.3168]]`

Index :`[2, 3, 10]`

New Value : `ปริญญาตรี`

ค่าที่จะนำไปแทนค่าสูญหายคือ **ปริญญาตรี**

| item | age  | sex  | education_level | occupation | total_spend |
|------|------|------|-----------------|------------|-------------|
| 1    | 25.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | NaN  | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.0 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.0 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.0 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.0 | ชาย  | NaN             | พนักงานขาย | 15000       |
| 10   | 34.0 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

- แทนค่าในคอลัมน์ **อายุ** และ **ระดับการศึกษา** พร้อมกัน

```
1 # แทนค่าสูญหาย ด้วยค่าที่เหมาะสมได้
2 df.loc[4, 'age'] = new_age_value
3 df.loc[9, 'education_level'] = new_education_level
4 df
```

✓ 0.0s

|      | age   | sex  | education_level | occupation | total_spend |
|------|-------|------|-----------------|------------|-------------|
| item |       |      |                 |            |             |
| 1    | 25.00 | หญิง | ปริญญาตรี       | พนักงานขาย | 4500        |
| 2    | 27.00 | ชาย  | ปริญญาโท        | พนักงานขาย | 6200        |
| 3    | 23.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 5000        |
| 4    | 27.67 | หญิง | ปริญญาเอก       | พนักงานขาย | 8000        |
| 5    | 41.00 | ชาย  | ปริญญาโท        | พนักงานขาย | 120000      |
| 6    | 32.00 | หญิง | ปริญญาตรี       | พนักงานขาย | 3500        |
| 7    | 26.00 | หญิง | ปริญญาโท        | พนักงานขาย | 11000       |
| 8    | 22.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 8750        |
| 9    | 28.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 15000       |
| 10   | 34.00 | ชาย  | ปริญญาตรี       | พนักงานขาย | 12000       |

## 4.6 แบบฝึกหัด

1. จากข้อมูลที่กำหนดให้ จงตอบคำถามเกี่ยวกับการแทนค่าสูญหาย ดังนี้

| คนที่ | อายุ | เพศ  | ระดับการศึกษา | อาชีพ        | เงินเดือน |
|-------|------|------|---------------|--------------|-----------|
| 1     | 28   | หญิง | ปริญญาตรี     | พนักงานขาย   | 25,000    |
| 2     | 22   | ชาย  |               | พนักงานขาย   | 18,000    |
| 3     | 25   | ชาย  | ปริญญาตรี     | พนักงานบัญชี | 23,000    |
| 4     | 30   | หญิง | ปริญญาเอก     | พนักงานขาย   | 40,000    |
| 5     | 26   | ชาย  | ปริญญาโท      | พนักงานบัญชี | 27,000    |
| 6     | 45   | หญิง | ปริญญาตรี     | พนักงานบัญชี | 35,000    |
| 7     | 25   | หญิง | ปริญญาโท      |              | 25,000    |
| 8     | 28   | ชาย  | ปริญญาเอก     | พนักงานขาย   | 39,000    |
| 9     | 27   | ชาย  | ปริญญาตรี     | พนักงานขนส่ง | 25,000    |
| 10    |      | ชาย  | ปริญญาตรี     | พนักงานขาย   | 32,000    |

1.1 แสดงการคำนวณ Mean และ Median Imputations สำหรับคอลัมน์ **อายุ**

1.2 แสดงการคำนวณ Mode Imputation สำหรับคอลัมน์ **ระดับการศึกษา**

1.3 แสดงการคำนวณ KNN Imputation เมื่อ  $k = 3$  สำหรับคอลัมน์ **อาชีพ**

1.4 เขียนโปรแกรมเพื่อจัดการ Missing Values ด้วยวิธีการตามข้อ 1-3

2. จากข้อมูลที่กำหนดให้ จงตอบคำถามเกี่ยวกับการแทนค่าสูญหาย ดังนี้

|    | Age  | Gender | FavoriteColor | SatisfactionLevel |
|----|------|--------|---------------|-------------------|
| ID |      |        |               |                   |
| 1  | 25.0 | Male   | Blue          | Medium            |
| 2  | 31.0 | Female | NaN           | High              |
| 3  | NaN  | Female | Green         | Medium            |
| 4  | 29.0 | Male   | Blue          | Low               |
| 5  | 40.0 | Male   | Red           | High              |
| 6  | 22.0 | Female | Yellow        | Medium            |
| 7  | 36.0 | Male   | Green         | NaN               |
| 8  | NaN  | Female | Red           | Medium            |
| 9  | 28.0 | Female | Blue          | Low               |
| 10 | 33.0 | Male   | Yellow        | High              |

2.1 ระบุค่าที่ต้องไปแทนที่ Missing Value ใน คอลัมน์ "Age" จาก Mean Imputation (จุดทศนิยม 2 ตำแหน่ง)

2.2 ระบุค่าที่ต้องไปแทนที่ Missing Value ใน คอลัมน์ "Age" จาก Median Imputation (จุดทศนิยม 2 ตำแหน่ง)

2.3 ระบุค่าที่ต้องไปแทนที่ Missing Value ใน คอลัมน์ "SatisfactionLevel" จาก Median Imputation

2.4 ระบุค่าที่ต้องไปแทนที่ Missing Value ใน คอลัมน์ "FavoriteColor" จาก Mode Imputation

- 2.5 ระบุค่าที่ต้องไปแทนที่ Missing Value ใน คอลัมน์ "SatisfactionLevel" จาก Mode Imputation
- 2.6 ในการคำนวณ KNN Imputation เมื่อ  $k = 3$  เพื่อแทนค่าสูญหายใน ID ที่ 2 คอลัมน์ "FavoriteColor" จงระบุระยะทางที่ใกล้เคียงที่สุดอันดับ 1 (จุดทศนิยม 2 ตำแหน่ง)
- 2.7 ในการคำนวณ KNN Imputation เมื่อ  $k = 3$  เพื่อแทนค่าสูญหายใน ID ที่ 2 คอลัมน์ "FavoriteColor" จงระบุระยะทางที่ใกล้เคียงที่สุดอันดับ 2 (จุดทศนิยม 2 ตำแหน่ง)
- 2.8 ในการคำนวณ KNN Imputation เมื่อ  $k = 3$  เพื่อแทนค่าสูญหายใน ID ที่ 2 คอลัมน์ "FavoriteColor" จงระบุระยะทางที่ใกล้เคียงที่สุดอันดับ 3 (จุดทศนิยม 2 ตำแหน่ง)
- 2.9 ในการคำนวณ KNN Imputation เมื่อ  $k = 3$  เพื่อแทนค่าสูญหายใน ID ที่ 2 คอลัมน์ "FavoriteColor" จงระบุค่าที่จะนำไปแทนที่ค่าสูญหาย
- 2.10 การแทนค่าสูญหายในคอลัมน์ "SatisfactionLevel" ไม่ควรใช้วิธี \_\_\_\_\_ Imputation



# THANK YOU FOR YOUR ATTENTION

 [pichai\\_jo@rmutto.ac.th](mailto:pichai_jo@rmutto.ac.th)

