



บทที่ 6

การตรวจหาค่าผิดปกติ

- ✓ 6.1 แนะนำการตรวจหาค่าผิดปกติ
- ✓ 6.2 Z-Score Outlier Detection
- ✓ 6.3 IQR Outlier Detection
- ✓ 6.4 Local Outlier Factor
- ✓ 6.5 Outlier Handling
- ✓ 6.6 แบบฝึกหัด


6.1 แนะนำการตรวจหาค่าผิดปกติ

- การตรวจหาค่าผิดปกติ (Outlier Detection) คือ การค้นหาค่าที่มีพฤติกรรมแตกต่างจากข้อมูลส่วนใหญ่ เช่น ค่าที่สูงหรือต่ำผิดปกติ หรือ จุดข้อมูลที่มีการกระจายตัวผิดปกติ ซึ่งช่วยเพิ่มคุณภาพของข้อมูลก่อนนำไปใช้วิเคราะห์หรือสร้างโมเดล
- ตัวอย่างเทคนิคของการตรวจหาค่าผิดปกติ มีดังนี้
 - Z-Score Outlier Detection
 - IQR Outlier Detection
 - Local Outlier Factor

6.2 Z-Score Outlier Detection

- เป็นวิธีที่เรียบง่าย
- คำนวณได้เร็ว เหมาะสำหรับชุดข้อมูลขนาดใหญ่
- ใช้ค่า Z-Score เพื่อบอกว่าค่าหนึ่ง ๆ แตกต่างจากค่าเฉลี่ยมากน้อยแค่ไหน เมื่อเทียบกับความกระจายของข้อมูล
- มักใช้เกณฑ์ $|z| > 2.5$ หรือ 3 เพื่อระบุ Outliers
- เหมาะกับข้อมูลที่มีการกระจายตัวใกล้เคียง Normal Distribution

The Normal Distribution



$$z = \frac{x - \mu}{\sigma}$$

เมื่อ

z = ค่า z - score

x = ข้อมูลแต่ละจุด

μ = ค่าเฉลี่ย

σ = ส่วนเบี่ยงเบนมาตรฐาน

6.2.1 การคำนวณสำหรับ Z-Score Outlier Detection

สูตรการคำนวณ

$$z = \frac{x - \mu}{\sigma}$$

เมื่อ

z = ค่า z - score

x = ข้อมูลแต่ละจุด

μ = ค่าเฉลี่ย

σ = ส่วนเบี่ยงเบนมาตรฐาน

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

ถ้า $|z| > 2.5$ or 3 จะพิจารณาว่าข้อมูลนั้นเป็นข้อมูลผิดปกติ (Outlier)

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงหา Outliers ด้วยวิธี Z-Score Outlier Detection

$x = [4500, 6200, 5000, 8000, 120000, 3500, 11000, 8750, 15000, 12000]$

วิธีทำ

จาก $z = \frac{x - \mu}{\sigma}$

$$\mu = 19,395$$

$$\sigma = 33,711.78$$

เมื่อ $x = 4,500$ จะได้

$$z = \frac{4,500 - 19,395}{33,711.78}$$

$$z = -0.44$$

$$|z| = 0.44$$

เมื่อ $x = 6,200$ จะได้

$$z = \frac{6,200 - 19,395}{33,711.78}$$

$$z = -0.39$$

$$|z| = 0.39$$

.....

เมื่อ $x = 12,000$ จะได้

$$z = \frac{12,000 - 19,395}{33,711.78}$$

$$z = -0.22 \quad |z| = 0.22$$

ค่า $|z|$ ทั้งหมด คือ 0.44, 0.39, 0.43, 0.34, **2.98**, 0.47, 0.25, 0.32, 0.13, 0.22

ตอบ Outlier คือ 120,0000 หรือ ข้อมูล ณ รายการที่ 5

item	age	sex	education_level	occupation	total_spend	z-score
1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500	0.44
2	27	ชาย	ปริญญาโท	พนักงานบัญชี	6200	0.39
3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000	0.43
4	35	หญิง	ปริญญาเอก	พนักงานบุคคล	8000	0.34
5	41	ชาย	ปริญญาโท	พนักงานบัญชี	120000	2.98
6	32	หญิง	ปริญญาตรี	พนักงานบัญชี	3500	0.47
7	26	หญิง	ปริญญาโท	พนักงานขาย	11000	0.25
8	22	ชาย	ปริญญาตรี	พนักงานบุคคล	8750	0.32
9	28	ชาย	ปริญญาตรี	พนักงานบุคคล	15000	0.13
10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000	0.22

6.2.2 โค้ดไพทอนสำหรับ Z-Score Outlier Detection

```
1 #Import libraries
2 import pandas as pd
3 import numpy as np
4 from sklearn.preprocessing import StandardScaler
5
6 #Load data
7 x = pd.read_csv('data/customer3.csv')
8
9 #Detect outliers with Z-score
10 trans=StandardScaler()
11 zscore=np.abs(trans.fit_transform(x[['total_spend']])).round(2)
12 outlier_index = np.where(zscore > 2.5)[0]
13 outlier_value = zscore[outlier_index][0].round(2)
14
15 #Display outliers
16 print("Detected outliers using Z-score method:")
17 print(f"Item: {outlier_index + 1}")
18 print(f"|Z-Score|: {outlier_value.tolist()}")
19 x['|z-score|']=zscore.round(2)
20 x
```

Detected outliers using Z-score method:

Item: [5]




|Z-Score|: [2.98]

item	age	sex	education_level	occupation	total_spend	z-score
1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500	0.44
2	27	ชาย	ปริญญาโท	พนักงานบัญชี	6200	0.39
3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000	0.43
4	35	หญิง	ปริญญาเอก	พนักงานบุคคล	8000	0.34
5	41	ชาย	ปริญญาโท	พนักงานบัญชี	120000	2.98
6	32	หญิง	ปริญญาตรี	พนักงานบัญชี	3500	0.47
7	26	หญิง	ปริญญาโท	พนักงานขาย	11000	0.25
8	22	ชาย	ปริญญาตรี	พนักงานบุคคล	8750	0.32
9	28	ชาย	ปริญญาตรี	พนักงานบุคคล	15000	0.13
10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000	0.22

6.3 IQR Outlier Detection

- เป็นวิธีที่เรียบง่าย
- ใช้ค่า IQR (Interquartile Range) ในการวัดการกระจายตัวของข้อมูล โดย $IQR = Q_3 - Q_1$
- ระบุเป็น Outliers เมื่อ
ข้อมูลมีค่า $< Q_1 - 1.5 \times IQR$ หรือ มีค่า $> Q_3 + 1.5 \times IQR$
- ใช้ได้ดีแม้ว่าข้อมูลมีรูปแบบการแจกแจงแบบเบ้ (Skewed) หรือ การแจกแจงแบบไม่ปกติ (Non-Normal Distribution)

The Normal Distribution



6.3.1 การคำนวณสำหรับ IQR Outlier Detection

สูตรการคำนวณ

- เรียงข้อมูลจากน้อยไปหามาก
- คำนวณ Q_1 (25 percentile) และ Q_3 (75 percentile) โดยที่

$$Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)})$$

$$k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots \quad \text{บางทฤษฎีคำนวณค่า } k \text{ จากสมการ } k = \lfloor p(n+1) \rfloor, k = 1, 2, 3, \dots$$

$$h = \{p(n-1)\}$$

เมื่อ Q_p = ค่าควอร์ไทล์ ในสัดส่วน percentile
นั่นคือ $Q_1 = Q_{0.25}$, $Q_2 = Q_{0.5}$, $Q_3 = Q_{0.75}$

$x_{(k)}$ = ค่าของข้อมูลลำดับที่ k

$x_{(k+1)}$ = ค่าของข้อมูลลำดับที่ $k+1$

h = ตัวเลขหลังจุดทศนิยม (Fractional Part) จากการคำนวณ $p(n-1)$

- คำนวณ IQR โดยที่ $IQR = Q_3 - Q_1$

- คำนวณ Lower Bound (LB) และ Upper Bound (UB) แล้ว ระบุข้อมูลที่มีค่า น้อยกว่า LB หรือ สูงกว่า UB เป็น Outliers

$$\text{Lower Bound} = Q_1 - 1.5 \times IQR$$

$$\text{Upper Bound} = Q_3 + 1.5 \times IQR$$

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงหา Outliers ด้วยวิธี IQR Outlier Detection

$x = [4500, 6200, 5000, 8000, 120000, 3500, 11000, 8750, 15000, 12000]$

วิธีทำ

1. เรียงข้อมูลจากน้อยไปหามาก ได้ดังนี้

$x_{\text{sort}} = [3500, 4500, 5000, 6200, 8000, 8750, 11000, 12000, 15000, 120000]$

2. คำนวณ Q_1 และ Q_3 ดังนี้

คำนวณ Q_1 (25 percentile)

จาก $Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)})$ และ $k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots$

จะได้ $p = 0.25$

$$p(n-1) = 0.25(10-1) = 2.25$$

$k = 2$ เมื่อ k เริ่มต้นที่ 0

$$h = 0.25$$

$$x_{(k)} = 5,000$$

$$x_{(k+1)} = 6,200$$

$$Q_1 = 5,000 + (0.25)(6,200 - 5,000)$$

$$Q_1 = 5,000 + 300 = 5,300$$

คำนวณ Q_3 (75 percentile)

จาก $Q_p = x_{(k)} + (h)(x_{(k+1)} - x_{(k)})$ และ $k = \lfloor p(n-1) \rfloor, k = 0, 1, 2, \dots$

จะได้ $p = 0.75$

$$p(n-1) = 0.75(10-1) = 6.75$$

$k = 6$ เมื่อ k เริ่มต้นที่ 0

$$h = 0.75$$

$$x_{(k)} = 11,000$$

$$x_{(k+1)} = 12,000$$

$$Q_3 = 11,000 + (0.75)(12,000 - 11,000)$$

$$Q_3 = 11,000 + 750 = 11,750$$

3. คำนวณ IQR ดังนี้

$$\text{IQR} = 11,750 - 5,300 = 6,450$$

4. ระบุข้อมูลที่มีค่าน้อยกว่า Lower Bound หรือ สูงกว่า Upper Bound เป็น Outliers

$$\text{Lower Bound} = 5,300 - 1.5 \times 6,450 = -4,375$$

$$\text{Upper Bound} = 11,750 + 1.5 \times 6,450 = 21,425$$

$$x = [4500, 6200, 5000, 8000, \text{120000}, 3500, 11000, 8750, 15000, 12000]$$

ตอบ Outlier คือ 120,0000 หรือ ข้อมูล ณ รายการที่ 5

6.3.2 โค้ดไพทอนสำหรับ IQR Outlier Detection

```
1 #Import libraries
2 import pandas as pd
3 import numpy as np
4
5 #Load data
6 df = pd.read_csv('data/customer3.csv')
7 x = df['total_spend']
8
9 # Compute IQR
10 q1 = np.quantile(x, 0.25)
11 q3 = np.quantile(x, 0.75)
12 iqr = q3 - q1
13
14 # Compute lower and upper bounds
15 lower = q1 - 1.5 * iqr
16 upper = q3 + 1.5 * iqr
17
18 # Detect outliers
19 outlier_index_lower = np.where(x < lower)[0]
20 outlier_index_upper = np.where(x > upper)[0]
21
22 # Display outliers
23 print("Detected outliers using IQR method:")
24 print(f"IQR: {iqr}")
25 print(f"Lower bound: {lower}")
26 print(f"Upper bound: {upper}")
27 print(f"Item (lower): {outlier_index_lower + 1}")
28 print(f"Item (upper): {outlier_index_upper + 1}")
```

Detected outliers using IQR method:

IQR: 6450.0

Lower bound: -4375.0

upper bound: 21425.0

Item (lower): []

Item (upper): [5]

item	age	sex	education_level	occupation	total_spend
1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500
2	27	ชาย	ปริญญาโท	พนักงานบัญชี	6200
3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000
4	35	หญิง	ปริญญาเอก	พนักงานบุคคล	8000
5	41	ชาย	ปริญญาโท	พนักงานบัญชี	120000
6	32	หญิง	ปริญญาตรี	พนักงานบัญชี	3500
7	26	หญิง	ปริญญาโท	พนักงานขาย	11000
8	22	ชาย	ปริญญาตรี	พนักงานบุคคล	8750
9	28	ชาย	ปริญญาตรี	พนักงานบุคคล	15000
10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000

6.4 Local Outlier Factor

- ใช้แนวคิด การเปรียบเทียบความหนาแน่นของข้อมูลแต่ละจุด (Local Density) เทียบกับ ความหนาแน่นของเพื่อนบ้าน (k -NN)
ถ้าจุดข้อมูลมีความหนาแน่น "ต่ำกว่าเพื่อนบ้านมาก" ระบบจะมองว่าเป็น Outlier เพราะถือว่าข้อมูลนั้น "โดดเดี่ยวผิดปกติ"
- การคำนวณซับซ้อนกว่าวิธี Z-Score และ IQR
- พิจารณาหลายตัวแปรพร้อมกัน ซึ่งต่างจาก วิธี Z-Score และ IQR
- ใช้ได้ดีแม้ว่าข้อมูลมีรูปแบบการแจกแจงแบบเบ้ (Skewed) หรือ การแจกแจงแบบไม่ปกติ (Non-Normal Distribution)

6.4.1 Local Outlier Factor

สูตรการคำนวณ

1. คำนวณ ระยะทางที่เข้าถึงได้ (Reachability Distance)

$$\text{reach-distance}_k(p, o) = \max(\text{distance}_k(o), d(p, o)), \forall o \in N_k(p)$$

โดยที่ $\text{reach-distance}_k(p, o)$ คือ ระยะทางที่สามารถเข้าถึงจุด p ได้ จากจุด o

$d(p, o)$ คือ ระยะทางระหว่างจุด p และ จุด o

$\text{distance}_k(o)$ คือ ระยะทางจาก จุด o ไปยังเพื่อนบ้านที่อยู่ใกล้ที่สุดลำดับที่ k

$N_k(p) = \{o_1, o_2, \dots, o_k\}$ คือ เซตของเพื่อนบ้าน p ที่ใกล้เคียงที่สุดใน k จุด

2. คำนวณ ความหนาแน่นที่เข้าถึงได้ท้องถิ่น (Local Reachability Density: LRD)

$$\text{lrd}_k(p) = \frac{|N_k(p)|}{\sum_{o \in N_k(p)} \text{reach-distance}_k(p, o)}$$

โดยที่ $\text{lrd}_k(p)$ คือ ความหนาแน่นของจุด p ที่เพื่อนบ้านที่ใกล้เคียงที่สุด k จุดสามารถเข้าถึงได้

$|N_k(p)|$ คือ จำนวนจุดข้อมูลในเซตของเพื่อนบ้าน p ที่ใกล้เคียงที่สุด k จุด
ซึ่งอาจมากกว่า k เนื่องจากมีเพื่อนบ้านบางจุดที่ระยะทางเท่ากัน

3. คำนวณ ค่าผิดปกติท้องถิ่น (Local Outlier Factor: LOF)

$$\text{LOF}_k(p) = \frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \frac{\text{lrd}_k(o)}{\text{lrd}_k(p)}$$

โดยที่ $\text{LOF}_k(A)$ คือ ค่า Local Outlier Factor

ค่า $\text{LOF}_k(p) > 1$ หมายความว่าจุด p มีความหนาแน่นต่ำกว่าเพื่อนบ้าน ซึ่งอาจพิจารณาเป็น Outliers ได้

ทั้งนี้ ไม่มีกฎเกณฑ์ที่แน่ชัด ในบางกรณีอาจพิจารณาเป็น %

เช่น พิจารณาเป็น Outliers เมื่อ จุดข้อมูลมีค่า LOF มากที่สุด อยู่ใน 10% แรก จากข้อมูลทั้งหมด

6.4.2 โค้ดไพทอนสำหรับ Local Outlier Factor

```
1 #Import libraries
2 import pandas as pd
3 from sklearn.preprocessing import LabelBinarizer
4 from sklearn.preprocessing import OrdinalEncoder
5 from sklearn.preprocessing import OneHotEncoder
6 from sklearn.preprocessing import MinMaxScaler
7 from sklearn.neighbors import LocalOutlierFactor
8
9 #Load data
10 x = pd.read_csv('data/customer3.csv')
11
12 #Transform data with LabelBinarizer
13 train = LabelBinarizer()
14 x['sex'] = train.fit_transform(x[['sex']])
15
16 #Transform data with OrdinalEncoder
17 categories = ['ปริญญาตรี', 'ปริญญาโท', 'ปริญญาเอก']
18 trans = OrdinalEncoder(categories=[categories])
19 x['education_level'] = trans.fit_transform(x[['education_level']])
20
21 #Transform data with OrdinalEncoder
22 trans = OneHotEncoder()
23 x[categories] = trans.fit_transform(x[['occupation']]).toarray()
24 x = x.drop(columns=['occupation'])
25
26 #Transform data with MinMaxScaler
27 trans = MinMaxScaler((0, 1))
28 trans_col = ['age', 'education_level', 'total_spend']
29 x[trans_col] = trans.fit_transform(x[trans_col]).round(2)
30
31 #Detect outliers with LOF
32 lof = LocalOutlierFactor(n_neighbors=5, contamination=0.1) #outlier 10%
33 outlier_label = lof.fit_predict(x.loc[:, 'age':])
34 print(f"LOF: {(lof.negative_outlier_factor_*-1).round(4)}")
35 x["is_outlier"] = (outlier_label == -1) #1 = inlier, -1 = outlier
36 x
```

item	age	sex	education_level	total_spend	ปริญญาตรี	ปริญญาโท	ปริญญาเอก	is_outlier
1	0.16	1	0.0	0.01	1.0	0.0	0.0	False
2	0.26	0	0.5	0.02	0.0	1.0	0.0	False
3	0.05	0	0.0	0.01	1.0	0.0	0.0	False
4	0.68	1	1.0	0.04	0.0	0.0	1.0	False
5	1.00	0	0.5	1.00	0.0	1.0	0.0	True
6	0.53	1	0.0	0.00	0.0	1.0	0.0	False
7	0.21	1	0.5	0.06	1.0	0.0	0.0	False
8	0.00	0	0.0	0.05	0.0	0.0	1.0	False
9	0.32	0	0.0	0.10	0.0	0.0	1.0	False
10	0.63	0	0.0	0.07	1.0	0.0	0.0	False

6.5 Outlier Handling

- Outlier Handling ດ້ວຍ ການລຸບທັງແຄວ
- Outlier Handling ດ້ວຍ Missing Value Imputaion

6.5.1 Outlier Handling ด้วย การลบทิ้งแถว

```
1 #Import libraries
2 import pandas as pd
3 import numpy as np
4 from sklearn.preprocessing import StandardScaler
5
6 #Load data
7 x = pd.read_csv('data/customer3.csv')
8
9 #Detect outliers with Z-score
10 trans=StandardScaler()
11 zscore=trans.fit_transform(x[['total_spend']]).round(2)
12 outlier_index = np.where(zscore > 2.5)[0]
13 outlier_value = zscore[outlier_index][0].round(2)
14
15 #Display outliers
16 print("Detected outliers using Z-score method:")
17 print(f"Item: {outlier_index + 1}")
18 print(f"|Z-Score|: {outlier_value.tolist()}")
19
20 #Outlier handling with the row deletion
21 x = x.drop(outlier_index)
22 x
```

	item	age	sex	education_level	occupation	total_spend
0	1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500
1	2	27	ชาย	ปริญญาโท	พนักงานบัญชี	6200
2	3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000
3	4	35	หญิง	ปริญญาเอก	พนักงานบุคคล	8000
5	6	32	หญิง	ปริญญาตรี	พนักงานบัญชี	3500
6	7	26	หญิง	ปริญญาโท	พนักงานขาย	11000
7	8	22	ชาย	ปริญญาตรี	พนักงานบุคคล	8750
8	9	28	ชาย	ปริญญาตรี	พนักงานบุคคล	15000
9	10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000

Detected outliers using Z-score method:

Item: [5]

|Z-Score|: [2.98]

6.5.2 Outlier Handling ด้วย Missing Value Imputation

```
1 #Import libraries
2 import pandas as pd
3 import numpy as np
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.impute import SimpleImputer
6
7 #Load data
8 x = pd.read_csv('data/customer3.csv')
9
10 #Compute Z-score
11 trans=StandardScaler()
12 zscore=trans.fit_transform(x[['total_spend']]).round(2)
13 #Detect outliers with Z-score
14 outlier_index = np.where(zscore > 2.5)[0]
15 outlier_value = zscore[outlier_index][0].round(2)
16
17 #Outlier handling with the missing value imputation
18 x.loc[outlier_index,'total_spend']=np.nan
19 imp=SimpleImputer(missing_values=np.nan, strategy='mean')
20 x[['total_spend']]=imp.fit_transform((x[['total_spend']])).round(2)
21 x
```

item	age	sex	education_level	occupation	total_spend
1	25	หญิง	ปริญญาตรี	พนักงานขาย	4500.00
2	27	ชาย	ปริญญาโท	พนักงานบัญชี	6200.00
3	23	ชาย	ปริญญาตรี	พนักงานขาย	5000.00
4	35	หญิง	ปริญญาเอก	พนักงานบุคคล	8000.00
5	41	ชาย	ปริญญาโท	พนักงานบัญชี	8216.67
6	32	หญิง	ปริญญาตรี	พนักงานบัญชี	3500.00
7	26	หญิง	ปริญญาโท	พนักงานขาย	11000.00
8	22	ชาย	ปริญญาตรี	พนักงานบุคคล	8750.00
9	28	ชาย	ปริญญาตรี	พนักงานบุคคล	15000.00
10	34	ชาย	ปริญญาตรี	พนักงานขาย	12000.00

6.6 แบบฝึกหัด

จากข้อมูลที่กำหนดให้ จงทำการค้นหา Outliers ด้วยวิธีต่อไปนี้

- วิธี Z-Score Outlier Detection สำหรับคอลัมน์ salary
- วิธี IQR Outlier Detection สำหรับคอลัมน์ age

item	age	salary	department	score	city	education_level
1	25	32,000	Sales	78	Bangkok	Bachelor
2	28	35,000	IT	82	Chiangmai	Bachelor
3	31	40,000	HR	88	Bangkok	Master
4	29	36,500	Sales	75	Phuket	High School
5	45	120,000	IT	90	Bangkok	Master
6	22	28,000	HR	72	Bangkok	High School
7	27	34,000	Sales	79	Khon Kaen	Bachelor
8	30	38,000	IT	85	Bangkok	Master
9	102	33,500	HR	5	Chiangmai	High School
10	26	31,000	Sales	81	Bangkok	Bachelor
11	24	500,000	IT	77	Phuket	PhD
12	29	37,500	HR	84	Bangkok	Bachelor



THANK YOU FOR YOUR ATTENTION

 pichai_jo@rmutto.ac.th

