



บทที่ 7

วิศวกรรมคุณลักษณะ

- ✓ 7.1 แนะนำวิศวกรรมคุณลักษณะ
- ✓ 7.2 Feature Selection
- ✓ 7.3 Feature Extraction
- ✓ 7.4 แบบฝึกหัด

7.1 แนะนำวิศวกรรมคุณลักษณะ

- วิศวกรรมคุณลักษณะ (Feature Engineering) คือ กระบวนการออกแบบ ปรับปรุง และเตรียมคุณลักษณะ (Features) จากข้อมูลดิบ เพื่อให้เหมาะสมต่อการนำไปใช้ในการสร้างโมเดล Machine Learning (ML)
- เทคนิค วิศวกรรมคุณลักษณะ มีดังนี้
 - Feature Selection
 - Feature Extraction
 - Feature Transformation
 - Feature Creation

7.2 Feature Selection

- เป็นการเลือกเอาเฉพาะปัจจัย (Features/Factors) หรือ ตัวแปรต้น (Independent Variables) ที่จำเป็นต่อการสร้างโมเดล
- ช่วยลดความซับซ้อน (Complexity) ของโมเดล
- ช่วยลดเวลา (Training Time) ในการ Train โมเดล
- (อาจจะ) ช่วยเพิ่มประสิทธิผล (Effectiveness) ของโมเดล
- เทคนิคการเลือกปัจจัย มีดังนี้
 - Filter Method
 - Wrapper Method
 - Embedded Method

7.2.1 Filter Method

- เป็นวิธี ที่ไม่เจาะจงกับเทคนิคของ ML ใด เทคนิคหนึ่ง
 - ซึ่งทำให้มีโอกาสเกิดปัญหา Overfitting น้อยกว่า Wrapper Method
 - แต่ อาจทำให้ Model มีประสิทธิภาพน้อยกว่าวิธีที่เจาะจงกับเทคนิคของ ML เช่น Wrapper และ Embedded Method
- มักใช้เวลาน้อยกว่า Wrapper Method
- เทคนิค Filter Method มีดังนี้
 - Variance
 - Pearson Correlation's Coefficient
 - Chi-Square Test
 - Mutual Information
- เทคนิค การเลือก มีดังนี้
 - กำหนด Threshold : เช่น เลือก Features ที่มี score > 1 (หรือ < 1)
 - กำหนด Top-K features : เช่น เลือก 10 Features แรก ที่มี score มากที่สุด (หรือ น้อยที่สุด)
 - กำหนด Top-K% : เช่น เลือก Features 80% แรก ที่มี score มากที่สุด (หรือ น้อยที่สุด)

7.2.1.1 Variance

สูตรการคำนวณ

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

เมื่อ

σ^2 คือ ความแปรปรวน (Variance)

x_i คือ ข้อมูลรายการที่ i

μ คือ ค่าเฉลี่ย (Mean)

n คือ จำนวนข้อมูลทั้งหมด

เป็นการเลือกเอา Features ที่มีการกระจายตัวไม่ต่ำจนเกินไป

หมายเหตุ : ควรทำ Normalization เพื่อให้ข้อมูลมี Scale เท่า ๆ กัน ก่อนทำการคำนวณ Variance ทั้งนี้ ในตัวอย่างต่อไปนี้อาจไม่ได้การทำ Normalization ก่อน เนื่องจากต้องการเน้นการทำ Variance Threshold

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงแสดงการเลือก Features ด้วยวิธี Variance เมื่อ Features มีค่า $\sigma^2 > 1$

item	house_age_years	parking_spaces	distance_to_road_km	poi_count_2km
1	0	2	1	5
2	5	1	2	4
3	0	3	2	5
4	8	1	3	3
5	6	2	5	1
6	14	1	2	2
7	24	1	5	0
8	28	3	3	1
9	10	1	4	3
10	5	1	1	4

วิธีทำ

- คำนวณ ความแปรปรวน ของ house_age_years

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \quad \text{เมื่อ } n = 10$$

item	1	2	3	4	5	6	7	8	9	10
house_age_years	0	5	0	8	6	14	24	28	10	5

$$\mu = 10$$

$$\sigma^2 = \frac{1}{10} ((0 - 10)^2 + (5 - 10)^2 + (0 - 10)^2 + \dots + (5 - 10)^2) = 80.6$$

- คำนวณ ความแปรปรวน ของ parking_spaces

item	1	2	3	4	5	6	7	8	9	10
parking_spaces	2	1	3	1	2	1	1	3	1	1

$$\mu = 1.6$$

$$\sigma^2 = \frac{1}{10} ((2 - 1.6)^2 + (1 - 1.6)^2 + (3 - 1.6)^2 + \dots + (1 - 1.6)^2) = 0.64$$

- คำนวณ ความแปรปรวน ของ distance_to_road_km

item	1	2	3	4	5	6	7	8	9	10
distance_to_road_km	1	2	2	3	5	2	5	3	4	1

$$\mu = 2.8$$

$$\sigma^2 = \frac{1}{10} ((1 - 2.8)^2 + (2 - 2.8)^2 + (2 - 2.8)^2 + \dots + (1 - 2.8)^2) = 1.96$$

- คำนวณ ความแปรปรวน ของ poi_count_2km

item	1	2	3	4	5	6	7	8	9	10
poi_count_2km	5	4	5	3	1	2	0	1	3	4

$$\mu = 2.8$$

$$\sigma^2 = \frac{1}{10} ((5 - 2.8)^2 + (4 - 2.8)^2 + (5 - 2.8)^2 + \dots + (4 - 2.8)^2) = 2.76$$

ตอบ เลือก house_age_years, distance_to_road_km, และ poi_count_2km
 เนื่องจากมีค่า $\sigma^2 > 1$ นั่นคือ 80.6, 1.96, และ 2.76 ตามลำดับ

โค้ดไพทอนสำหรับ Variance

```
1  #Import libraries
2  import pandas as pd
3  from sklearn.feature_selection import VarianceThreshold
4
5  #Load data
6  x = pd.read_csv('data/house_price.csv')
7  x = x.drop(columns=['item', 'price_kTHB_sqm'])
8
9  #Select features by using variance > 1.0
10 selector = VarianceThreshold(threshold=1.0)
11 selector.fit_transform(x)
12 selected_features = x.columns[selector.get_support()]
13
14 #Display selected features
15 print('Selected features:', selected_features.to_list())
16 print('Variance:', selector.variances_[selector.get_support()].round(2))
```

Selected features: ['house_age_years', 'distance_to_road_km', 'poi_count_2km']

Variance: [80.6 1.96 2.76]

7.2.1.2 Pearson Correlation's Coefficient

สูตรการคำนวณ

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_X s_Y} \quad \text{หรือ} \quad r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

เมื่อ

r_{XY} คือ สัมประสิทธิ์สหสัมพันธ์เพียร์สัน (Pearson Correlation's Coefficient) ระหว่างตัวแปร X และ Y
 $\text{Cov}(X, Y)$ คือ ความแปรปรวนร่วม (Covariance) ระหว่างตัวแปร X และ Y

s_X คือ ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) ของตัวแปรตัวแปร X

s_Y คือ ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) ของตัวแปรตัวแปร Y

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$s_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad s_Y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

เป็นการเลือกเอา Features ที่มีความสัมพันธ์เชิงเส้นระหว่าง ตัวแปรต้น (Features) เชิงปริมาณ กับตัวแปรตามเชิงปริมาณ

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงแสดงการเลือก Features ด้วยวิธี Pearson Correlation's Coefficient
เมื่อ Features มีค่า $|r_{X,Y}| > 0.3$

item	house_age_years	parking_spaces	distance_to_road_km	poi_count_2km	price_kTHB_sqm
1	0	2	1	5	80
2	5	1	2	4	61
3	0	3	2	5	65
4	8	1	3	3	54
5	6	2	5	1	44
6	14	1	2	2	50
7	24	1	5	0	25
8	28	3	3	1	43
9	10	1	4	3	45
10	5	1	1	4	56

วิธีทำ

1. คำนวณ ความแปรปรวนร่วม และ ส่วนเบี่ยงเบนมาตรฐาน จากสมการ

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad s_X = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad s_Y = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

$X =$	item	house_age_years	parking_spaces	distance_to_road_km	poi_count_2km	$Y =$
	1	0	2	1	5	
	2	5	1	2	4	
	3	0	3	2	5	
	4	8	1	3	3	
	5	6	2	5	1	
	6	14	1	2	2	
	7	24	1	5	0	
	8	28	3	3	1	
	9	10	1	4	3	
	10	5	1	1	4	
$\text{Cov}(X, Y) =$		-110.556	2.911	-17.822	23.622	
$s_x =$		9.463	0.843	1.476	1.751	$s_y = 14.833$

2. คำนวณ สัมประสิทธิ์สหสัมพันธ์เพียร์สัน ระหว่างตัวแปร X และ Y จากสมการ

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_X s_Y}$$

- คำนวณ ค่าสัมประสิทธิ์ ของ house_age_years

$$= \frac{-110.556}{9.463 \times 14.833} = -0.79$$

- คำนวณ ค่าสัมประสิทธิ์ ของ parking_spaces

$$= \frac{2.911}{0.843 \times 14.833} = 0.23$$

- คำนวณ ค่าสัมประสิทธิ์ ของ distance_to_road_km

$$= \frac{-17.822}{1.476 \times 14.833} = -0.81$$

- คำนวณ ค่าสัมประสิทธิ์ ของ poi_count_2km

$$= \frac{23.622}{1.751 \times 14.833} = 0.91$$

ตอบ เลือก house_age_years, distance_to_road_km, และ poi_count_2km
เนื่องจากมีค่า $|r_{X,Y}| > 0.3$ นั่นคือ 0.79, 0.81, และ 0.91 ตามลำดับ

โค้ดไพทอนสำหรับ Pearson Correlation's Coefficient

```
1 #Import libraries
2 import numpy as np
3 import pandas as pd
4
5 #Load data
6 x = pd.read_csv('data/house_price.csv')
7
8 #Compute |r(x,y)|
9 r = x.corr(method='pearson')['price_kTHB_sqm'].to_numpy()
10 abs_r = np.abs(r[1: len(r)-1])
11
12 #Select features by using |r(x,y)| > 0.3
13 index = x.columns[1: len(r)-1]
14 selected_feature = index[abs_r > 0.3]
15
16 #Display selected features
17 print('selected features:', selected_feature.to_list())
18 print('|r(x,y)|:', abs_r[abs_r > 0.3].round(2))
```

```
selected features: ['house_age_years', 'distance_to_road_km', 'poi_count_2km']
|r(x,y)|: [0.79 0.81 0.91]
```

7.2.1.3 Chi-Square Test

สูตรการคำนวณ

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \frac{(\text{row total}_i)(\text{column total}_j)}{N}$$

เมื่อ

χ^2 คือ ค่าไคสแควร์ (Chi-Square Statistic) ใช้วัดระดับความสัมพันธ์ระหว่างตัวแปรสองตัว

O_{ij} คือ ความถี่ที่สังเกตเห็น (Observed Frequency) ของแถวที่ i และคอลัมน์ที่ j ในตารางความถี่

E_{ij} คือ ความถี่ที่คาดหวัง (Expected Frequency) หากตัวแปรทั้งสองเป็นอิสระต่อกัน

r คือ จำนวนกลุ่มของตัวแปรต้น (จำนวนแถว ในตารางความถี่)

c คือ จำนวนกลุ่มของตัวแปรตาม (จำนวนคอลัมน์ ในตารางความถี่)

row total_i คือ จำนวนข้อมูลรวมของแถวที่ i

column total_j คือ จำนวนข้อมูลรวมของคอลัมน์ที่ j

N คือ จำนวนข้อมูลทั้งหมด

เป็นการเลือกเอา Features ที่มีความสัมพันธ์ระหว่าง ตัวแปรต้น (Features) เชิงกลุ่ม กับตัวแปรตามเชิงกลุ่ม โดยไม่จำเป็นต้องเป็นความสัมพันธ์เชิงเส้น

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงแสดงการเลือก Features ด้วยวิธี Chi-Square Test
เมื่อ Features มีค่า χ^2 มากที่สุด 2 อันดับแรก

item	age	sex	education_level	occupation	churn
1	22-25	หญิง	ปริญญาตรี	พนักงานขาย	ยกเลิก
2	26-31	ชาย	ปริญญาโท	พนักงานบัญชี	ไม่ยกเลิก
3	22-25	ชาย	ปริญญาตรี	พนักงานขาย	ยกเลิก
4	32-41	หญิง	ปริญญาเอก	พนักงานบุคคล	ไม่ยกเลิก
5	32-41	ชาย	ปริญญาโท	พนักงานบัญชี	ไม่ยกเลิก
6	32-41	หญิง	ปริญญาตรี	พนักงานบัญชี	ยกเลิก
7	26-31	หญิง	ปริญญาโท	พนักงานขาย	ไม่ยกเลิก
8	22-25	ชาย	ปริญญาตรี	พนักงานบุคคล	ยกเลิก
9	26-31	ชาย	ปริญญาตรี	พนักงานบุคคล	ไม่ยกเลิก
10	32-41	ชาย	ปริญญาตรี	พนักงานขาย	ไม่ยกเลิก

วิธีทำ

- คำนวณ ค่าไคสแควร์ ของ age

1. สร้าง ตารางความถี่ที่สังเกตเห็น (Observed)

age	ยกเลิก	ไม่ยกเลิก	รวม (row total)
22-25	3	0	3
26-31	0	3	3
32-41	1	3	4
รวม (column total)	4	6	10 (N)

2. คำนวณ ความถี่ที่คาดหวัง (Expected)

$$E_{ij} = \frac{(\text{row total}_i)(\text{column total}_j)}{N}$$

age	ยกเลิก	ไม่ยกเลิก
22-25	$(3 \times 4) / 10 = 1.2$	$(3 \times 6) / 10 = 1.8$
26-31	$(3 \times 4) / 10 = 1.2$	$(3 \times 6) / 10 = 1.8$
32-41	$(4 \times 4) / 10 = 1.6$	$(4 \times 6) / 10 = 2.4$

3. คำนวณ ค่าไคสแควร์ (Chi-Square)

$$\begin{aligned} \chi^2 &= \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \frac{(3 - 1.2)^2}{1.2} + \frac{(0 - 1.8)^2}{1.8} + \frac{(0 - 1.2)^2}{1.2} + \frac{(3 - 1.8)^2}{1.8} + \frac{(1 - 1.6)^2}{1.6} + \frac{(3 - 2.4)^2}{2.4} \\ &= 2.7 + 1.8 + 1.2 + 0.8 + 0.225 + 0.15 = 6.88 \end{aligned}$$

item	age	churn
1	22-25	ยกเลิก
2	26-31	ไม่ยกเลิก
3	22-25	ยกเลิก
4	32-41	ไม่ยกเลิก
5	32-41	ไม่ยกเลิก
6	32-41	ยกเลิก
7	26-31	ไม่ยกเลิก
8	22-25	ยกเลิก
9	26-31	ไม่ยกเลิก
10	32-41	ไม่ยกเลิก

- คำนวณ ค่าไคสแควร์ ของ sex

1. สร้าง ตารางความถี่ที่สังเกตเห็น (Observed)

sex	ยกเลิก	ไม่ยกเลิก	รวม (row total)
ชาย	2	4	6
หญิง	2	2	4
รวม (column total)	4	6	10 (N)

2. คำนวณ ความถี่ที่คาดหวัง (Expected)

$$E_{ij} = \frac{(\text{row total}_i)(\text{column total}_j)}{N}$$

sex	ยกเลิก	ไม่ยกเลิก
ชาย	$(6 \times 4) / 10 = 2.4$	$(6 \times 6) / 10 = 3.6$
หญิง	$(4 \times 4) / 10 = 1.6$	$(4 \times 6) / 10 = 2.4$

3. คำนวณ ค่าไคสแควร์ (Chi-Square)

$$\begin{aligned} \chi^2 &= \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \frac{(2 - 2.4)^2}{2.4} + \frac{(4 - 3.6)^2}{3.6} + \frac{(2 - 1.6)^2}{1.6} + \frac{(2 - 2.4)^2}{2.4} \\ &= 0.07 + 0.04 + 0.1 + 0.07 = 0.28 \end{aligned}$$

item	sex	churn
1	หญิง	ยกเลิก
2	ชาย	ไม่ยกเลิก
3	ชาย	ยกเลิก
4	หญิง	ไม่ยกเลิก
5	ชาย	ไม่ยกเลิก
6	หญิง	ยกเลิก
7	หญิง	ไม่ยกเลิก
8	ชาย	ยกเลิก
9	ชาย	ไม่ยกเลิก
10	ชาย	ไม่ยกเลิก

- คำนวณ ค่าไคสแควร์ ของ education_level

1. สร้าง ตารางความถี่ที่สังเกตเห็น (Observed)

education_level	ยกเลิก	ไม่ยกเลิก	รวม (row total)
ปริญญาตรี	4	2	6
ปริญญาโท	0	3	3
ปริญญาเอก	0	1	1
รวม (column total)	4	6	10 (N)

2. คำนวณ ความถี่ที่คาดหวัง (Expected)

$$E_{ij} = \frac{(\text{row total}_i)(\text{column total}_j)}{N}$$

education_level	ยกเลิก	ไม่ยกเลิก
ปริญญาตรี	$(6 \times 4) / 10 = 2.4$	$(6 \times 6) / 10 = 3.6$
ปริญญาโท	$(3 \times 4) / 10 = 1.2$	$(3 \times 6) / 10 = 1.8$
ปริญญาเอก	$(1 \times 4) / 10 = 0.4$	$(1 \times 6) / 10 = 0.6$

item	education_level	churn
1	ปริญญาตรี	ยกเลิก
2	ปริญญาโท	ไม่ยกเลิก
3	ปริญญาตรี	ยกเลิก
4	ปริญญาเอก	ไม่ยกเลิก
5	ปริญญาโท	ไม่ยกเลิก
6	ปริญญาตรี	ยกเลิก
7	ปริญญาโท	ไม่ยกเลิก
8	ปริญญาตรี	ยกเลิก
9	ปริญญาตรี	ไม่ยกเลิก
10	ปริญญาตรี	ไม่ยกเลิก

3. คำนวณ ค่าไคสแควร์ (Chi-Square)

$$\begin{aligned} \chi^2 &= \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \frac{(4 - 2.4)^2}{2.4} + \frac{(2 - 3.6)^2}{3.6} + \frac{(0 - 1.2)^2}{1.2} + \frac{(3 - 1.8)^2}{1.8} + \frac{(0 - 0.4)^2}{0.4} + \frac{(1 - 0.6)^2}{0.6} \\ &= 1.067 + 0.711 + 1.2 + 0.8 + 0.4 + 0.267 = 4.44 \end{aligned}$$

- คำนวณ ค่าไคสแควร์ ของ occupation

1. สร้าง ตารางความถี่ที่สังเกตเห็น (Observed)

occupation	ยกเลิก	ไม่ยกเลิก	รวม (row total)
พนักงานขาย	2	2	4
พนักงานบัญชี	1	2	3
พนักงานบุคคล	1	2	3
รวม (column total)	4	6	10 (N)

2. คำนวณ ความถี่ที่คาดหวัง (Expected)

$$E_{ij} = \frac{(\text{row total}_i)(\text{column total}_j)}{N}$$

occupation	ยกเลิก	ไม่ยกเลิก
พนักงานขาย	$(4 \times 4) / 10 = 1.6$	$(4 \times 6) / 10 = 2.4$
พนักงานบัญชี	$(3 \times 4) / 10 = 1.2$	$(3 \times 6) / 10 = 1.8$
พนักงานบุคคล	$(3 \times 4) / 10 = 1.2$	$(3 \times 6) / 10 = 1.8$

item	occupation	churn
1	พนักงานขาย	ยกเลิก
2	พนักงานบัญชี	ไม่ยกเลิก
3	พนักงานขาย	ยกเลิก
4	พนักงานบุคคล	ไม่ยกเลิก
5	พนักงานบัญชี	ไม่ยกเลิก
6	พนักงานบัญชี	ยกเลิก
7	พนักงานขาย	ไม่ยกเลิก
8	พนักงานบุคคล	ยกเลิก
9	พนักงานบุคคล	ไม่ยกเลิก
10	พนักงานขาย	ไม่ยกเลิก

3. คำนวณ ค่าไคสแควร์ (Chi-Square)

$$\begin{aligned} \chi^2 &= \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = \frac{(2 - 1.6)^2}{1.6} + \frac{(2 - 2.4)^2}{2.4} + \frac{(1 - 1.2)^2}{1.2} + \frac{(2 - 1.8)^2}{1.8} + \frac{(1 - 1.2)^2}{1.2} + \frac{(2 - 1.8)^2}{1.8} \\ &= 0.1 + 0.067 + 0.033 + 0.022 + 0.033 + 0.022 = 0.28 \end{aligned}$$

ตอบ

เลือก age และ education_level ซึ่งมีค่า χ^2 มากที่สุด 2 อันดับแรก
นั่นคือ 6.88 และ 4.44 ตามลำดับ ขณะที่ sex กับ occupation มีค่า χ^2 เท่ากัน คือ 0.28

โค้ดไพทอนสำหรับ Chi-Square Test

```
1 #Import libraries
2 import pandas as pd
3 from scipy.stats import chi2_contingency
4
5 #Load data
6 x = pd.read_csv('data/customer4.csv')
7
8 #Compute Chi-square
9 features = ["age", "sex", "education_level", "occupation"]
10 results = []
11
12 for f in features:
13     #Create observed frequency tables
14     table = pd.crosstab(x[f], x["churn"])
15     #print(table)
16     chi2, p, df, _ = chi2_contingency(table, correction=False)
17     results.append((f, chi2.round(2)))
18
19 result = pd.DataFrame(results, columns=["feature", "chi2"])
20 result = result.sort_values(["chi2"], ascending=False)
21
22 #Select features by using top 2
23 result = result[:2]
24
25 #Display selected features
26 print('Selected features:', result["feature"].tolist())
27 print('Chi-square:', result["chi2"].tolist())
```

Selected features: ['age', 'education_level']

Chi-square: [6.88, 4.44]

7.2.1.4 Mutual Information

สูตรการคำนวณ

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right)$$

$$p(x, y) = \frac{n(x, y)}{N} \quad p(x) = \sum_{y \in \mathcal{Y}} p(x, y) \quad p(y) = \sum_{x \in \mathcal{X}} p(x, y)$$

เมื่อ

$I(X; Y)$ คือ ค่า Mutual Information (MI) ระหว่าง x และ y

$p(x, y)$ คือ ความน่าจะเป็นร่วม (Joint Probability)

$p(x)$ คือ ความน่าจะเป็นของเหตุการณ์ (Marginal Probability) ของ x

$p(y)$ คือ ความน่าจะเป็นของเหตุการณ์ (Marginal Probability) ของ y

N คือ จำนวนข้อมูลทั้งหมด

เป็นการเลือกเอา Features ที่มีความสัมพันธ์ระหว่าง ตัวแปรต้น (Features) เชิงกลุ่ม กับตัวแปรตามเชิงกลุ่ม โดยไม่จำเป็นต้องเป็นความสัมพันธ์เชิงเส้น

ตัวอย่างการคำนวณ

จากข้อมูลต่อไปนี้ จงแสดงการเลือก Features ด้วยวิธี Mutual Information
เมื่อ Features มีค่า $I(X; Y)$ มากที่สุด 2 อันดับแรก

item	age	sex	education_level	occupation	churn
1	22-25	หญิง	ปริญญาตรี	พนักงานขาย	ยกเลิก
2	26-31	ชาย	ปริญญาโท	พนักงานบัญชี	ไม่ยกเลิก
3	22-25	ชาย	ปริญญาตรี	พนักงานขาย	ยกเลิก
4	32-41	หญิง	ปริญญาเอก	พนักงานบุคคล	ไม่ยกเลิก
5	32-41	ชาย	ปริญญาโท	พนักงานบัญชี	ไม่ยกเลิก
6	32-41	หญิง	ปริญญาตรี	พนักงานบัญชี	ยกเลิก
7	26-31	หญิง	ปริญญาโท	พนักงานขาย	ไม่ยกเลิก
8	22-25	ชาย	ปริญญาตรี	พนักงานบุคคล	ยกเลิก
9	26-31	ชาย	ปริญญาตรี	พนักงานบุคคล	ไม่ยกเลิก
10	32-41	ชาย	ปริญญาตรี	พนักงานขาย	ไม่ยกเลิก

วิธีทำ

- คำนวณ ค่า MI ของ age

1. สร้าง ตารางเหตุการณ์ (Contingency Table)

education_level	ยกเลิก	ไม่ยกเลิก	รวม (row total)
22-25	3	0	3
26-31	0	3	3
32-41	1	3	4
รวม (column total)	4	6	10 (N)

item	education_level	churn
1	22-25	ยกเลิก
2	26-31	ไม่ยกเลิก
3	22-25	ยกเลิก
4	32-41	ไม่ยกเลิก
5	32-41	ไม่ยกเลิก
6	32-41	ยกเลิก
7	26-31	ไม่ยกเลิก
8	22-25	ยกเลิก
9	26-31	ไม่ยกเลิก
10	32-41	ไม่ยกเลิก

2. คำนวณ ความน่าจะเป็นร่วม (Joint Prob.) และ ความน่าจะเป็นของเหตุการณ์ (Marginal Prob.)

education_level	ยกเลิก	ไม่ยกเลิก	$p(x)$
22-25	3/10 = 0.3	0/10 = 0.0	3/10 = 0.3
26-31	0/10 = 0.0	3/10 = 0.3	3/10 = 0.3
32-41	1/10 = 0.1	3/10 = 0.3	4/10 = 0.4
$p(y)$	4/10 = 0.4	6/10 = 0.6	10 (N)

$$p(x, y) = \frac{n(x, y)}{N}$$

$$p(x) = \sum_{y \in \mathcal{Y}} p(x, y) \quad p(y) = \sum_{x \in \mathcal{X}} p(x, y)$$

3. คำนวณ ค่า MI

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right)$$

$$= 0.3 \log_2 \frac{0.3}{0.3 \times 0.4} + 0.0 \log_2 \frac{0.0}{0.3 \times 0.6} + 0.0 \log_2 \frac{0.0}{0.3 \times 0.4} + 0.3 \log_2 \frac{0.3}{0.3 \times 0.6} + 0.1 \log_2 \frac{0.1}{0.4 \times 0.4} + 0.3 \log_2 \frac{0.3}{0.4 \times 0.6}$$

$$= 0.397 + 0 + 0 + 0.221 - 0.068 + 0.097 = 0.65$$

- คำนวณ ค่า MI ของ sex

1. สร้าง ตารางเหตุการณ์ (Contingency Table)

sex	ยกเลิก	ไม่ยกเลิก	รวม (row total)
ชาย	2	4	6
หญิง	2	2	4
รวม (column total)	4	6	10 (N)

item	sex	churn
1	หญิง	ยกเลิก
2	ชาย	ไม่ยกเลิก
3	ชาย	ยกเลิก
4	หญิง	ไม่ยกเลิก
5	ชาย	ไม่ยกเลิก
6	หญิง	ยกเลิก
7	หญิง	ไม่ยกเลิก
8	ชาย	ยกเลิก
9	ชาย	ไม่ยกเลิก
10	ชาย	ไม่ยกเลิก

2. คำนวณ ความน่าจะเป็นร่วม (Joint Prob.) และ ความน่าจะเป็นของเหตุการณ์ (Marginal Prob.)

sex	ยกเลิก	ไม่ยกเลิก	$p(x)$
ชาย	$2/10 = 0.2$	$4/10 = 0.4$	$6/10 = 0.6$
หญิง	$2/10 = 0.2$	$2/10 = 0.2$	$4/10 = 0.4$
$p(y)$	$4/10 = 0.4$	$6/10 = 0.6$	10 (N)

$$p(x, y) = \frac{n(x, y)}{N}$$

$$p(x) = \sum_{y \in \mathcal{Y}} p(x, y) \quad p(y) = \sum_{x \in \mathcal{X}} p(x, y)$$

3. คำนวณ ค่า MI

$$\begin{aligned}
 I(X; Y) &= \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right) \\
 &= 0.2 \log_2 \frac{0.2}{0.6 \times 0.4} + 0.4 \log_2 \frac{0.4}{0.6 \times 0.6} + 0.2 \log_2 \frac{0.2}{0.4 \times 0.4} + 0.2 \log_2 \frac{0.2}{0.4 \times 0.6} \\
 &= -0.053 + 0.061 + 0.064 - 0.053 = 0.02
 \end{aligned}$$

- คำนวณ ค่า MI ของ education_level

1. สร้าง ตารางเหตุการณ์ (Contingency Table)

education_level	ยกเลิก	ไม่ยกเลิก	รวม (row total)
ปริญญาตรี	4	2	6
ปริญญาโท	0	3	3
ปริญญาเอก	0	1	1
รวม (column total)	4	6	10 (N)

item	education_level	churn
1	ปริญญาตรี	ยกเลิก
2	ปริญญาโท	ไม่ยกเลิก
3	ปริญญาตรี	ยกเลิก
4	ปริญญาเอก	ไม่ยกเลิก
5	ปริญญาโท	ไม่ยกเลิก
6	ปริญญาตรี	ยกเลิก
7	ปริญญาโท	ไม่ยกเลิก
8	ปริญญาตรี	ยกเลิก
9	ปริญญาตรี	ไม่ยกเลิก
10	ปริญญาตรี	ไม่ยกเลิก

2. คำนวณ ความน่าจะเป็นร่วม (Joint Prob.) และ ความน่าจะเป็นของเหตุการณ์ (Marginal Prob.)

education_level	ยกเลิก	ไม่ยกเลิก	$p(x)$
ปริญญาตรี	4/10 = 0.4	2/10 = 0.2	6/10 = 0.6
ปริญญาโท	0/10 = 0.0	3/10 = 0.3	3/10 = 0.3
ปริญญาเอก	0/10 = 0.0	1/10 = 0.1	1/10 = 0.1
$p(y)$	4/10 = 0.4	6/10 = 0.6	10 (N)

$$p(x, y) = \frac{n(x, y)}{N}$$

$$p(x) = \sum_{y \in \mathcal{Y}} p(x, y) \quad p(y) = \sum_{x \in \mathcal{X}} p(x, y)$$

3. คำนวณ ค่า MI

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right)$$

$$= 0.4 \log_2 \frac{0.4}{0.6 \times 0.4} + 0.2 \log_2 \frac{0.2}{0.6 \times 0.6} + 0.0 \log_2 \frac{0.0}{0.3 \times 0.4} + 0.3 \log_2 \frac{0.3}{0.3 \times 0.6} + 0.0 \log_2 \frac{0.0}{0.1 \times 0.4} + 0.1 \log_2 \frac{0.1}{0.1 \times 0.6}$$

$$= 0.295 - 0.17 + 0 + 0.221 + 0 + 0.074 = 0.42$$

- คำนวณ ค่า MI ของ occupation

1. สร้าง ตารางเหตุการณ์ (Contingency Table)

occupation	ยกเลิก	ไม่ยกเลิก	รวม (row total)
พนักงานขาย	2	2	4
พนักงานบัญชี	1	2	3
พนักงานบุคคล	1	2	3
รวม (column total)	4	6	10 (N)

item	occupation	churn
1	พนักงานขาย	ยกเลิก
2	พนักงานบัญชี	ไม่ยกเลิก
3	พนักงานขาย	ยกเลิก
4	พนักงานบุคคล	ไม่ยกเลิก
5	พนักงานบัญชี	ไม่ยกเลิก
6	พนักงานบัญชี	ยกเลิก
7	พนักงานขาย	ไม่ยกเลิก
8	พนักงานบุคคล	ยกเลิก
9	พนักงานบุคคล	ไม่ยกเลิก
10	พนักงานขาย	ไม่ยกเลิก

2. คำนวณ ความน่าจะเป็นร่วม (Joint Prob.) และ ความน่าจะเป็นของเหตุการณ์ (Marginal Prob.)

occupation	ยกเลิก	ไม่ยกเลิก	$p(x)$
พนักงานขาย	$2/10 = 0.2$	$2/10 = 0.2$	$4/10 = 0.4$
พนักงานบัญชี	$1/10 = 0.1$	$2/10 = 0.2$	$3/10 = 0.3$
พนักงานบุคคล	$1/10 = 0.1$	$2/10 = 0.2$	$3/10 = 0.3$
$p(y)$	$4/10 = 0.4$	$6/10 = 0.6$	10 (N)

$$p(x, y) = \frac{n(x, y)}{N}$$

$$p(x) = \sum_{y \in \mathcal{Y}} p(x, y) \quad p(y) = \sum_{x \in \mathcal{X}} p(x, y)$$

3. คำนวณ ค่า MI

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right)$$

$$= 0.2 \log_2 \frac{0.2}{0.4 \times 0.4} + 0.2 \log_2 \frac{0.2}{0.4 \times 0.6} + 0.1 \log_2 \frac{0.1}{0.3 \times 0.4} + 0.2 \log_2 \frac{0.2}{0.3 \times 0.6} + 0.1 \log_2 \frac{0.1}{0.3 \times 0.4} + 0.2 \log_2 \frac{0.2}{0.3 \times 0.6}$$

$$= 0.064 - 0.053 - 0.026 + 0.03 - 0.026 + 0.03 = 0.02$$

ตอบ

เลือก age และ education_level ซึ่งมีค่า $I(X; Y)$ มากที่สุด 2 อันดับแรก
นั่นคือ 0.65 และ 0.42 ตามลำดับ ขณะที่ sex กับ occupation มีค่า $I(X; Y)$ เท่ากัน คือ 0.02

โค้ดไพทอนสำหรับ Mutual Information

```
1  #Import libraries
2  import pandas as pd
3  import numpy as np
4  from sklearn.metrics import mutual_info_score
5
6  #Load data
7  df = pd.read_csv('data/customer4.csv')
8  features = ["age", "sex", "education_level", "occupation"]
9  y = df["churn"]
10
11 #Compute MI
12 features = ["age", "sex", "education_level", "occupation"]
13 results = []
14
15 for f in features:
16     #mi = mutual_info_score(df[f], y) # log base e
17     mi_bits = mutual_info_score(df[f], y) / np.log(2) #log base 2
18     results.append((f, mi_bits.round(2)))
19
20 result = pd.DataFrame(results, columns=["feature", "mi"])
21 result = result.sort_values(["mi"], ascending=[False])
22
23 #Select features by using top 2
24 result = result[:2]
25
26 #Display selected features
27 print('Selected features:', result["feature"].tolist())
28 print('MI:', result["mi"].tolist())
```

Selected features: ['age', 'education_level']

MI: [0.65, 0.42]

7.2.2 Wrapper Method

- เป็นวิธีการที่เฉพาะเจาะจงกับเทคนิคของ ML
 - ซึ่งอาจทำให้ Model มีประสิทธิภาพดีกว่า Filter Method
 - แต่มีโอกาสดังกล่าว Overfitting มากกว่าแบบ Filter Method
- ใช้เวลามากกว่า Filter Method
- เทคนิค Wrapper Method มีดังนี้
 - Sequential Forward Selection $(O)n^2$
 - Sequential Backward Selection (Elimination) $(O)n^2$
 - Stepwise Selection $(O)n^3$
 - Exhaustive search $(O)2^n$

7.2.2.1 Sequential Forward Selection (SFS)

ขั้นตอนการเลือก

0. เริ่มจาก ไม่มี Feature เลย
1. เพิ่ม Feature ทีละตัว
2. Train Model และ ประเมิน Performance
3. เลือก Features ที่ให้ Performance สูงสุด
4. หยุด ถ้า Performance ไม่ดีขึ้น หรือ
ทำซ้ำตั้งแต่ขั้นที่ 1 ถ้า Performance ดีขึ้น

ตัวอย่างการเลือก

จงแสดงการเลือก Features ด้วยวิธี Sequential Forward Selection

กำหนดให้ Dataset มี 4 Features คือ $\{F_1, F_2, F_3, F_4\}$

วิธีทำ

เริ่มจาก ไม่มี Feature เลย $\{ \}$

รอบที่ 1 : เพิ่ม Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	$\{F_1\}$	0.72
2	$\{F_2\}$	0.75
3	$\{F_3\}$	0.70
4	$\{F_4\}$	0.73

เลือก $\{F_2\}$ แล้วดำเนินการต่อ

รอบที่ 2 : เพิ่ม Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	$\{F_2, F_1\}$	0.80
2	$\{F_2, F_3\}$	0.78
3	$\{F_2, F_4\}$	0.82

เลือก $\{F_2, F_4\}$ แล้วดำเนินการต่อ

รอบที่ 3 : เพิ่ม Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	{F ₂ , F ₄ , F ₁ }	0.83
2	{F ₂ , F ₄ , F ₃ }	0.81

เลือก {F₂, F₄, F₁} แล้วดำเนินการต่อ

รอบที่ 4 : เพิ่ม Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	{F ₂ , F ₄ , F ₁ , F ₃ }	0.82

พบว่า Performance ลดลง จึงไม่เลือก feature ในรอบนี้

ตอบ Features ที่เลือก คือ {F₂, F₄, F₁}

โค้ดไพทอนสำหรับ Sequential Forward Selection

```
1  #Import libraries
2  import pandas as pd
3  from sklearn.feature_selection import SequentialFeatureSelector as SFS
4  from sklearn.linear_model import LinearRegression
5
6  #Load data
7  df = pd.read_csv('data/house_price.csv')
8  x = df.iloc[:, 1:len(df.columns)-1]
9  y = df[["price_kTHB_sqm"]]
10
11 #Select features by using SFS
12 net = LinearRegression()
13 sfs = SFS(net, direction='forward')
14 sfs.fit(x, y)
15
16 #Display selected features
17 print('Selected features:', sfs.get_feature_names_out())
```

7.2.2.2 Sequential Backward Selection (SBS)

ขั้นตอนการเลือก

0. เริ่มจาก ใช้ Features ทั้งหมด
1. ลบ Feature ทีละตัว
2. Train Model และ ประเมิน Performance
3. เลือก Features ที่ให้ Performance สูงสุด
4. หยุด ถ้า Performance ไม่ดีขึ้น หรือ
ทำซ้ำตั้งแต่ขั้นที่ 1 ถ้า Performance ดีขึ้น

ตัวอย่างการเลือก

จงแสดงการเลือก Features ด้วยวิธี Sequential Backward Selection

กำหนดให้ Dataset มี 4 Features คือ $\{F_1, F_2, F_3, F_4\}$

วิธีทำ

เริ่มจาก ใช้ Features ทั้งหมด $\{F_1, F_2, F_3, F_4\}$, Train และ ประเมิน ได้ 0.84

รอบที่ 1 : ลบ Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	$\{F_2, F_3, F_4\}$	0.83
2	$\{F_1, F_3, F_4\}$	0.79
3	$\{F_1, F_2, F_4\}$	0.84
4	$\{F_1, F_2, F_3\}$	0.81

เลือก $\{F_1, F_2, F_4\}$ แล้วดำเนินการต่อ

รอบที่ 2 : ลบ Feature ทีละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	$\{F_2, F_4\}$	0.82
2	$\{F_1, F_4\}$	0.85
3	$\{F_1, F_2\}$	0.80

เลือก $\{F_1, F_4\}$ แล้วดำเนินการต่อ

รอบที่ 3 : ลบ Feature ที่ละตัว, Train Model และ ประเมิน Performance ได้ดังนี้

รายการ	Feature Set	Performance
1	{F ₄ }	0.78
2	{F ₁ }	0.76

พบว่า Performance ลดลง จึงไม่เลือก feature ในรอบนี้

ตอบ Features ที่เลือก คือ {F₁, F₄}

โค้ดไพทอนสำหรับ Sequential Backward Selection

```
1  #Import libraries
2  import pandas as pd
3  from sklearn.feature_selection import SequentialFeatureSelector as SBS
4  from sklearn.linear_model import LinearRegression
5
6  #Load data
7  df = pd.read_csv('data/house_price.csv')
8  x = df.iloc[:, 1:len(df.columns)-1]
9  y = df[["price_kTHB_sqm"]]
10
11 #Select features by using SBS
12 net = LinearRegression()
13 sbs = SBS(net, direction='backward')
14 sbs.fit(x, y)
15
16 #Display selected features
17 print('Selected features:', sbs.get_feature_names_out())
```

7.2.3 Embedded Method

- เป็นวิธีการเลือกปัจจัยที่ถูกฝัง (Embedded) อยู่ใน Algorithm ของ ML technique หรือกล่าวได้ว่า ML technique มีการเลือกปัจจัยในตัว
- ML Techniques ที่มีการเลือกปัจจัยในตัว มีดังนี้
 - Tree-based Models เช่น
 - Decision Tree : เลือก Features ผ่านการ Split
 - Random Forest : เลือก Features ผ่านการ Split และ การทำ Bagging
 - XGBoost : เลือก Features ผ่านการ Split และ การทำ Boosting
 - Linear SVM + L1 penalty: ตัด Features ที่มี weight เป็น 0

7.3 Feature Extraction

- เป็นการสร้างปัจจัยใหม่ (New Features) จากปัจจัยเดิม (Original Features)
- ช่วยเก็บเฉพาะ “สาระสำคัญ” ของข้อมูลไว้
- ช่วยแปลงข้อมูลให้อยู่ในรูปที่โมเดลเรียนรู้ได้ง่ายขึ้น
- เทคนิค Feature Extraction มีดังนี้
 - Text Vectorization
 - Spectrogram
 - Principal Component Analysis (PCA)
 - Autoencoder (Neural Network-based)
 - Time-series features (rolling mean, autocorrelation)

7.3.1 Text Vectorization

- เป็นวิธีการแปลงข้อมูลข้อความ (Text) ให้อยู่ในรูป เวกเตอร์เชิงตัวเลข (Numerical Vectors) เพื่อให้สามารถนำไปใช้กับเทคนิค ML ได้
- เทคนิค Text Vectorization มีดังนี้
 - Bag of Words (BoW)
 - Binary Encoding
 - Term Frequency-Inverse Document Frequency (TF-IDF)
 - N-grams (word / character)
 - Word Embedding (Word2Vec, GloVe, FastText)
 - Sentence / Document Embedding
 - Contextual Embedding (BERT, RoBERTa, Transformer-based models)

```
1 # ติดตั้ง pythainlp
2 %pip install pythainlp
```

✓ 4.9s

Python

7.3.1.1 Bag of Words (BoW)

แนวคิด

- นับจำนวนครั้งที่คำปรากฏ
- ไม่สนใจลำดับคำ

ตัวอย่าง

จงแสดงการทำ Text Vectorization ด้วยวิธี Bag of Words เกี่ยวกับข้อมูล รีวิวภาพยนตร์ ซึ่งมีรายการ ดังนี้

D1: หนังดีสนุกมาก นักแสดงดี

D2: หนังน่าเบื่อ เนื้อเรื่องซ้ำ

D3: นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา

D4: หนังสนุก เนื้อเรื่องดี

วิธีทำ

ทำการตัดคำ (Word Tokenization) และสร้างรายการคำศัพท์ (Vocabulary) ทั้งหมด 10 คำ ดังนี้

[หนัง, สนุก, มาก, นักแสดง, ดี, น่าเบื่อ, เนื้อเรื่อง, ซ้ำ, แต่, ธรรมดา] จากนั้น นำไปทำ Text Vectorization ได้ ดังนี้

Document	ซ้ำ	ดี	ธรรมดา	นักแสดง	น่าเบื่อ	มาก	สนุก	หนัง	เนื้อเรื่อง	แต่
D1	0	2	0	1	0	1	1	1	0	0
D2	1	0	0	0	1	0	0	1	1	0
D3	0	1	2	1	0	0	0	0	1	1
D4	0	1	0	0	0	0	1	1	1	0

โค้ดไพทอนสำหรับ Bag of Words (Scikit-Learn)

```
1 #Import libraries
2 from pythainlp.tokenize import word_tokenize
3 from sklearn.feature_extraction.text import CountVectorizer
4
5 #Load data
6 corpus = ["หนังดีสนุกมาก นักแสดงดี",
7           "หนังน่าเบื่อ เนื้อเรื่องซ้ำ",
8           "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9           "หนังสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 words = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extrace features by using Back of Words (Bow)
15 trans = CountVectorizer(analyzer=lambda x: x.split())#max_features=5
16 trans = trans.fit(words)
17
18 #Display vocabulary and text vectorization
19 print(trans.get_feature_names_out()) # vocabulary
20 x = trans.transform(words).toarray() # text vectorization (BoW)
21 print(x)
```

```
['ซ้ำ' 'ดี' 'ธรรมดา' 'นักแสดง' 'น่าเบื่อ' 'มาก' 'สนุก' 'หนัง'
 'เนื้อเรื่อง' 'แต่']
```

```
[[0 2 0 1 0 1 1 1 0 0]
 [1 0 0 0 1 0 0 1 1 0]
 [0 1 2 1 0 0 0 0 1 1]
 [0 1 0 0 0 0 1 1 1 0]]
```

โค้ดไพทอนสำหรับ Bag of Words (TensorFlow)

```
1  #Import libraries
2  import tensorflow as tf
3  from pythainlp.tokenize import word_tokenize
4
5  #Load data
6  corpus = ["หนังสือสนุกมาก นักแสดงดี",
7            "หนังสือน่าเบื่อ เนื้อเรื่องซ้ำ",
8            "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9            "หนังสือสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 texts = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extract features by using Bag of Words (Bow)
15 vectorizer = tf.keras.layers.TextVectorization(
16     output_mode="count",
17     split="whitespace"
18 )
19 vectorizer.adapt(texts) # Learn vocabulary + Bow
20
21 #Display vocabulary and text vectorization
22 vocab = [str(w) for w in vectorizer.get_vocabulary()]
23 print(vocab) # vocabulary
24
25 X = vectorizer(texts)
26 print((tf.round(X * 100) / 100).numpy()) # text vectorization
```

```
['[UNK]', 'ดี', 'เนื้อเรื่อง', 'หนังสือ', 'สนุก', 'นักแสดง', 'ธรรมดา', 'แต่', 'มาก', 'น่าเบื่อ', 'ซ้ำ']
```

```
[[0. 2. 0. 1. 1. 1. 0. 0. 1. 0. 0.]
```

```
 [0. 0. 1. 1. 0. 0. 0. 0. 0. 1. 1.]
```

```
 [0. 1. 1. 0. 0. 1. 2. 1. 0. 0. 0.]
```

```
 [0. 1. 1. 1. 1. 0. 0. 0. 0. 0. 0.]]
```


7.3.1.2 Binary Encoding

แนวคิด

- ไม่สนใจว่าซ้ำกี่ครั้ง
- ซ้ำกี่ครั้งก็ยังเป็น 1

ตัวอย่าง

จงแสดงการทำ Text Vectorization ด้วยวิธี Binary Encoding เกี่ยวกับข้อมูล รีวิวภาพยนตร์ ซึ่งมีรายการ ดังนี้

D1: หนังดีสนุกมาก นักแสดงดี

D2: หนังน่าเบื่อ เนื้อเรื่องซ้ำ

D3: นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา

D4: หนังสนุก เนื้อเรื่องดี

วิธีทำ

Document	ซ้ำ	ดี	ธรรมดา	นักแสดง	น่าเบื่อ	มาก	สนุก	หนัง	เนื้อเรื่อง	แต่
D1	0	1	0	1	0	1	1	1	0	0
D2	1	0	0	0	1	0	0	1	1	0
D3	0	1	1	1	0	0	0	0	1	1
D4	0	1	0	0	0	0	1	1	1	0

โค้ดไพทอนสำหรับ Binary Encoding (Scikit-Learn)

```
1 #Import libraries
2 from pythainlp.tokenize import word_tokenize
3 from sklearn.feature_extraction.text import CountVectorizer
4
5 #Load data
6 corpus = ["หนังดีสนุกมาก นักแสดงดี",
7           "หนังน่าเบื่อ เนื้อเรื่องซ้ำ",
8           "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9           "หนังสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 words = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extrace features by using Binary Encoding)
15 trans = CountVectorizer(analyzer=lambda x: x.split(), binary=True)
16 trans = trans.fit(words)
17
18 #Display vocabulary and text vectorization
19 print(trans.get_feature_names_out()) # vocabulary
20 x = trans.transform(words).toarray() # text vectorization
21 print(x)
```

```
['ซ้ำ' 'ดี' 'ธรรมดา' 'นักแสดง' 'น่าเบื่อ' 'มาก' 'สนุก' 'หนัง'
 'เนื้อเรื่อง' 'แต่']
```

```
[[0 1 0 1 0 1 1 1 0 0]
 [1 0 0 0 1 0 0 1 1 0]
 [0 1 1 1 0 0 0 0 1 1]
 [0 1 0 0 0 0 1 1 1 0]]
```

โค้ดไพทอนสำหรับ Binary Encoding (TensorFlow)

```
1 #Import libraries
2 import tensorflow as tf
3 from pythainlp.tokenize import word_tokenize
4
5 #Load data
6 corpus = ["หนังดีสนุกมาก นักแสดงดี",
7           "หนังน่าเบื่อ เนื้อเรื่องซ้ำ",
8           "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9           "หนังสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 texts = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extract features by using Binary Encoding
15 vectorizer = tf.keras.layers.TextVectorization(
16     output_mode="binary",
17     split="whitespace"
18 )
19 vectorizer.adapt(texts) # Learn vocabulary + Encoding
20
21 #Display vocabulary and text vectorization
22 vocab = [str(w) for w in vectorizer.get_vocabulary()]
23 print(vocab) # vocabulary
24
25 X = vectorizer(texts)
26 print((tf.round(X * 100) / 100).numpy()) # text vectorization
```

```
['[UNK]', 'ดี', 'เนื้อเรื่อง', 'หนัง', 'สนุก', 'นักแสดง', 'ธรรมดา', 'แต่', 'มาก', 'น่าเบื่อ', 'ซ้ำ']
```

```
[[0. 1. 0. 1. 1. 1. 0. 0. 1. 0. 0.]
```

```
 [0. 0. 1. 1. 0. 0. 0. 0. 0. 1. 1.]
```

```
 [0. 1. 1. 0. 0. 1. 1. 1. 0. 0. 0.]
```

```
 [0. 1. 1. 1. 1. 0. 0. 0. 0. 0. 0.]]
```

7.3.1.3 TF-IDF

แนวคิด

- พิจารณา คำซ้ำทั้งใน Document เดียวกัน และต่าง Document กัน
- ค่า TF-IDF จะสูง ถ้าใน Document เดียวกัน ซ้ำเยอะ แต่ต่าง Document กัน ซำน้อย

สูตรการคำนวณ

- คำนวณค่า TF

$$TF(t, d) = \frac{\text{จำนวนครั้งที่คำ } t \text{ ปรากฏใน document } d}{\text{จำนวนคำทั้งหมดใน document } d}$$

- คำนวณค่า IDF

$$IDF(t) = \log \frac{N}{n(t)} \quad \text{บางทฤษฎีใช้สมการ} \quad IDF(t) = \ln \left(\frac{N + 1}{n(t) + 1} \right) + 1$$

เมื่อ

N = จำนวน document ทั้งหมด

$n(t)$ = จำนวน document ที่มีคำ t

- คำนวณค่า TF-IDF

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

วิธีทำ

- คำนวณค่า TF

$$TF(t, d) = \frac{\text{จำนวนครั้งที่คำ } t \text{ ปรากฏใน document } d}{\text{จำนวนคำทั้งหมดใน document } d}$$

Document	ช้า	ดี	ธรรมดา	นักแสดง	น่าเบื่อ	มาก	สนุก	หนัง	เนื้อเรื่อง	แต่	sum
D1	0/6 = 0	2/6 = 0.33	0/6 = 0	1/6 = 0.17	0/6 = 0	1/6 = 0.17	1/6 = 0.17	1/6 = 0.17	0/6 = 0	0/6 = 0	6
D2	1/4 = 0.25	0/4 = 0	0/4 = 0	0/4 = 0	1/4 = 0.25	0/4 = 0	0/4 = 0	1/4 = 0.25	1/4 = 0.25	0/4 = 0	4
D3	0/6 = 0	1/6 = 0.17	2/6 = 0.33	1/6 = 0.17	0/6 = 0	0/6 = 0	0/6 = 0	0/6 = 0	1/6 = 0.17	1/6 = 0.17	6
D4	0/4 = 0	1/4 = 0.25	0/4 = 0	0/4 = 0	0/4 = 0	0/4 = 0	1/4 = 0.25	1/4 = 0.25	1/4 = 0.25	0/4 = 0	4

- คำนวณค่า IDF

$$IDF(t) = \log \frac{N}{n(t)}, N = 4$$

	ช้า	ดี	ธรรมดา	นักแสดง	น่าเบื่อ	มาก	สนุก	หนัง	เนื้อเรื่อง	แต่
$n(t)$	1	3	1	2	1	1	2	3	3	1
$IDF(t)$	$\log(4/1)=0.6$	$\log(4/3)=0.12$	$\log(4/1)=0.6$	$\log(4/2)=0.3$	$\log(4/1)=0.6$	$\log(4/1)=0.6$	$\log(4/2)=0.3$	$\log(4/3)=0.12$	$\log(4/3)=0.12$	$\log(4/1)=0.6$

- คำนวณค่า TF-IDF

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

Document	ช้า	ดี	ธรรมดา	นักแสดง	น่าเบื่อ	มาก	สนุก	หนัง	เนื้อเรื่อง	แต่
D1	0*0.6= 0	0.33*0.12= 0.04	0*0.6= 0	0.17*0.3= 0.05	0*0.6= 0	0.17*0.6= 0.1	0.17*0.3= 0.05	0.17*0.12= 0.02	0*0.12= 0	0*0.6= 0
D2	0.25*0.6= 0.15	0*0.12= 0	0*0.6= 0	0*0.3= 0	0.25*0.6= 0.15	0*0.6= 0	0*0.3= 0	0.25*0.12= 0.03	0.25*0.12= 0.03	0*0.6= 0
D3	0*0.6= 0	0.17*0.12= 0.02	0.33*0.6= 0.2	0.17*0.3= 0.05	0*0.6= 0	0*0.6= 0	0*0.3= 0	0*0.12= 0	0.17*0.12= 0.02	0.17*0.6= 0.1
D4	0*0.6= 0	0.25*0.12= 0.03	0*0.6= 0	0*0.3= 0	0*0.6= 0	0*0.6= 0	0.25*0.3= 0.08	0.25*0.12= 0.03	0.25*0.12= 0.03	0*0.6= 0

โค้ดไพทอนสำหรับ TF-IDF (Scikit-Learn)

```
1 #Import libraries
2 from pythainlp.tokenize import word_tokenize
3 from sklearn.feature_extraction.text import TfidfVectorizer
4
5 #Load data
6 corpus = ["หนังสือสนุกมาก นักแสดงดี",
7           "หนังสือน่าเบื่อ เนื้อเรื่องซ้ำ",
8           "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9           "หนังสือสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 words = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extrace features by using TF-IDF
15 trans = TfidfVectorizer(analyzer=lambda x: x.split())
16 trans = trans.fit(words)
17
18 #Display vocabulary and text vectorization
19 print(trans.get_feature_names_out()) # vocabulary
20 x = trans.transform(words).toarray() # text vectorization
21 print(x.round(2))
```

```
['ซ้ำ' 'ดี' 'ธรรมดา' 'นักแสดง' 'น่าเบื่อ' 'มาก' 'สนุก' 'หนังสือ'
 'เนื้อเรื่อง' 'แต่']
```

```
[[0.  0.62 0.  0.38 0.  0.48 0.38 0.31 0.  0. ]
 [0.6 0.  0.  0.  0.6 0.  0.  0.38 0.38 0. ]
 [0.  0.25 0.79 0.31 0.  0.  0.  0.  0.25 0.39]
 [0.  0.47 0.  0.  0.  0.  0.58 0.47 0.47 0. ]]
```

โค้ดไพทอนสำหรับ TF-IDF (TensorFlow)

```
1 #Import libraries
2 import tensorflow as tf
3 from pythainlp.tokenize import word_tokenize
4
5 #Load data
6 corpus = ["หนังสือสนุกมาก นักแสดงดี",
7           "หนังสือน่าเบื่อ เนื้อเรื่องซ้ำ",
8           "นักแสดงดี แต่เนื้อเรื่องธรรมดา ธรรมดา",
9           "หนังสือสนุก เนื้อเรื่องดี"]
10
11 #Tokenize words (แยกคำ)
12 texts = [' '.join(word_tokenize(text)) for text in corpus]
13
14 #Extract features by using TF-IDF
15 vectorizer = tf.keras.layers.TextVectorization(
16     output_mode="tf-idf",
17     split="whitespace"
18 )
19 vectorizer.adapt(texts) # Learn vocabulary + IDF
20
21 #Display vocabulary and text vectorization
22 vocab = [str(w) for w in vectorizer.get_vocabulary()]
23 print(vocab) # vocabulary
24
25 X = vectorizer(texts)
26 print((tf.round(X * 100) / 100).numpy()) # text vectorization
```

```
['[UNK]', 'ดี', 'เนื้อเรื่อง', 'หนังสือ', 'สนุก', 'นักแสดง', 'ธรรมดา', 'แต่', 'มาก', 'น่าเบื่อ', 'ซ้ำ']
```

```
[[0.    1.39 0.    0.69 0.85 0.85 0.    0.    1.1 0.    0. ]
 [0.    0.    0.69 0.69 0.    0.    0.    0.    0.    1.1 1.1 ]
 [0.    0.69 0.69 0.    0.    0.85 2.2 1.1 0.    0.    0. ]
 [0.    0.69 0.69 0.69 0.85 0.    0.    0.    0.    0.    0. ]]
```


7.3.2 Spectrogram

เป็นวิธีการแปลงข้อมูลเสียง (Audio / Signal) ให้อยู่ในรูปของ การแทนค่าเชิงตัวเลขในโดเมนเวลา-ความถี่ (Time-Frequency Representation) เพื่อให้สามารถนำไปใช้กับเทคนิค ML ได้

สูตรการคำนวณ

- การแปลงฟูเรียร์ช่วงสั้น (Short-Time Fourier Transform : STFT)

- สำหรับสัญญาณเวลาไม่ต่อเนื่อง หรือ สัญญาณดิจิทัล

$$X(m, k) = \sum_{n=0}^{N-1} x(n + mH)w(n)e^{-j\frac{2\pi}{N}kn}$$

เมื่อ

$X(m, k)$ คือ ค่าที่ได้จากการแปลงฟูเรียร์ระยะเวลาดำเนิน (STFT)

$x(n + mH)$ คือ ส่วนของสัญญาณในเฟรมที่ m

โดยมี H คือ Hop Size (ระยะเลื่อน)

$w(n)$ คือ ฟังก์ชันหน้าต่างที่มีความยาว N

(เช่น Hamming Window)

k คือ ดัชนีของความถี่ (Frequency Bin)

N คือ จำนวนจุดที่ใช้ทำ Fast Fourier Transform (FFT)

- สำหรับสัญญาณเวลาต่อเนื่อง หรือ สัญญาณอนาล็อก

$$X(\tau, \omega) = \int_{-\infty}^{\infty} x(t)w(t - \tau)e^{-j\omega t}dt$$

เมื่อ

$X(\tau, \omega)$ คือ ค่าที่ได้จากการแปลงฟูเรียร์ระยะเวลาดำเนิน (STFT)

$x(t)$ คือ สัญญาณอินพุต ณ เวลา t

$w(t - \tau)$ คือ หน้าต่าง (Window) ที่เลื่อนไป ณ เวลา τ

$e^{-j\omega t}$ คือ เทอมของ Fourier Transform เพื่อสกัดความถี่ ω

- สเปกโตรแกรม (Spectrogram)

$$S(m, k) = |X(m, k)| \quad \text{หรือ} \quad S(m, k) = |X(m, k)|^2$$

เมื่อ

$S(m, k)$ คือ ค่าพลังงานของสัญญาณ (Magnitude Spectrum) ณ ช่วงเวลาที่ m ความถี่ที่ k

$X(m, k)$ คือ ค่าที่ได้จากการแปลงฟูริเยร์ระยะเวลานั้น ซึ่งเป็น Complex Number ที่เก็บข้อมูล ทั้งความเข้ม (Magnitude) และ เฟส (Phase) ของสัญญาณไว้

- การแปลงเป็นหน่วยเดซิเบล (Log-scaling)

- แปลงเป็นหน่วยเดซิเบล โดยตรง

$$S_{dB}(m, l) = 10 \cdot \log_{10} \left(\frac{S(m, k))}{P_{ref}} \right)$$

เมื่อ

$S_{dB}(m, l)$ คือ ค่าสุดท้ายที่จะส่งเข้า CNN

P_{ref} คือ ค่าพลังงานอ้างอิง

(มักใช้ค่าสูงสุด เพื่อทำ Normalization)

- ใช้ Mel Filter Bank เพื่อลดความถี่ ก่อน

$$M(m, l) = \sum_{k=0}^{N-1} S(m, k) \cdot H_l(k)$$

เมื่อ

$M(m, l)$ คือ ค่าพลังงานใน Mel-bin ที่ l ณ เวลาที่ m

$H_l(k)$ คือ ฟิเตอร์แบบสามเหลี่ยม

(Triangular filters) ใน Mel-scale

$$S_{dB}(m, l) = 10 \cdot \log_{10} \left(\frac{M(m, l)}{P_{ref}} \right)$$

เมื่อ

$S_{dB}(m, l)$ คือ ค่าสุดท้ายที่จะส่งเข้า CNN

P_{ref} คือ ค่าพลังงานอ้างอิง

(มักใช้ค่าสูงสุด เพื่อทำ Normalization)

ติดตั้ง Libraries

```
1  #ติดตั้ง librosa สำหรับวิเคราะห์และประมวลผลสัญญาณเสียง
2  %pip install librosa
3
4  #ติดตั้ง numpy เวอร์ชันที่รองรับ librosa
5  %pip install numpy==2.4.0
6
7  #ติดตั้ง sounddevice สำหรับบันทึกและเล่นเสียง
8  %pip install sounddevice
```

Python



โค้ดไพทอนสำหรับ Spectrogram

```
1  # Import libraries
2  import librosa
3  import librosa.display
4  import numpy as np
5  import matplotlib.pyplot as plt
6
7  # 1. โหลดไฟล์เสียง (signal) หรือ x(n)
8  signal, sample_rate = librosa.load('data/speech/go/0a9f9af7_nohash_0.wav')
9
10 # 2. คำนวณ STFT หรือ X(m, k)
11 stft = librosa.stft(signal) # complex-valued STFT
12
13 # 3. คำนวณ Magnitude Spectrogram |X(m,k)|
14 spectrogram = np.abs(stft)
15
16 # 4. แปลงเป็น dB (Log-Magnitude Spectrogram)
17 S_db = librosa.amplitude_to_db(spectrogram, ref=np.max)
18
```

```

19 # 5. แสดงผล
20 plt.figure(figsize=(12, 6))
21
22 # (a) Plot signal (time-domain)
23 plt.subplot(2, 1, 1)
24 librosa.display.waveshow(signal, sr=sample_rate)
25 plt.title('Audio Signal x(n)')
26 plt.xlabel('Time (seconds)')
27 plt.ylabel('Amplitude')
28
29 # (b) Plot spectrogram (frequency-domain)
30 plt.subplot(2, 1, 2)
31 librosa.display.specshow(
32     S_db,
33     sr=sample_rate,
34     x_axis='time',
35     y_axis='hz'
36 )
37 plt.colorbar(format='%+2.0f dB')
38 plt.title('Log-Magnitude Spectrogram  $|X(m,k)|$  (dB)')
39 plt.xlabel('Time (seconds)')
40 plt.ylabel('Frequency (Hz)')
41
42 plt.tight_layout()
43 plt.show()

```

โค้ดไพทอนสำหรับ เล่นเสียง

```
1  #เล่นไฟล์เสียง
2  import librosa
3  import sounddevice as sd
4
5  y, sr = librosa.load("data/speech/go/0a9f9af7_nohash_0.wav", sr=None)
6
7  sd.play(y, sr)
8  sd.wait()
9
```

✓ 1.2s

Python

7.4 แบบฝึกหัด

1. จากข้อมูลต่อไปนี้ จงแสดงการเลือก Features ด้วยวิธี Pearson Correlation's Coefficient
เมื่อ Features มีค่า $|r_{X,Y}| > 0.3$

เดือนที่	งบโฆษณาออนไลน์ (k฿)	จำนวนคนเข้าร้าน	อัตราสินค้าชำรุด (%)	ส่วนลดของกลุ่ม (%)	ยอดขายต่อเดือน (k฿)
1	50	820	4.1	10	420
2	55	870	5	15	440
3	60	860	4.9	12	455
4	58	870	4.6	11	470
5	65	900	4.4	10	500
6	70	910	4.2	9	510
7	75	920	3.9	14	545
8	72	900	3.7	8	560
9	78	850	3.6	11	590
10	85	1020	3.3	12	600

2. จงแสดงการทำ Text Vectorization ด้วยวิธี TF-IDF เกี่ยวกับข้อมูล รีวิวสินค้า ซึ่งมีรายการ ดังนี้

D1 : the product is very good and very good

D2 : the product is bad and very bad

D3 : very impressive and impressive service

D4 : the product broke



THANK YOU FOR YOUR ATTENTION

 pichai_jo@rmutto.ac.th

