

บทที่ 10

การจัดกลุ่ม

- ✓ 10.1 แนะนำการจัดกลุ่ม
- ✓ 10.2 K-Mean
- ✓ 10.3 Hierarchical Clustering
- ✓ 10.4 แบบฝึกหัด




10.1 แนะนำการจัดกลุ่ม


- **การจัดกลุ่ม (Clustering)** เป็นเทคนิคการแบ่งข้อมูลออกเป็นกลุ่มย่อย ๆ โดยข้อมูลที่อยู่ในกลุ่มเดียวกันจะมีคุณลักษณะที่คล้ายคลึงกัน และแตกต่างจากข้อมูลในกลุ่มอื่น
- เป็นเทคนิคหนึ่งของ ML ในกลุ่ม Unsupervised Learning
- ไม่มีตัวแปรตาม (Dependent/Target) กำกับไว้ล่วงหน้า โมเดลจะเรียนรู้โครงสร้างหรือรูปแบบของข้อมูลจากตัวแปรต้น (Independent/Input) เพียงอย่างเดียว

- **ตัวอย่างการประยุกต์ใช้**

- การจัดกลุ่มลูกค้าเพื่อเสนอโปรโมชั่นที่เหมาะสม (กลุ่ม 1, 2, k)
- การจัดกลุ่มร้านค้าปลีกเพื่อสร้างกลยุทธ์ที่เหมาะสม (กลุ่ม 1, 2, k)
- การจัดกลุ่มพนักงานเพื่อใช้สำหรับการฝึกอบรม (กลุ่ม 1, 2, k)



ภาพที่ 10-1 : ตัวอย่างการจัดกลุ่มข้อมูล



ภาพที่ 10-2 : Machine Learning Techniques

10.2 K-Mean

- อาศัยหลักการวัดระยะทาง ซึ่งนิยมวัดระยะทางโดยใช้วิธี Euclidian Distance
- ง่ายต่อการทำความเข้าใจและการคำนวณ
- Sensitive ต่อ Outliers
- ข้อมูลที่มีช่วงต่างกันมาก เช่น อายุ 0-100 กับเงินเดือน 1 พัน-1 แสน จะทำให้ข้อมูลที่มีช่วงกว้างกว่า มีอิทธิพลต่อการคำนวณระยะทางมากกว่า ควรทำการ Normalize/Standardize ข้อมูล เช่น ทำให้ข้อมูลอยู่ในช่วง $[0, 1]$

10.2.1 การคำนวณสำหรับ K-Mean

สูตรการคำนวณ

- การเทรนโมเดล

ขั้นที่ 1 : กำหนด Centroid เริ่มต้น c_k โดยที่ $k = 0, \dots, K - 1$ และ K คือ จำนวน Centroids

ขั้นที่ 2 : คำนวณ ระยะทางระหว่าง Training Point กับ Centroid $d(x_i, c_k)$ โดยที่ $i = 1, \dots, n$ และ n คือจำนวน Training Points

$$d(x_i, c_k) = \|x_i - c_k\| = \sqrt{\sum_{j \in m} (x_{ij} - c_{kj})^2} \text{ เมื่อ } m \text{ คือ จำนวนมิติของข้อมูล}$$

ขั้นที่ 3 : กำหนดสมาชิกของ Centroids, โดยให้ $x_i \in c_k$ เมื่อ x_i อยู่ใกล้ c_k ที่สุดเมื่อเทียบกับ Centroids อื่น ๆ

ขั้นที่ 4 : ทำการปรับปรุง Centroid c_k

$$c_k = \frac{1}{|c_k|} \sum_{x_i \in c_k} x_i$$

ขั้นที่ 5 : กลับไปทำขั้นตอนที่ 2 จนกว่า Centroid ไม่มีการเปลี่ยนแปลง หรือ ครบจำนวนรอบของการปรับ Centroid

- การทดสอบโมเดล

ขั้นที่ 1 : คำนวณ ระยะทางระหว่าง Test Point กับ ทุก Centroid

$$d(x, c_k) = ||x - c_k|| = \sqrt{\sum_{j \in m} (x_j - c_{kj})^2}$$

ขั้นที่ 2 : ทำนาย Cluster จาก

$$\hat{y} = \arg \min_k d(x, c_k)$$

เมื่อ

$\hat{y}$ คือ Cluster ที่ทำนายได้

$\arg \min_k$ คือ ฟังก์ชันที่ใช้หาค่า k หรือ Index ของ Centroid ที่มีระยะห่างจาก Test Point น้อยที่สุด

10.2.2 ตัวอย่างการคำนวณ K-Mean

จงแสดงวิธีการคำนวณ K-Mean เพื่อจัดกลุ่มข้อมูลลูกค้า โดยให้ใช้ค่า และชุดข้อมูลต่อไปนี้


- กำหนด Centroid เริ่มต้น โดยให้ $c_0 = [4, 3]$, $c_1 = [10, 4]$
- จำนวนรอบของการปรับ Centroid = 2 รอบ

ตารางที่ 10-1ก : ชุดข้อมูลฝึก (Training Set)

รายการ	จำนวนครั้งที่ซื้อสินค้าต่อเดือน	จำนวนประเภทสินค้าที่เคยซื้อ
1	6	5
2	7	4
3	7	6
4	5	6
5	6	4
6	11	3
7	10	4
8	12	5
9	11	4
10	11	6

ตารางที่ 10-1ข : ชุดข้อมูลทดสอบ (Test Set)

รายการ	จำนวนครั้งที่ซื้อสินค้าต่อเดือน	จำนวนประเภทสินค้าที่เคยซื้อ
1	7	5



ภาพที่ 10-3 : ชุดข้อมูลฝึก (Training Set)

วิธีทำ

• การเทรโมเดล

กำหนด centroid เริ่มต้น

$c_0 =$	4	3
$c_1 =$	10	4

รอบที่ 1

x=	จำนวนครั้งที่ซื้อ สินค้าต่อเดือน	จำนวนประเภท สินค้าที่เคยซื้อ	การคำนวณระยะทาง ระหว่าง c_0 กับ x	ระยะทาง ระหว่าง c_0 กับ x	การคำนวณระยะทาง ระหว่าง c_1 กับ x	ระยะทาง ระหว่าง c_1 กับ x	กลุ่มข้อมูล (Cluster)
	6	5	$\text{SQRT}((4-6)^2+(3-5)^2)$	2.83	$\text{SQRT}((10-6)^2+(4-5)^2)$	4.12	0
	7	4	$\text{SQRT}((4-7)^2+(3-4)^2)$	3.16	$\text{SQRT}((10-7)^2+(4-4)^2)$	3.00	1
	7	6	$\text{SQRT}((4-7)^2+(3-6)^2)$	4.24	$\text{SQRT}((10-7)^2+(4-6)^2)$	3.61	1
	5	6	$\text{SQRT}((4-5)^2+(3-6)^2)$	3.16	$\text{SQRT}((10-5)^2+(4-6)^2)$	5.39	0
	6	4	$\text{SQRT}((4-6)^2+(3-4)^2)$	2.24	$\text{SQRT}((10-6)^2+(4-4)^2)$	4.00	0
	11	3	$\text{SQRT}((4-11)^2+(3-3)^2)$	7.00	$\text{SQRT}((10-11)^2+(4-3)^2)$	1.41	1
	10	4	$\text{SQRT}((4-10)^2+(3-4)^2)$	6.08	$\text{SQRT}((10-10)^2+(4-4)^2)$	0.00	1
	12	5	$\text{SQRT}((4-12)^2+(3-5)^2)$	8.25	$\text{SQRT}((10-12)^2+(4-5)^2)$	2.24	1
	11	4	$\text{SQRT}((4-11)^2+(3-4)^2)$	7.07	$\text{SQRT}((10-11)^2+(4-4)^2)$	1.00	1
	11	6	$\text{SQRT}((4-11)^2+(3-6)^2)$	7.62	$\text{SQRT}((10-11)^2+(4-6)^2)$	2.24	1
ปรับ centroid	5.67	5					
$c_0 =$	5.67	5					
$c_1 =$	9.86	4.57					

$(6+5+6)/3 = 5.67$

$(5+6+4)/3 = 5$

$(7+7+11+10+12+11+11)/7 = 9.86$

$(4+6+3+4+5+4+6)/7 = 4.57$

รอบที่ 2

x=	จำนวนครั้งที่ซื้อ สินค้าต่อเดือน	จำนวนประเภท สินค้าที่เคยซื้อ	การคำนวณระยะทาง ระหว่าง c ₀ กับ x	ระยะทาง ระหว่าง c ₀ กับ x	การคำนวณระยะทาง ระหว่าง c ₁ กับ x	ระยะทาง ระหว่าง c ₁ กับ x	กลุ่มข้อมูล (Cluster)
	6	5	$\text{SQRT}((5.67-6)^2+(5-5)^2)$	0.33	$\text{SQRT}((9.86-6)^2+(4.57-5)^2)$	3.88	0
	7	4	$\text{SQRT}((5.67-7)^2+(5-4)^2)$	1.66	$\text{SQRT}((9.86-7)^2+(4.57-4)^2)$	2.92	0
	7	6	$\text{SQRT}((5.67-7)^2+(5-6)^2)$	1.66	$\text{SQRT}((9.86-7)^2+(4.57-6)^2)$	3.20	0
	5	6	$\text{SQRT}((5.67-5)^2+(5-6)^2)$	1.20	$\text{SQRT}((9.86-5)^2+(4.57-6)^2)$	5.07	0
	6	4	$\text{SQRT}((5.67-6)^2+(5-4)^2)$	1.05	$\text{SQRT}((9.86-6)^2+(4.57-4)^2)$	3.90	0
	11	3	$\text{SQRT}((5.67-11)^2+(5-3)^2)$	5.69	$\text{SQRT}((9.86-11)^2+(4.57-3)^2)$	1.94	1
	10	4	$\text{SQRT}((5.67-10)^2+(5-4)^2)$	4.44	$\text{SQRT}((9.86-10)^2+(4.57-4)^2)$	0.59	1
	12	5	$\text{SQRT}((5.67-12)^2+(5-5)^2)$	6.33	$\text{SQRT}((9.86-12)^2+(4.57-5)^2)$	2.18	1
	11	4	$\text{SQRT}((5.67-11)^2+(5-4)^2)$	5.42	$\text{SQRT}((9.86-11)^2+(4.57-4)^2)$	1.27	1
	11	6	$\text{SQRT}((5.67-11)^2+(5-6)^2)$	5.42	$\text{SQRT}((9.86-11)^2+(4.57-6)^2)$	1.83	1
ปรับ centroid							
c ₀ =	6.2	5					
c ₁ =	11	4.4					

- การทดสอบโมเดล

จาก

$$d(x, c_k) = \sqrt{\sum_{j \in m} (x_j - c_{kj})^2} \quad \hat{y} = \arg \min_k d(x, c_k)$$

$$x = [7, 5] \quad c_0 = [6.2, 5], \quad c_1 = [11, 4.4]$$

จะได้

$$d(x, c_0) = \sqrt{(7 - 6.2)^2 + (5 - 5)^2} = 0.8$$

$$d(x, c_1) = \sqrt{(7 - 11)^2 + (5 - 4.4)^2} = 4.04$$

$$\hat{y} = \arg \min_k \{0.8, 4.04\} = 0$$

ตอบ ลูกค้านี้ถูกจัดให้อยู่ใน Cluster 0 เนื่องจากมีระยะทางใกล้กับ Centroid ของ Cluster 0 มากที่สุด

10.2.3 ตัวอย่างโค้ด K-Mean

```
# Import Python Library
from sklearn.cluster import KMeans
from sklearn.metrics import davies_bouldin_score

#Load Data
x_train = [[6, 5], [7, 4], [7, 6], [5, 6], [6, 4], [11, 3], [10, 4], [12, 5], [11, 4], [11, 6]]
x_test = [[7, 5]]


#Build Model
init_centers = [[4, 3],[10, 4]]
net = KMeans(n_clusters=2, init=init_centers, n_init=1, max_iter=2).fit(x_train)
#net = KMeans(n_clusters=2, random_state=0).fit(x_train)

print('Centroids : \n', net.cluster_centers_.round(4)) #show centroids
print('Cluster Labels (Train) : ', net.labels_) #show train cluster labels

#Test Model
y_pred = net.predict(x_test) #predict clusters and show test cluster labels
print('Cluster Labels (Test) : ', y_pred)

#Evaluate Model
dbi = davies_bouldin_score(x_train, net.labels_)
print(f'DBI : {dbi:.2f}')

Centroids :
[[ 6.2  5. ]
 [11.  4.4]]
Cluster Labels (Train) : [0 0 0 0 0 1 1 1 1 1]
Cluster Labels (Test) : [0]
DBI : 0.45
```



10.3 Hierarchical Clustering

- อาศัยหลักการวัดระยะทาง ซึ่งนิยมวัดระยะทางโดยใช้วิธี Euclidian Distance
- ง่ายต่อการทำความเข้าใจและการคำนวณ แต่ Sensitive ต่อ Outliers
- ข้อมูลที่มีช่วงต่างกันมาก ควรทำการ Normalize/Standardize ข้อมูล
- เป็นการสร้าง Cluster แบบลำดับชั้น (Hierarchy) แบ่งเป็น
 - Agglomerative Algorithm : สร้าง Cluster จากการรวม Cluster ย่อย ไปเป็น Cluster ที่ใหญ่ขึ้นไปเรื่อย ๆ เรียกว่า Bottom Up
 - Divisive Algorithm : สร้าง Cluster จากการแยก Cluster ใหญ่ ไปเป็น Cluster ที่เล็กลงไปเรื่อย ๆ เรียกว่า Top Down

10.3.1 การคำนวณสำหรับ Agglomerative Algorithm

สูตรการคำนวณ

- การเทรนโมเดล

ขั้นที่ 1 : กำหนดให้ทุก Training Points เป็น clusters และ n คือ จำนวน cluster ทั้งหมด

ขั้นที่ 2 : คำนวณ ระยะทางระหว่าง Training Point ด้วยตัวเอง $d(x_i, x_j)$ โดยที่ $i \neq j$ โดยที่ $i, j = 1, \dots, n$

$$d(x_i, x_j) = \sqrt{\sum_{l \in m} (x_{il} - x_{jl})^2} \quad \text{เมื่อ } m \text{ คือ จำนวนมิติของข้อมูล}$$

จำนวน $d(x_i, x_j)$ เท่ากับ $n(n-1)/2$

ขั้นที่ 3 : รวม x_i กับ x_j ที่มี $d(x_i, x_j)$ น้อยที่สุด ไปเป็น cluster ใหม่ ค่า $d(x_i, x_j)$ นี้แสดงถึงค่า dendrogram ของ cluster ใหม่ ณ ขั้นตอนนี้จำนวนของ cluster จะลดลงไป 1 cluster (รอบแรก = $n-1$)

ขั้นที่ 4 : กลับไปทำขั้นตอนที่ 2 จนกระทั่ง เหลือเพียง 1 Cluster หรือ เหลือเท่ากับจำนวน Cluster ที่ต้องการ

หมายเหตุ : เราสามารถกำหนดจำนวน Cluster ที่ต้องการได้ตั้งแต่ขั้นตอนที่ 1 และหากมีการกำหนดจำนวนที่ต้องการแล้ว ใน**ขั้นตอนที่ 5** ก็**ไม่จำเป็นต้องดำเนินการ**

ขั้นที่ 5 : ทำการเลือกจำนวน cluster

5.1 ระบุจำนวน Cluster K ที่ต้องการ

5.2 Plot รูป Dendrogram (Tree)

5.2 ตัด Node ของ Dendrogram ออกให้เหลือจำนวน Cluster ที่ต้องการ โดยเริ่มจากการตัด Root Node ก่อน

- การทดสอบโมเดล

ขั้นที่ 1 : คำนวณ ระยะทางระหว่าง Test Point กับ ทุก Training Points

$$d(x, x_i) = \sqrt{\sum_{l \in m} (x_l - x_{il})^2}$$

ขั้นที่ 2 : ทำนาย Cluster จาก

$$\hat{y} = \text{cluster} \left(\arg \min_{x_i} d(x, x_i) \right)$$

เมื่อ

$\hat{y}$ คือ Cluster ที่ทำนายได้

$\arg \min_{x_i}$ คือ ฟังก์ชันที่ใช้หา x_i หรือ Training Point ที่มีระยะห่างจาก Test Point น้อยที่สุด

cluster คือ ฟังก์ชันที่ใช้หา Cluster ของ x_i หรือ Training Point ที่มีระยะห่างจาก Test Point น้อยที่สุด

10.3.2 ตัวอย่างการคำนวณ Agglomerative Algorithm

จงแสดงวิธีการคำนวณ Agglomerative Algorithm เพื่อจัดกลุ่มข้อมูลลูกค้า โดยให้ใช้ค่า และชุดข้อมูลทดสอบต่อไปนี้


- กำหนดให้มี 2 Clusters

ตารางที่ 10-2ก : ชุดข้อมูลฝึก (Training Set)

รายการ	จำนวนครั้งที่ซื้อสินค้าต่อเดือน	จำนวนประเภทสินค้าที่เคยซื้อ
1	6	3
2	7	3
3	4	6
4	5	8
5	9	5

ตารางที่ 10-2ข : ชุดข้อมูลทดสอบ (Test Set)

รายการ	จำนวนครั้งที่ซื้อสินค้าต่อเดือน	จำนวนประเภทสินค้าที่เคยซื้อ
1	7	5



ภาพที่ 10-4 : ชุดข้อมูลฝึก (Training Set)

วิธีทำ

- การเทรนโมเดล

กำหนดให้ทุก Training Points เป็น Clusters

$x_1 =$	6	3
$x_2 =$	7	3
$x_3 =$	4	6
$x_4 =$	5	8
$x_5 =$	9	5

รอบที่ 1

x_i	x_j	$d(x_i, x_j)$	การคำนวณระยะทางระหว่าง x_i กับ x_j	ระยะทางระหว่าง x_i กับ x_j
x_1	x_2	d12	$\text{SQRT}((6-7)^2+(3-3)^2)$	1.00
x_1	x_3	d13	$\text{SQRT}((6-4)^2+(3-6)^2)$	3.61
x_1	x_4	d14	$\text{SQRT}((6-5)^2+(3-8)^2)$	5.10
x_1	x_5	d15	$\text{SQRT}((6-9)^2+(3-5)^2)$	3.61
x_2	x_3	d23	$\text{SQRT}((7-4)^2+(3-6)^2)$	4.24
x_2	x_4	d24	$\text{SQRT}((7-5)^2+(3-8)^2)$	5.39
x_2	x_5	d25	$\text{SQRT}((7-9)^2+(3-5)^2)$	2.83
x_3	x_4	d34	$\text{SQRT}((4-5)^2+(6-8)^2)$	2.24
x_3	x_5	d35	$\text{SQRT}((4-9)^2+(6-5)^2)$	5.10
x_4	x_5	d45	$\text{SQRT}((5-9)^2+(8-5)^2)$	5.00

รวม x_1 กับ x_2 ไปเป็น cluster ใหม่ (x_1, x_2) เนื่องจากมีระยะทางระหว่างกันน้อยที่สุด (ระยะทาง = 1.00)

ทำให้ตอนนี้มีจำนวน Cluster เหลืออยู่ 4 Clusters ประกอบด้วย (x_1, x_2), x_3 , x_4 , และ x_5

รอบที่ 2 : นำ Cluster (x_1, x_2) , x_3 , x_4 , และ x_5 ที่ได้จากรอบที่ 1 มาคำนวณระยะทาง

x_i	x_j	$d(x_i, x_j)$	การคำนวณระยะทางระหว่าง x_i กับ x_j	ระยะทางระหว่าง x_i กับ x_j
(x_1, x_2)	x_3	d_{13}, d_{23}	$\text{MIN}(d_{13}, d_{23})$	3.61
(x_1, x_2)	x_4	d_{14}, d_{24}	$\text{MIN}(d_{14}, d_{24})$	5.10
(x_1, x_2)	x_5	d_{15}, d_{25}	$\text{MIN}(d_{15}, d_{25})$	2.83
x_3	x_4	d_{34}	$\text{SQRT}((4-5)^2 + (6-8)^2)$	2.24
x_3	x_5	d_{35}	$\text{SQRT}((4-9)^2 + (6-5)^2)$	5.10
x_4	x_5	d_{45}	$\text{SQRT}((5-9)^2 + (8-5)^2)$	5.00

รวม x_3 กับ x_4 ไปเป็น cluster ใหม่ (x_3, x_4) เนื่องจากมีระยะทางระหว่างกันน้อยที่สุด (ระยะทาง = 2.24)

ทำให้ตอนนี้มีจำนวน Cluster เหลืออยู่ 3 Clusters ประกอบด้วย (x_1, x_2) , (x_3, x_4) , และ x_5

รอบที่ 3 : นำ Cluster (x_1, x_2) , (x_3, x_4) , และ x_5 ที่ได้จากรอบที่ 2 มาคำนวณระยะทาง

x_i	x_j	$d(x_i, x_j)$	การคำนวณระยะทางระหว่าง x_i กับ x_j	ระยะทางระหว่าง x_i กับ x_j
(x_1, x_2)	(x_3, x_4)	$d_{13}, d_{14}, d_{23}, d_{24}$	$\text{MIN}(d_{13}, d_{14}, d_{23}, d_{24})$	3.61
(x_1, x_2)	x_5	d_{15}, d_{25}	$\text{MIN}(d_{15}, d_{25})$	2.83
(x_3, x_4)	x_5	d_{35}, d_{45}	$\text{MIN}(d_{35}, d_{45})$	5.00

รวม (x_1, x_2) กับ x_5 ไปเป็น cluster ใหม่ (x_1, x_2, x_5) เนื่องจากมีระยะทางระหว่างกันน้อยที่สุด (ระยะทาง = 2.83)

ทำให้ตอนนี้มีจำนวน Cluster เหลืออยู่ 2 Clusters ประกอบด้วย (x_1, x_2, x_5) และ (x_3, x_4)

เนื่องจาก เหลืออยู่ 2 Clusters ตามต้องการแล้ว จึงไม่จำเป็นต้องรวมให้เหลือ 1 Cluster

ทั้งนี้ไม่มีหลักเกณฑ์ตายตัวว่ากลุ่มข้อมูลไหนต้องเป็น Cluster 0 หรือ Cluster 1

ในกรณีนี้ กำหนดให้กลุ่มที่รวมตัวเสร็จก่อนเป็น Cluster 0 จากนั้นก็เพิ่มขึ้นเรื่อย ๆ **โดยให้**

(x_3, x_4) ซึ่งมีระยะทาง 2.24 เป็นสมาชิกของ Cluster 0


(x_1, x_2, x_5) ซึ่งมีระยะทาง 2.83 เป็นสมาชิกของ Cluster 1

หากต้องการรวมให้เหลือ 1 Cluster แล้วสร้าง Dendrogram เพื่อหาจำนวน Cluster ก็สามารถทำได้ ดังนี้

รอบที่ 4 : นำ Cluster (x_1, x_2, x_5) และ (x_3, x_4) ที่ได้จากรอบที่ 3 มาคำนวณระยะทาง

x_i	x_j	$d(x_i, x_j)$	การคำนวณระยะทางระหว่าง x_i กับ x_j	ระยะทางระหว่าง x_i กับ x_j
(x_1, x_2, x_5)	(x_3, x_4)	$d_{13}, d_{14}, d_{23}, d_{24}, d_{35}, d_{45}$	$\text{MIN}(d_{13}, d_{14}, d_{23}, d_{24}, d_{35}, d_{45})$	3.61

นำระยะทางที่คำนวณได้มาสร้าง Dendrogram จากนั้นกำหนดเส้นแบ่ง หากต้องการ 2 Clusters ให้สร้างเส้นแบ่งในช่วง 2.83 - 3.61 หรือ หากต้องการ 3 Clusters ให้สร้างเส้นแบ่งในช่วง 2.24 - 2.83



ภาพที่ 10-5 : Dendrogram สำหรับแบ่ง Cluster

- การทดสอบโมเดล

จาก

$$d(x, x_i) = \sqrt{\sum_{l \in m} (x_l - x_{il})^2} \quad \hat{y} = \text{cluster} \left(\arg \min_{x_i} d(x, x_i) \right)$$

$$x = [7, 5] \quad x_1 = [6, 3], \quad x_2 = [7, 3], \quad x_3 = [4, 6], \quad x_4 = [5, 8], \quad x_5 = [9, 5]$$

จะได้

$$d(x, x_1) = \sqrt{(7 - 6)^2 + (5 - 3)^2} = 2.24$$

$$d(x, x_2) = \sqrt{(7 - 7)^2 + (5 - 3)^2} = 2$$

$$d(x, x_3) = \sqrt{(7 - 4)^2 + (5 - 6)^2} = 3.16$$

$$d(x, x_4) = \sqrt{(7 - 5)^2 + (5 - 8)^2} = 3.61$$

$$d(x, x_5) = \sqrt{(7 - 9)^2 + (5 - 5)^2} = 2$$

$$\hat{y} = \text{cluster} \left(\arg \min_{x_i} \{2.24, 2, 3.16, 3.61, 2\} \right) = \text{cluster}\{x_2, x_5\} = 1$$

(x_3, x_4) เป็นสมาชิกของ Cluster 0
 (x_1, x_2, x_5) เป็นสมาชิกของ Cluster 1

ตอบ ลูกค้านี้ถูกจัดให้อยู่ใน Cluster 1 เนื่องจากมีระยะทางใกล้กับ Training Points ที่เป็นสมาชิกของ Cluster 1 มากที่สุด (ทั้ง x_2 และ x_5 เป็นสมาชิกของ Cluster 1)

10.3.3 ตัวอย่างโค้ด Agglomerative Algorithm

```
1  #Import Python Package
2  import numpy as np
3  from sklearn.cluster import AgglomerativeClustering
4  from scipy.spatial.distance import euclidean
5  import matplotlib.pyplot as plt
6  import scipy.cluster.hierarchy as shc
7  from sklearn.metrics import davies_bouldin_score
8
9  #Load Data
10 x_train = np.array([[6, 3], [7, 3], [4, 6], [5, 8], [9, 5]])
11 x_test = np.array([7, 5])
12
13 #Build Model
14 net = AgglomerativeClustering(linkage='single',
15                               metric='euclidean',
16                               n_clusters=2).fit(x_train)
17 labels = net.labels_
18 print('Cluster Labels (Train) : ', labels) #show train cluster labels
19
20 #Test Model
21 y_pred = min(np.unique(labels),
22              key=lambda k: min(euclidean(x_test, xi) for xi in x_train[labels == k]))
23 print('Cluster Labels (Test) : ', y_pred)
24
25 #Evaluate Model
26 dbi = davies_bouldin_score(x_train, net.labels_)
27 print(f'DBI : {dbi:.2f}')
28
29 #Show Dendrogram (Tree)
30 plt.figure(figsize=(10, 7))
31 plt.title("Dendograms")
32 dend = shc.dendrogram(shc.linkage(x_train, method='single'))
```

Cluster Labels (Train) : [0 0 1 1 0]

Cluster Labels (Test) : 0

DBI : 0.59

10.4 แบบฝึกหัด


1. จงแสดงวิธีการคำนวณ K-Mean เพื่อจัดกลุ่มนักศึกษา โดยทำการปรับ Centroid จำนวน 2 รอบ และใช้ค่าของ Centroid เริ่มต้น ดังนี้ $c_0 = [2, 13]$, $c_1 = [3, 18]$, $c_2 = [3, 8]$

ตารางที่ 10-3ก : ชุดข้อมูลฝึก (Training Set)

รายการ	เกรดเฉลี่ย (GPA)	รายได้ต่อเดือน (1,000 บาท)
1	3.85	20
2	3.7	16
3	3.6	18
4	3.5	19
5	2.5	14
6	2.4	15
7	2.2	12
8	2.1	13
9	3.2	9.5
10	3.3	8.5
11	3	8
12	3.2	7

ตารางที่ 10-3ข : ชุดข้อมูลทดสอบ (Test Set)

รายการ	เกรดเฉลี่ย (GPA)	รายได้ต่อเดือน (1,000 บาท)
1	3.4	16



ภาพที่ 10-6 : ชุดข้อมูลฝึก (Training Set)


2. จงแสดงวิธีการคำนวณ Agglomerative Algorithm เพื่อจัดกลุ่มนักศึกษา กำหนดให้มี 2 Clusters

ตารางที่ 10-4ก : ชุดข้อมูลฝึก (Training Set)

รายการ	เกรดเฉลี่ย (GPA)	รายได้ต่อเดือน (1,000 บาท)
1	3.5	16
2	3.2	19
3	2.4	10
4	2.3	12
5	2.2	9

ตารางที่ 10-4ข : ชุดข้อมูลทดสอบ (Test Set)

รายการ	เกรดเฉลี่ย (GPA)	รายได้ต่อเดือน (1,000 บาท)
1	2.5	8



ภาพที่ 10-7 : ชุดข้อมูลฝึก (Training Set)



THANK YOU FOR YOUR ATTENTION

 pichai_jo@rmutto.ac.th

